

分类号: TM714

密 级: 公开

单位代码: 10422

学 号: 201820427



山东大学
SHANDONG UNIVERSITY

博士学位论文

Dissertation for Doctoral Degree

(专业学位)

论文题目: 交互式多模型电力负荷建模问题研究

Research on Interacting Multiple Model Based Power
System Load Modeling

作 者 姓 名	卞绍润
培 养 单 位	电气工程学院
专 业 名 称	先进制造
指 导 教 师	王振树 教授
合 作 导 师	

2024 年 5 月 23 日

摘 要

随着世界范围内能源转型的深入,能源消费电气化转型已成为能源消费结构的发展趋势,分布式电源、电动汽车、储能装置等含有高比例电力电子元件的新型电力负荷在负荷构成中的占比越来越高,导致电力系统的动态特性发生重大变化。新一代电力系统呈现出高比例可再生能源,高比例新型电力负荷,高比例电力电子设备,多能互补综合能源和物理信息深度融合等技术特征。现有电力负荷模型无法准确反映这种负荷构成的变化和新型负荷的特性信息,会导致电力系统动态安全评估和电压稳定分析结果的不准确。从更符合电力负荷实际的角度进行负荷建模的困难在于负荷的时变性和耦合性问题。采用特定时间量测数据建立负荷模型的传统建模方法无法有效捕捉负荷时变信息。电力系统的负荷之间存在耦合关系,系统受到的扰动会对每个负荷节点的模型参数辨识产生不同的影响。交互式多模型(Interacting Multiple Model, IMM)负荷建模方法能够克服电力系统负荷的时变特性,具有跟踪精度高、计算量小的优点。深度学习,尤其是深度神经网络在计算机视觉领域的突出表现,为电力系统中采用传统方法或基于模型的方法无法解决的问题带来了新的机遇。建立能够反映符合实际负荷特性的负荷模型,是新型电力系统建模研究的基础。因此,对 IMM 负荷建模问题进行系统的研究具有重要理论意义和实用价值。

本文主要研究内容和创新点如下:

(1) 针对时变负荷建模问题,提出了一种基于改进交互式多模型(Improved Interacting Multiple Model, IIMM)算法的负荷建模方法(以下简称“IIIMM 负荷建模方法”)。在分析 IMM 机理的基础上,深入研究影响 IMM 负荷建模方法有效性的模型转移概率更新问题,采用极化校正函数和激活校正函数对模型转移概率进行动态更新。根据 IIMM 算法的基本理论,建立 IIMM 负荷建模方法的框架。采用一组负荷模型集描述系统可能的负荷特性,从整体负荷模型集中遴选出最优模型参与输入交互,不同模型通过马尔可夫链实现转移,利用扩展卡尔曼滤波器并行滤波,依据估计误差更新各模型权重,依概率进行各模型的输出融合,生成符合实际负荷特性的综合负荷模型。仿真结果表明,IIIMM 负荷建模方法具有精度高的优点。

(2) 针对以往的负荷建模方法未考虑电力系统内电源、其它负荷等对该节点负荷的交互耦合影响问题,提出基于图卷积神经网络的负荷节点数据解耦方法。利用图表示学习和图卷积神经网络(Graph Convolutional Neural Network, GCN)理论分析电力系统图特性,将电力系统按一定原则简化并进行图表示,以发电机、负荷节点为图节点,以线路为图的边,获取图的邻接矩阵等信息。将图特征数据及各节点电压、功率数据作为

GCN 输入，以边传递消息，节点聚合消息，采用 GCN 理论对电力系统扰动过程中各节点的耦合深入分析。训练 GCN 模型得到各节点间相互影响的权重信息，利用权重信息对负荷数据解耦，获取反映各负荷节点实际特性的电压和响应功率。仿真测试结果验证了所提方法的有效性。

(3) 为研究电力负荷季节时变特性，探索电力负荷的周期性规律，提出基于主成分分析网络 (Principal Component Analysis Network, PCANet) 和卷积双向长短记忆神经网络 (Convolutional Neural Network and Bi-directional Long-Short Term Memory, CNN+Bi-LSTM) 算法的电力负荷时变特性特征提取及分类方法。借鉴深度学习理论和方法在图像处理中的应用，通过对日负荷曲线的数据挖掘，提取反映季节性电力负荷特性的特征，依据特征提取的分类实现对同一负荷节点的季节划分。利用格拉姆角场将时间序列编码的日负荷曲线转换为极坐标系中的二维图像；对图像进行二层卷积主成分分析滤波处理，采用 PCANet 方法获取负荷深度特征。针对负荷深度特征的分类，采用 CNN 和 Bi-LSTM 算法相结合构建分类器，获得各季节的典型负荷特性曲线。以某电网负荷实例分析验证了所提方法的有效性，该方法分类准确性高，满足时变负荷建模需要。

关键词：负荷建模；交互式多模型；时变性；耦合性

ABSTRACT

With the deepening of energy transition around the world, the electrification has become the development trend of energy consumption. New types of loads, such as distributed energy resources, electric vehicles and energy storage devices, contain a high proportion of power electronic components and account for an increasing proportion of load composition, resulting in significant changes in dynamic characteristics of the power system. The new generation of power system presents characteristics of high proportion of renewable energy, high proportion of new loads, high proportion of power electronic equipment, multi-energy complementary integrated energy, deep integration of physical information and other technical characteristics. The existing load model cannot accurately reflect the change of load composition and the characteristic information of new loads, which will lead to inaccurate conclusion of power system dynamic safety assessment and voltage stability analysis. The difficulty of load modeling lies in the time-varying and coupling issues from the perspective of reflecting the real load characteristics. The traditional modeling method of using measurement data at a specific time to establish a load model cannot effectively capture the time-varying information of the load. There is a coupling relationship between the loads in the power system, and disturbances in the power system will have different effects on the parameter identification of each load. The interacting multiple model (IMM) based load modeling method can overcome the time-varying characteristics of power system load, and has the advantages of high tracking accuracy and small amount of calculation. Deep learning, especially the success application of deep neural networks in the field of computer vision, has brought new opportunities for problems that cannot be solved by traditional or model-based methods in power systems. Therefore, establish an accurate load model that can reflect the dynamic characteristics of the load is fundamental to modeling and research of the new power system, it is of theoretical and practical significance to study the interacting multiple model based power system load modeling.

The main research contents and innovations of the thesis are as follows:

(1) In order to solve the time-varying problem of load modeling, a load modeling method based on improved interacting multiple model (IIMM) algorithm is proposed in this thesis. The mechanism of the IMM algorithm is analyzed, and the model transfer probability that affects the effectiveness of interacting multiple model based load modeling is studied and

improved. Then, the polarization correction function and the activation correction function are applied to dynamically update the model transfer probability. According to the basic theory of IIMM algorithm, a framework for IIMM based load modeling is established. A set of load models is used to describe the possible load characteristics, and the optimal models are selected from the overall load model set to participate in the input interaction. Different models are transferred through Markov chains, and the extended Kalman filter is used for parallel filtering, the weights of each model are updated according to the estimation error. Finally, the output fusion of each model is carried out according to the probability to generate a comprehensive load model close to the actual load characteristics. Simulation results show that the IIMM load modeling method is of high accuracy and can effectively solves the time-varying problem of load characteristics.

(2) In view of the fact that the previous load modeling methods do not consider the interactive coupling influence of other loads and power sources on the load in the system, a decoupling method based on graph convolutional neural network is proposed for load characteristic analysis. The graph representation learning and graph convolutional neural network (GCN) are used to analyze the graph characteristics of the power system. The power system is simplified and represented according to certain principles, and the information such as the adjacency matrix of the graph is obtained by taking the generator and load as the graph nodes and the line as the edges of the graph. The voltage and power data of each node as well as the graph feature are used as GCN inputs, then the coupling of each node in the process of power system disturbance is analyzed by using the GCN theory to transmit messages at the edge and aggregate messages by nodes. The GCN model is trained to obtain the weight information of the interaction between each node, and the weight information is used to decouple the load data to obtain the voltage and power response that reflect the actual characteristics. Simulation results proved effectiveness of the proposed decoupling method.

(3) In order to study the seasonal time-varying characteristics and explore the periodic law of power load, a time-varying characteristic feature extraction and classification method based on principal component analysis network (PCANet) and convolutional neural network and bi-directional long-short term memory (CNN+Bi-LSTM) algorithm is proposed. Based on the application of deep learning theory in image processing, the features that can reflect the seasonal power load characteristics are extracted via data mining of the daily load curves. Then the seasonal division of the load is realized based on the classification of extracted features. The gramian angular field is used to convert the time-series encoded daily load curve into a two-dimensional image in a polar coordinate system. In the two-layer convolutional

Principal Component Analysis filtering of images, the PCANet method is used to obtain the depth characteristics of load. For the classification of depth characteristics, the CNN+Bi-LSTM algorithm combining advantages of CNN and Bi-LSTM algorithms is used to construct a classifier to obtain the typical load curve of each season. The effectiveness of the proposed method is verified by an example of power grid load analysis, and the proposed method is of high classification accuracy and can meet the needs of time-varying load modeling and analysis.

Key words: load modeling; interacting multiple model; time-variability; coupling

目 录

1 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	3
1.2.1 交互式多模型负荷建模研究现状.....	3
1.2.2 电力负荷耦合性研究现状.....	5
1.2.3 电力负荷时变性研究现状.....	7
1.3 存在的主要问题.....	10
1.4 本文主要研究工作.....	11
2 改进交互式多模型负荷建模	13
2.1 引言	13
2.2 改进交互式多模型基本理论	14
2.2.1 IMM 算法	14
2.2.2 极化校正函数.....	15
2.2.3 激活校正函数.....	16
2.2.4 TPM 更新策略.....	18
2.3 改进交互式多模型负荷建模方法	19
2.3.1 负荷模型集构成.....	20
2.3.2 最优负荷模型输入交互.....	21
2.3.3 状态估计.....	23
2.3.4 负荷模型概率更新.....	27
2.3.5 最优负荷模型输出融合.....	27
2.4 算例分析.....	29
2.5 本章小结.....	40
3 基于 GCN 的电力负荷解耦.....	41
3.1 引言	41
3.2 考虑负荷特性的电力系统图表示	41
3.2.1 电力系统图表示.....	41
3.2.2 电力系统图学习.....	43
3.3 基于 GCN 的电力负荷解耦方法	44
3.3.1 图卷积神经网络.....	44
3.3.2 基于 GCN 的负荷解耦	46
3.4 算例分析.....	48
3.4.1 算例系统设置.....	49
3.4.2 电力负荷耦合性验证.....	51

3.4.3 图卷积神经网络解耦.....	55
3.4.4 解耦效果分析.....	58
3.4.5 解耦效果验证.....	64
3.5 本章小结.....	67
4 电力负荷季节时变特性分析	68
4.1 引言	68
4.2 电力负荷特性的基本分类方法	69
4.3 电力负荷时变特性特征提取与分类框架	74
4.4 基于 PCANet 和 CNN+Bi-LSTM 算法的负荷时变特性特征提取 与分类方法	76
4.4.1 日负荷曲线数据处理.....	76
4.4.2 时间序列数据转换.....	80
4.4.3 负荷特性特征提取.....	83
4.4.4 负荷特性分类算法.....	85
4.5 算例分析.....	93
4.6 本章小结.....	100
5 结论与展望.....	101
参考文献.....	103

1 绪论

1.1 研究背景及意义

随着世界化石能源逐渐枯竭与气候危机加剧,各国政府为促进绿色和可持续发展积极实施能源转型^[1,2]。当前,太阳能光伏、海上和陆上风电、生物质能、地热、氢能等新能源发电成本大幅降低,一次能源消费向电的消费转型已成为能源消费的发展趋势。含有高比例电力电子元件的新型负荷,如分布式电源、电动汽车、储能装置等在负荷构成中的占比越来越高,大量可再生能源接入电网代替了传统交流发电^[3]。预计到 2050 年,电力在能源消费端的份额将提升至 50%~60%,新能源发电量占世界总发电量的比重将达到 75%~80%^[4]。新能源的输出具有波动性和不确定性,大量基于电力电子的新设备接入电网,导致电力系统的动态特性发生根本性变化,对电力系统的安全稳定运行将产生重大影响。

面对我国能源发展新形势,2021 年 3 月中央财经委员会第九次会议提出构建新型电力系统。随着我国能源转型的不断深入,新型电力系统呈现出高比例可再生能源和高比例新型电力负荷特征。电力负荷由原来的刚性、消费型向新型柔性、产消型负荷转变,电力负荷的复杂程度越来越高^[5,6]。新能源并网系统的电力电子设备缺乏同步发电机的“实体转轴”,使得新型电力系统逐步呈现低惯量,存在失稳隐患。然而,受端大部分电动机类负荷接入电力电子的变频调速设备,削弱了电力系统受到大的扰动时电力电子的变频调速设备与电网母线联结处的电压支撑。

负荷建模对电力系统的分析、规划、运行和控制具有重要影响^[7-9]。历史上多次大规模停电都表明了准确负荷模型的重要性,如 1983 年瑞典停电、1987 年东京电网崩溃和 1996 年北美西部停电^[10-12]。针对上述事件,国际一些电力系统专业组织开展了更多关于负荷建模的研究,例如西部电力协调委员会(Western Electricity Coordinating Council, WECC)于 2002 年成立负荷建模工作组(Load Modeling Task Force, LMTF),为电力系统规划与运行研究开发综合负荷模型^[13];美国电力科学研究院(Electric Power Research Institute, EPRI)于 2004 年启动了协同负荷建模研究计划;国际大电网会议(International Conference on Large Electric Systems, CIGRE)成立了负荷建模工作组^[14]。电力负荷模型对短路计算、电压稳定性、小信号稳定性和暂态稳定性分析产生了越来越重要的影响^[15-18]。特别是近年来,随着分布式发电、电动汽车和需求侧管理等新兴智能电网技术的出现,更新现有负荷模型结构并提高负荷模型的准确性和灵活性势在必行^[19,20]。然

而, 电力负荷的复杂性、时变性给准确负荷建模带来了诸多困难^[21-23]。因此, 准确的负荷建模已成为当今电力系统动态研究和仿真的挑战之一^[24]。

负荷模型分为静态模型和动态模型。负荷的静态模型描述了负荷在电力系统电压和频率缓慢变化时, 其有功功率、无功功率随之变化的规律, 主要包括幂函数模型、多项式模型。在只计及负荷电压特性时, 多项式模型简化为 ZIP 模型。动态模型描述了负荷在电力系统电压和频率快速变化时, 其相应的负荷电压、频率变化特性。由于感应电动机 (Induction Motor, IM) 在电力负荷中占比较高, 是动态负荷的主要成分, 因此通常就用 IM 模型描述负荷动态特性^[25,26]。由于具有物理意义以及能够反映负荷构成比例的优点, 目前在电力系统动态分析中仍然采用 ZIP 模型和 IM 模型组合构成的综合负荷模型^[27]。随着电力系统的发展和对负荷建模探讨的深入, 虽然有文献报道对传统综合负荷模型的结构进行了改进^[28,29], 但仍然无法准确获取完整的电力负荷特性。近年来, 随着用电负荷结构发生了重大变化, 非线性电力电子负荷、分布式电源和储能装置在受电一侧大规模投入使用^[30], 分布式电源及电力电子负荷需要考虑到模型中, WECC 已经将分布式电源作为未来改进综合负荷模型的首要工作。由于新型负荷具有较强的非线性、复杂性, 与传统负荷特性相比差异性较大, 采用模型单一、结构和参数固定的 ZIP+IM 综合负荷模型难以描述其物理特性^[31,32]。

数十年来, 国内外科技工作者对负荷建模方法的研究取得了丰富成果。目前, 电力负荷建模方法分为基于元件机理的建模方法和基于测量辨识的建模方法两大类。基于元件机理的负荷建模方法依赖于电力负荷数据的调查统计, 难以对一些复杂过程和因素进行描述, 且无法实现在线负荷建模。基于测量辨识的负荷建模方法利用现场数据对负荷模型参数进行辨识, 建立特定时间和地点的负荷模型, 但该建模方法建立的负荷模型多采用固定结构与参数的单一模型^[33,34]。鉴于在电力系统中安装的监测设备越来越多, 大多数研究均集中基于测量的负荷建模方法^[35]。

虽然电力负荷建模的研究取得了较多的成果, 但由于电力负荷复杂性、时变性以及缺乏详细的负荷信息等原因, 现有的电力负荷模型很难适应新型电力系统分析、规划、运行与控制的需要^[36]。交互式多模型 (Interacting Multiple Model, IMM) 电力负荷建模方法是基于交互式多模型及其改进算法相关理论的建模方法, 在综合负荷成分、特性发生突变时, 实现负荷非线性结构精确建模, 解决电力负荷成分多样性、时变性的综合建模问题, 文献^[37-40]进行了有益的探讨。一方面, 基于测量辨识的负荷建模方法都仅通过考虑负荷所连接的相应母线上的扰动量测数据来辨识负荷模型参数; 由于所有负荷均集成在电力系统中, 系统中的扰动会对每个负荷的参数辨识产生不同的影响, 即在目标负荷与同一系统连接的

其它负荷之间存在耦合关系。另一方面, 负荷构成与时间、天气、季节、价格等具有密切复杂联系, 在缺少量测数据和详细负荷统计信息的情况下, 采用特定时间量测数据建立负荷模型的传统建模方法无法有效捕捉负荷时变性信息, 负荷模型的泛化能力不足, 这是当前负荷建模问题的难点所在。本文研究 IMM 负荷建模及相关的时变性和耦合性问题, 具有重要的理论价值和现实意义。

1.2 国内外研究现状

1.2.1 交互式多模型负荷建模研究现状

多模型 (Multiple Model, MM) 理论源自控制理论中的多模型控制, 这些算法主要应用于目标跟踪领域。1965 年, D.T.Magill 提出了 MM 算法。MM 算法中的每个模型都有相应的滤波器, 系统的估计是通过每个模型的滤波器的估计加权实现。MM 算法能够较好地估计具有时变结构和参数的系统状态。本世纪一十年代, 随着电力电子技术、现代控制理论等一系列新技术、新理论在电力系统中的应用, 分布式新能源发电设备接入电网, 大量电力电子设备广泛应用于电力系统, 所有这些都使得电力负荷的特性更加复杂。传统的负荷模型结构总是采用单一的模型, 结构和参数都是固定的, 从而限制了在负荷成分变化的情况下建立准确的负荷模型。文献[37]提出基于 MM 思想的自适应综合动态电力负荷建模, 基于 MM 理论建立负荷模型集, 模型集中的每个模型都有一个权重; 将传统的负荷模型作为负荷模型集合中负荷模型的基本结构。当实际负荷系统存在机动时, 可以调整电力负荷模型的参数和权重。然后, 将模型集中的模型集成到自适应综合动态负荷模型中。

1984 年, Blom 等人对广义伪贝叶斯 (Generalized Pseudo Bayesian, GPB) 算法进行改进, 提出了 IMM 算法。IMM 算法通过并行运行多个卡尔曼滤波器来简化模型选择过程。IMM 算法是一种用于机动目标的状态估计算法, 通过同时并行运行一组滤波器并使用加权概率组合每个滤波器的估计来解决 MM 估计问题; 概率由滤波器递归计算, 并表示每个模型捕捉系统表现出的当前动态行为。与仅使用一个模型进行估计的基于决策的模型相比, IMM 技术使用基于不同模型的并行滤波器进行估计, 然后在所有单个估计的加权和基础上生成最终估计^[41]。为了克服电力系统负荷的时变特性, 有效的方法是采用 IMM 算法进行负荷建模。文献[38]提出了基于 IMM 算法的电力负荷建模方法 (Interacting Multiple Load Modeling, IMLM), 具有跟踪精度高、计算量小的优点; 采用综合负荷模型作为负荷模型集中子模型的基本结构, 根据模型集中各子模型的归一化新息加权平方和构建负荷模型的遴选机制, 筛选出最优模型集; 最优模型集中的各个子模型之

间存在马尔可夫转移概率, 利用马尔可夫转移矩阵进行各个子模型之间交互运算; 采用扩展卡尔曼滤波对子模型的状态变量求解; 通过计算子模型的似然函数来调整子模型的权重; 对各个子模型加权求和获得模型集输出。文献[39]提出了一种用于 IMLM 的模型选择机制, 以实现最佳模型集的自适应调整; 选择最优模型集进行交互的模型选择机制的方法, 解决了模型集的完整性与大模型集的模型竞争之间的矛盾。该方法将 ZIP+IM 综合负荷模型的结构作为交互式多负荷模型结构; 基于负荷模型集的选择和初始化, 所有状态计算器并行工作, 以获得每个模型与实际系统之间的新息误差; 计算提供了每个模型在新息向量和协方差方面的归一化新息平方和; 通过选择机制, 能够从整体负荷模型集中选择几个最匹配的负荷模型参与模型交互过程; 通过数值仿真验证了所提出方法的有效性。

1995 年, A.Munir 和 D.P.Atherton 提出了一种自适应交互式多模型 (Adaptive Interacting Multiple Model, AIMM) 算法^[42]。AIMM 算法是一种具有自适应模型集的 IMM 算法。与 IMM 算法相比, 参与输入交互的模型更少, 跟踪精度更高^[43]。AIMM 算法的基本思想是自适应地从模型集中选取最有可能代表观测系统运动模式的子模型进行交互建模。归一化新息平方和用于在输入交互的整个模型集中选择最优模型。每个最优模型之间存在齐次马尔可夫变换关系。每个模型都匹配一个滤波器, 该滤波器并行工作来估计状态。在状态估计之后, 根据估计的误差更新所有模型概率, 并根据更新的概率融合状态估计的结果, 从而跟踪机动目标^[42,44]。

IMM 方法在很大程度上依赖于模型交互。转移概率矩阵 (Transition Probability Matrix, TPM) 具有马尔可夫转移特性, 它混合了模型概率, 影响估计精度。由于目标的动态模型在运动过程中随时可能发生变化, 因此它是在一组预定的状态空间模型之间进行切换。假设各个模型遵循马尔可夫链定义的马尔可夫过程, 则 TPM 反映了这种变化过程。标准的解决方案是将 TPM 组件设置为恒定值。然而, 如果系统波动或转移概率不合适, 这种方法可能导致不正确的状态估计。文献[45]将模型转移概率矩阵马尔可夫参数自适应的新息滤波多模型 (Adaptive Markov Parameter Innovation Filtering Interacting Multiple Model, AMP-IFIMM) 算法引入了误差压缩比的概念, 并基于该比率自适应调整马尔可夫 TPM, 以增加匹配模型的概率, 降低不匹配模型的概率。然而, 这种方法只适用于双模型系统, 不能扩展到多模型。文献[46]通过由 TPM 元素和模型概率构建的模型误差压缩率自适应地估计 TPM, 这增加了模型稳定阶段的精度。但是由于 TPM 的过度调节, 故模型算法的鲁棒性降低。文献[47]使用模型概率变化率的指数函数来映射 TPM 元素的调整率, 并且算法更稳定, 但调整不够深入。文献[48]提出利用当前测量信息更新目标的模型概率, 并利用更新后的模型概率

对目标状态进行混合预测，在一定程度上提高了算法的滤波性能。文献[49]通过使用包含过去模型信息的模型概率梯度和似然比对 TPM 校正函数进行建模，并使用两个并行的 IMM 来获得更多关于模型跳跃的信息，子模型跳跃阈值的设置解决了响应滞后和峰值估计误差问题；但并行结构使计算工作量加倍，并且不能验证两个以上的模型。文献[50]引入了新的校正因子，利用后验的信息对 TPM 进行动态校正，增强了模型匹配的概率，在一定程度上提高了滤波和跟踪精度。上述算法虽然修改了 TPM，解决了切换过程模型的概率滞后问题，但均没有解决固定滤波参数的问题。文献[51]提出了包含极化校正函数和激活校正函数对 TPM 动态更新，采用两个函数的融合方法来解决固定滤波参数这一难题。校正过程分为两部分，一部分是子模型非跳跃段；另一部分为子模型跳跃段。通过权重提高状态估计性能，尽可能地抑制低模型概率，加快子模型之间的跳转。该方法基于当前系统模型信息自适应地更新转移概率，提高了 IMM 技术的性能。

1.2.2 电力负荷耦合性研究现状

电力系统是一典型的复杂网络系统，由大量、不同而且强非线性相互作用的组成单元构成^[52,53]。随着科技的发展，电源、输电或供电网络和负荷在构成形式、交互耦合和相互作用等方面的关系更趋复杂，且电源、负荷等元件更新频率增加，对电力系统运行控制与稳定将产生深远影响^[54,55]。文献[56]研究表明，电力系统发生扰动后，电压与频率存在耦合和相互影响，不同负荷特性对各负荷节点的电压与频率动态交互影响的程度不同。在综合能源系统中，不同负荷之间的复杂互补关系不仅取决于需求侧的用户行为，还受到气象因素的影响，不同类型负荷之间存在内部相互作用和线性关系，也存在不可忽视的非线性关系^[57]。广义负荷的各组成成分之间通常也存在耦合关系^[58]，主动负荷的需求侧响应通常与新能源出力情况相关^[59]。

电力系统节点之间存在着强弱不同的电气耦合关系。节点通常由一组微分方程表示的物理定律建模，通过功率平衡相互耦合。由于电力系统各节点间存在耦合关系，各节点的状态量不仅受自身扰动的影响，还受其它节点扰动的影响。文献[60]考虑了电力系统节点间局部特性与整体特性的相互影响，提出一种基于拉普拉斯矩阵谱半径的节点度指标，揭示网络中节点间的相互影响和重要度。文献[61]为定量研究电力系统的源-网-荷各组成部分之间的动态耦合关系及其变化规律和主导影响因素，提出一种基于动态阻抗的源-网-荷耦合特性分析方法。文献[62]基于节点间电气耦合作用强度，提出使用电气耦合连接度指标作为节点关键性的判据，该判据弥补了拓扑结构模型只关注节点拓扑连线关系的不足。

在电力系统中，所有负荷节点之间存在耦合关系。一方面，每个负荷节点的电流不仅会对自身电压产生作用，也会影响其它负荷节点的电压；另一方面，每

个负荷节点的电压都会受到其余所有负荷节点电流的影响。为体现负荷节点间的电压、电流相互关系，传统网络阻抗矩阵元素使用两负荷节点间的互阻抗表示，虽然考虑了网络的拓扑结构，但没有计及潮流信息，难以准确描述负荷节点间的耦合关系。文献[63]对电力系统负荷节点耦合关系进行了深入研究，提出节点耦合阻抗矩阵和动态阻抗矩阵描述节点耦合关系。负荷节点耦合等值阻抗反映的是所有负荷节点在所研究负荷节点处产生的电压降落与所研究负荷节点电流间的相互关系，用来近似描述节点耦合关系。动态等值阻抗矩阵能够方便表征负荷节点间的耦合关系，能够用来准确描述节点耦合关系。负荷节点间耦合关系的强弱则取决于两负荷节点之间的动态互阻抗。

在负荷建模中，单个孤立负荷的模型与复杂电网环境中的负荷模型之间的区别尚未研究清楚。一方面，Berg 坚持认为，他的负荷模型代表了进行实验的斯堪的纳维亚微电网环境中的负荷^[64,65]；另一方面，Hill 对单负荷实验室环境中电压下降导致的电力中断进行了“曲线拟合”^[66,67]。这两个模型之间的一个令人困惑的区别是，Berg 模型涉及大约 50 个周期/秒的窄带宽中的分数指数频率，而 Hill 模型中的一个挥之不去的问题是它缺乏频率相关性。文献[68]证明了该区别是负荷聚合效应造成的，即在正常运行情况下，负荷不会孤立存在“孤岛”，每一个负荷都会穿透整个电网。移除旧金山湾区的一个负荷节点，在 550 公里外的洛杉矶地区的 PMU 可以观察到^[69]。现有的负荷建模方法都是通过只考虑连接该负荷的相应母线上的量测数据来确定负荷参数。由于所有负荷都集成在一个电力系统中，系统中的扰动会对每个负荷的参数辨识产生不同的影响。因此，目标负荷与连接到同一电力系统的其它负荷之间存在耦合关系^[40]。

图表示学习为许多现实问题的解决提供了支持，包括但不限于图像搜索、面部识别、医学图像分析、照片处理和目标检测等。1847 年，G.Kirchoff 发表了一篇论文，其中他使用图论概念来分析电路^[70]。从那时起，图论就被用于电力网络的理论和分析^[71]。从根本上说，电力系统是由发电机、负荷及其相关控制元件组成的互联网络的系统。电力系统的图论性质如何影响系统模型的稳定性、动态性能、可控性、可观察性、可识别性和其它系统理论性质是当前研究的热点方向。基于图表示的学习对于电力系统优化、建模及分析研究具有重要借鉴意义。文献[72]建立了配电网母线和变电站网络的图论模型，并证明了配电网的变电站网络是同一配电网母线的的一个分支，这有助于配电网问题的快速解决。文献[73]提出了一种适用于任何交直流系统的铁路供电系统(Railway Power Supply Systems, RPSS)描述方法，该方法用一组子图表示 RPSS 的不同元素，合并子图得到整个 RPSS 的图及其相关的邻接矩阵和关联矩阵，克服了系统拓扑和维度的可变性问题，即使列车改变其相对位置，或者当新列车进入或退出系统时，也能获得一

个不变的系统。文献[74]提出基于频谱的图卷积神经网络 (Graph Convolutional Neural Network, GCN) 来提高变压器故障诊断的准确性, 在不同的数据量和输入特征下, GCN 的性能优于多层感知、支持向量机 (Support Vector Machine, SVM) 和卷积神经网络 (Convolutional Neural Network, CNN) 等传统方法。文献[75]利用邻接矩阵来表示配电网中节点之间的拓扑信息, 采用深度图卷积方法对设备状态与负荷之间的复杂非线性关系进行分析和提取, 从而挖掘节点之间的相关性, 优化配电网的无功功率。

图表示学习领域在过去几十年中得到了极大的发展, 特别是图神经网络 (Graph Neural Network, GNN) 极大地促进了图表示学习在现实应用中的深度和广度, 如预测^[76]、分类^[77]、模式识别^[78]等。尤其是 GCN 算法, 将卷积运算从网格数据推广到图形数据, 适用性极广, 适用于任意拓扑结构的节点与图^[79], 在节点分类与边预测等任务上效果要远远优于其它方法。然而, 现有 GNN 的参数和结构都是针对计算机视觉数据设计的, 需要根据电力系统数据的特点进一步研究。

1.2.3 电力负荷时变性研究现状

随着智能电网的发展和能源转型的深化, 分布式电源、电动汽车和储能装置等新型广义负荷在负荷构成中所占比例越来越高, 电力负荷构成也越来越复杂^[19,80-83], 电力负荷构成的随机性和时变性是造成精确负荷建模时变问题的根本原因^[84,85]。

电力系统具有时变特性, 网络结构及各类参数在日、周、月、季节、年等不同时间尺度上是动态变化的^[86]。一方面, 负荷及各发电机组出力随气候季节及经济社会活动时刻变化; 另一方面, 由于电网运行方式调整等, 电网拓扑结构、电源组成等也在发生变化。随着可再生能源发电技术及直流输电技术的发展和运用, 新能源在电网电源中的占比快速增长, 特高压、超高压交直流电网混联运行, 现代电力系统运行特性已经发生了显著变化^[5,87]。根据《新型电力系统发展蓝皮书》公布的数据, 截至 2022 年底, 我国非化石能源装机规模达 12.7 亿千瓦, 占总装机的 49%。我国电网当前正处于“电力电子化”过渡期, 电力电子元件及含电力电子设备的负荷大规模接入电力系统^[88]。电力系统电力电子化后, 其特征与传统电力系统发生迥异变化。电力系统电力电子化特征增加了系统的暂态稳定风险^[89], 电力系统负荷对整个电力系统动态行为具有重要影响^[18]。在电力电子开关作用下, 电网拓扑结构呈现时变特性, 同时在不同时间尺度控制下存在相互作用。

负荷的时变性是指负荷功率消耗不仅随电压、频率变化, 还与季节、天气、时间段以及经济社会活动有关, 反映了实际负荷的特性随时间变化的特征^[90,91]。

一方面,连续电压/无功控制设备切换,负荷随着时间不断变化^[92,93];另一方面,天气、经济、社会行为引起的负荷变化,同一地理区域内的负荷之间存在时间相关性^[94]。使用某一时期测量数据的传统负荷建模方法可能无法捕捉时变负荷行为,并且缺乏可推广性。因此,如何在负荷模型和负荷组成中表示时间和地理变化已成为当前负荷建模研究的重点课题^[9]。文献[95]将概率时变参数辨识定义为一种新的负荷建模问题,采用深度生成架构从负荷和系统范围的测量中提取时间特征,通过估计负荷参数的条件概率密度函数来解决负荷辨识中的不确定性问题。文献[96]提出了一种鲁棒时变参数识别技术,用于 ZIP+IM 综合负荷模型,能够以较高的精度识别 ZIP+IM 综合负荷模型的时变参数。

然而,电力负荷组成的变化又有一定的周期性和规律性,包括时周期性、日周期性、周周期性、月周期性、季周期性、年周期性等。电力负荷特性是具有统计规律的带有正态分布随机噪声的随机过程^[97]。一方面,一天之内不同用电设备的使用时间具有一定的规律性,例如一班制的工业企业用电时间集中在白天,居民负荷的用电在深夜和凌晨最低;另一方面,一年之内部分用电设备或用户的用电时间受气候和季节影响较大,例如排灌负荷、空调负荷等负荷的用电高峰多出现在夏季,电热性采暖负荷多出现在冬季。因此,在不同的时间段中存在不同的负荷模型。掌握电力负荷的周期性和季节性变化规律,能够为电力规划、错峰管理等提供可靠的依据和准确的指导,为负荷建模提供重要理论支持和技术支撑^[98-100]。采用基于自适应模糊逻辑强跟踪的负荷建模方法,将负荷特性和负荷模型参数辨识问题转化为负荷的实时跟踪问题,具有良好的稳态和突变状态跟踪鲁棒性,可用于在线实时负荷建模^[101]。文献[102]对两种不同的电压敏感时变负荷模型进行了综合比较,设计了两种不同的双级滤波器,以正确识别负荷模型参数,能够处理突发负荷变化时的随机性。文献[103]提出了一种基于时变负荷建模和现场实测的柔性约束梯度分析的鲁棒降压节能(Conservation Voltage Reduction, CVR)因子评价方法,对现场测量中的不确定性(包括大扰动、异常值和噪声等)具有较好的鲁棒性。

负荷特性分类是解决负荷时变问题的有效途径。负荷特性分类是把负荷组成相似或者具有相似负荷曲线的用户、变电站、时间节点等归为一类。从解决问题的角度不同可分为两种情况^[104,105]。第一种分类是变电站负荷特性分类,将负荷构成成分不同的变电站进行分类,归纳出每一类的综合负荷特性,为挑选典型变电站进行测量建模提供依据,这主要解决负荷特性的地域差异性问题。文献[106]在阐述负荷特性分类与综合内涵及意义的基础上,以变电站负荷构成比例为特征向量,分别基于模糊等价关系和模糊 C 均值(Fuzzy C-means, FCM)算法进行分类。文献[107]基于自组织映射(Self-organizing Map, SOM)神经网络理论,

提出了一种变电站负荷特性分类与综合新方法,该方法在学习速度、分类精度和抗干扰能力上有明显提高。第二种分类是负荷动特性分类,将同一负荷节点在不同时刻的负荷扰动数据提取的特征进行分类,并建立不同类别的负荷模型,这主要解决负荷的时变性问题。文献[108]提出了一种多电压等级负荷集群的分类聚合方法,根据在线辨识得到的负荷簇的稳定性和暂态特性对其进行分类和分组,基于感应电机电压角的加权平均对具有相似动态特征的分组负荷模型进行聚类,该方法可以将从低电压水平到高电压水平的负荷模型逐层聚合,既保留了主要的暂态特征,又降低了模拟规模和计算复杂度。文献[109]提出了一种基于实测响应空间的负荷动特性分类方法,计算各个负荷动特性样本的实测响应相关系数作为特征向量,采用系统聚类法按相关系数值进行特性分类。文献[110]基于提升小波包变换对负荷实测电流响应数据进行特征提取,基于能量矩构建特征向量,采用 FCM 算法进行分类。

负荷季节特性分类是负荷动特性分类的一种,通过对同一负荷在一年内的日负荷曲线进行分析,研究不同季节的负荷变化规律。目前,负荷季节特性分类方面相关的研究文献有限。文献[111]对智能电网环境下的负荷特性分类进行了综述,分析并总结了常用的聚类方法和评价方法,提出了负荷特性分类的“五步模型”,但该文献仅考虑了不同用户用电模式的差异,未考虑同一用户在不同时间阶段的差异及不同用户不同时间阶段可能存在用电模式相似性的问题。文献[112]对 58 个英国家庭样本的半小时电力需求数据的分析,表明季节变化对英国家庭电力需求的多个方面都有显著影响,但文献未对负荷季节变化的规律进行研究。文献[113]考虑不同季节特性对充电负荷的影响,建立电动汽车短期负荷预测模型,但文献以典型温度反映季节变化影响,未进行不同季节充电负荷规律研究。文献[114]将温度、云量和风速作为气象变量研究短期负荷预测的季节性效应,提出季节特异相似性概念并将其集成到短期负荷预测过程中,将季节性效应纳入短期负荷预测。文献[115,116]通过对电力负荷曲线分类进行用户用电模式研究,并讨论了入住率和温度作为季节影响因素对用电模式的影响,未进行深入分析用电模式的季节性变化规律。文献[117]收集了欧洲八个国家的负荷数据,对比分析了 FCM 算法、谱聚类算法等几种常见的聚类方法,提出采用“Morning Slope”作为特征将每年的日负荷曲线分为工作日、假日、节前三类,未考虑不同季节下工作日、假日、节前负荷特性差异。文献[118,119]研究分析了气温和电网负荷特性内在关联特征,无法反映其它气象因素对季节变化规律的影响。以上文献关于负荷特性的季节变化研究主要集中在负荷特性、用电模式与温度等单个气象变量之间的关系上,但未涉及电力负荷季节时变特性的周期性规律。

在过去的十年中,深度学习技术得到了迅速的发展。与传统的机器学习相

比,深度学习技术可以从数据中自动学习模式,而不是手动设计。随着计算能力的提高,深度学习算法在自然语言处理、物体检测、语音识别等领域的应用取得了突出的成果^[120-122]。此外,深度学习已广泛应用于电力系统研究领域,如配电网重构^[123]、频率分析与控制^[124]、短期电压稳定性评估^[125]、异常检测^[126, 127]、负荷预测^[128]、智能电网调度^[129]等。在负荷建模方面,文献[32]基于西部电力协调委员会综合负荷模型,提出了一种基于双深度 Q 学习网络(Double Deep Q-learning Network, DDQN)的两阶段负荷建模框架;文献[40]提出了一种基于多模式长短期记忆(Multi-Modal Long Short-Term Memory, M-LSTM)深度学习的时变参数识别方法,用于 ZIP+IM 的综合负荷建模。基于一维数据的深度学习模型结构主要使用一维卷积核,泛化能力和适用性有待进一步提高。关于二维时变负荷特征提取和季节特征分类的相关研究文献较少。

1.3 存在的主要问题

针对准确负荷建模问题,学者们已开展了广泛深入的研究并取得了大量成果,IMM 负荷建模是当前研究的重点方向之一。针对 IMM 负荷建模方法及相关负荷时变性和耦合性问题,本文对 IMM 负荷建模方法进行改进并采用深度学习、图表示学习等人工智能方法进行负荷特性分析和负荷建模研究,提升对负荷时变特性的认知,获取负荷本身的动态特性。本论文拟解决的主要问题如下:

(1) 现有负荷建模方法多采用固定模型结构,通过条件概率密度函数、牛顿-拉夫逊迭代法等对时变参数进行辨识,没有考虑负荷成分或模型结构可能发生的变化。若在模型结构中考虑可能存在的各种负荷成分,构建的负荷模型待辨识参数数量增加较多,影响计算效率提升。IMM 负荷建模方法具有跟踪精度高、计算量小的优点,有效解决了负荷成分多样性问题。然而,由于采用了固定 TPM,存在切换过程模型的概率滞后等问题。因此,需要研究 TPM 动态调整的方法,提高 IMM 负荷建模方法效能。

(2) 电力系统中负荷相互影响,所有负荷节点都与其它负荷节点存在耦合关系。在一个负荷上进行的测量并不反映负荷自身特性,而是反映其在电网环境中的特性。当 IMM 建模方法应用于电力系统时,若仅通过考虑负荷所连接的相应母线上的扰动量测数据进行建模,获取的负荷模型无法刻画负荷自身特性。因此,需要研究负荷测量数据解耦方法,获取负荷本身特性。

(3) 目前电力系统中可用于负荷建模的扰动数据相对较少,难以满足时变负荷建模需要。现有的时变负荷特性的分析方法主要是负荷特性分类,通过建立不同负荷节点或同一负荷节点不同时间段的典型模型进行模型推广应用。负荷特

性分类主要采用基于一维数据的分析,以负荷组成成分调查数据、动态响应、日负荷曲线等作为特征向量进行研究,或研究个别季节气象因素对负荷需求的影响,未对负荷季节性变化的周期性规律进行研究。为在负荷模型中反映负荷随时间变化的周期性规律,需要研究负荷的季节特性、周特性、日特性等分类。

1.4 本文主要研究工作

电力系统负荷组成日趋复杂,时变性和耦合性已成为影响准确负荷建模的难题。本文在已有 IMM 负荷建模研究基础上,应用深度学习和图表示学习等理论对相关问题进行研究,提出了基于改进交互式多模型(Improved Interacting Multiple Model, IIMM)算法的负荷建模方法、负荷数据解耦方法、季节特性特征提取及分类方法,解决电力负荷复杂性、时变性导致准确负荷建模困难的问题。本文各部分研究内容的关系如图 1-1 所示,主要研究内容和创新性成果如下:

(1) 基于 IIMM 算法的负荷建模方法。将具有自适应 TPM 的 IIMM 算法应用于负荷特性时变问题研究,建立了新的负荷建模框架。输入交互用于优化负荷模型之间的信息交换,通过极化校正函数和激活校正函数自适应自动计算模型转移概率,实现模型之间的软切换。从负荷模型集中遴选出最优模型参与输入交互,不同模型通过马尔可夫链实现转移,利用扩展卡尔曼滤波器并行滤波,依据估计误差更新各模型权重,依概率进行各模型的输出融合,得到接近实际负荷特性的综合负荷模型。

(2) 基于 GCN 的电力负荷数据解耦方法。将电力系统进行图表示,采用 GCN 对各负荷节点数据进行处理,研究电力系统扰动过程中各节点响应耦合情况。在对各负荷节点特征信息与系统结构信息进行学习的基础上,对负荷节点的观测数据进行解耦操作,从而得到负荷节点响应,采用反映各节点实际负荷特性的数据进行负荷建模。

(3) 基于主成分分析网络(Principal Component Analysis Network, PCANet)和卷积双向长短记忆神经网络(Convolutional Neural Network and Bi-directional Long-Short Term Memory, CNN+Bi-LSTM)算法的电力负荷时变特性特征提取及分类方法。以季节性为例研究负荷的时变性规律,借鉴深度学习理论和方法在图像处理中的运用,通过对日负荷曲线的数据挖掘,提取出能够反映季节性电力负荷特性的特征,基于特征提取的分类实现对同一负荷节点的季节划分。利用格拉姆角场(Gramian Angular Field, GAF)将时间序列编码的日负荷曲线转换为极坐标系中的二维图像;在对图像进行二层卷积 PCA 滤波处理中,采用 PCANet 方法获取负荷深度特征;针对负荷深度特征的分类,采用 CNN 和 Bi-LSTM 算法相

结合的算法构建分类器，获得各季节的典型负荷特性曲线。




图 1-1 本文各部分研究内容关系

Fig. 1-1 Relationship of the research contents

2 改进交互式多模型负荷建模

2.1 引言

负荷建模对电力系统的分析、规划、运行和控制具有重要影响。近年来,随着新型电力系统的新形态出现,用电负荷结构发生了重大变化,非线性电力电子负荷、分布式电源在受电端大规模投入使用。由于负荷成分多样性、时变性,现有的电力负荷模型很难适应新型电力系统分析、规划、运行与控制的需要。电力负荷的复杂性、随机性、时变性给负荷建模带来了诸多困难。MM 理论源自控制理论中的 MM 控制,其 MM 算法主要应用于目标跟踪领域。MM 算法可以较好地估计具有时变结构和参数的系统的状态,这为负荷建模提供了新的路径。文献[37]基于多模型理论提出了一种采用静态多模型算法的负荷建模方法,其输出结果是每个经典负荷模型状态估计结果的加权综合,忽略了各子负荷模型的交互作用。IMM 算法是一种跟踪精度高、计算量小的动态多模型机动目标跟踪算法,这为非线性结构负荷精确建模,解决电力负荷复杂性、随机性、时变性的综合建模问题,提供了新的思路。

IMM 算法是并行多个模型来代表可能的目标运动模式,各个模型之间采用齐次马尔可夫过程的转换,根据每个模型相应的滤波器状态估计误差调整各模型的模型概率,实现各个模型权重值随其与实际系统匹配度动态调整,利用贝叶斯推理对交互后的状态估计结果进行加权融合,准确跟踪机动目标的变化情况^[40]。IMM 根据不同模型的状态演化模型提供尽可能好的估计,并且预测最接近真实测量的模型被赋予更多的权重。IMM 可以有不同类型的滤波器,如卡尔曼滤波器或扩展卡尔曼滤波器,以考虑基于不同测量传感器组的系统和模型的非线性。IMM 算法在很大程度上依赖于模型交互,TPM 具有马尔可夫转移特性,它混合了模型概率,影响估计精度。因此,TPM 设计是决定 IMM 性能的关键因素。传统的 IMM 估计器具有恒定的 TPM。如果不能准确地指定模型的运动概率,则可能导致子模型不能跳跃或模型平衡崩溃。因此,自适应或状态相关的 TPM 可以提高其估计精度。

IIMM 算法为解决上述问题提供了重要的理论工具。IIMM 算法是一种具有自适应模型集的 IMM 算法,通过校正函数动态调整马尔可夫 TPM,可以应用于线性和非线性模型,并能自适应自动计算转移概率。本章提出了 IIMM 负荷建模方法,从负荷模型集中遴选出最优模型参与输入交互,不同的负荷模型通过校正函数动态调整马尔可夫 TPM 进行切换,并通过扩展卡尔曼滤波器进行并行滤波。

在状态估计之后，根据所评估的误差来更新模型概率。基于概率对负荷模型进行融合和输出，从而生成综合负荷模型。仿真结果表明，IIMM 负荷建模方法的交互和输出融合具有较高的精度，能够有效地解决负荷特性的时变问题。

2.2 改进交互式多模型基本理论

2.2.1 IMM 算法

IMM 算法是将系统的可能状态映射到模型集，用模型集来描述系统的运动模式，通过并行运行多个卡尔曼滤波器来简化模型选择过程。各模型之间的转换通过马尔可夫过程来实现，加权综合输出状态估计；当系统状态发生改变时，可以自适应地调整各个模型的权重。IMM 通常设计用于状态估计的滤波器需要具有准确定义的系统模型，该模型有效地表示所有系统动力学、参数和输入。IMM 算法结构原理如图 2-1 所示。




图 2-1 IMM 算法结构原理

Fig. 2-1 Structure of IMM algorithm

考虑式 (2-1) 所示的离散时间跳变马尔可夫线性模型系统。在检测过程中以目标位置和速度作为状态变量 $X(t)=[x, \dot{x}, y, \dot{y}]^T$ ，目标机动方程可表示为

$$X(t)=\Phi(t|t-1)X(t-1)+\Gamma v(t-1) \quad (2-1)$$

式中 $X(t) \in R$ 为时刻 t 的系统状态向量； Φ 表示系统从 $t-1$ 到 t 的状态转移矩阵，用马尔可夫链来描述；过程噪声 $v(t-1)$ 为服从协方差矩阵 $Q(t-1)$ 的零均值高斯白

过程； Γ 为输入矩阵。基于马尔可夫链的 IMM 滤波方法根据目标运动模态自动调整匹配模型。IMM 滤波可以在相当短的时间内拟合多个基本模型估计和检测目标状态。IMM 从已知的几种滤波模型中选择最适合的系统模型进行目标跟踪。

将模型状态 $n(t)$ 的时间行为建模为具有 TPM 的时不变马尔可夫链，TPM 如式 (2-2) 所示。

$$\Pi(i, j) = \pi_{ij} \triangleq P(n(t) = j | n(t-1) = i) = \begin{bmatrix} p_{11} & p_{12} & \cdots & p_{1N} \\ p_{21} & p_{22} & \cdots & p_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ p_{N1} & p_{N2} & \cdots & p_{NN} \end{bmatrix} \quad (2-2)$$

$$\sum_{j=1}^N p_{ij} = 1, 0 \leq p_{ij} \leq 1$$

其中 π_{ij} 为 TPM， $n(t) \in \{1, 2, \dots, N\}$ 为时刻 t 的系统模型， N 为模型个数。该算法在多模型滤波的基础上增加了交互和反馈，建模精度高于单模型滤波算法。

传统的 IMM 估计器具有恒定的 TPM。通过设置对角元素的大常数值，能够很容易地设计出不变的 TPM，并获得一个好的估计状态。如果不能准确地更新模型概率，则可能导致子模型不能跳跃或出错。自适应或状态相关的 TPM 可以提高其估计精度。

IMM 算法通过对多个子模型间的概率加权计算综合估计状态，由于综合估计状态中包含了其它子模型的估计状态，因此低概率可视为噪声，且最高概率值不可能为 1。如果能使模型概率随时间趋于极化和平滑，就能提高估计精度。当系统模型根据目标运动切换子模型时，恒定 TPM 具有较低的变化率和过渡时间延迟。如果能够提高 TPM 变化率和减少过渡时间延迟，估计的误差就会变小。IIMM 算法为了提高估计精度，采用包含极化和激活的两个过渡校正函数，并利用两个函数的融合方法来解决使 TPM 随时间变化这一难题^[51]。

2.2.2 极化校正函数

如果系统子模型不能跳跃，则理想情况是只存在概率最高的模型的估计状态。在现实中，系统模型的估计状态是由各模型的似然加权求和。因此，低概率下的状态估计在综合估计中可能是噪声。使用有关预测概率的历史波动信息可以最小化噪声。

$$\begin{aligned} f(t) &= \beta f(t-1) + (1-\beta)\Lambda(t), \\ f(t-1) &= \beta f(t-2) + (1-\beta)\Lambda(t-1), \\ f(t-2) &= \beta f(t-3) + (1-\beta)\Lambda(t-2), \\ &\vdots \end{aligned} \quad (2-3)$$

其中 $f(t)$ 是估计的模型概率； $\Lambda(t)$ 是时刻 t 的可能性； β 表示作为子模型的似然函数计算的概率，其值随时间变化。它最终可以将 $f(t)$ 写成可能性的加权和，如式 (2-4) 所示。

$$f(t) = (1-\beta)\Lambda(t) + (1-\beta)\beta\Lambda(t-1) + (1-\beta)\beta^2\Lambda(t-2) + \dots \quad (2-4)$$

当乘以 β 时，旧数据呈指数减少；如果 $\beta=0$ ，则不反映过去的的数据。因此，如果对 β 进行不同的赋值以反映过去时间的模型概率，则有望获得平滑效应和极化效应。 $f(t)$ 可近似表示为

$$f(t) = \frac{1}{1-\beta}, \beta \in [-1, 1] \quad (2-5)$$

式中，当 β 接近 1 时，受过去模型概率的影响很大，存在平滑效应；当 β 大于等于 0 时，受当前模型概率的影响较大，存在极化效应；当 β 为负时，它抑制了与过去模型概率相反的当前值。因此，极化效应是可以实现的。

假设系统模型与目标状态的第 i 个模型相匹配，而与第 j 个模型不匹配。匹配的模型概率高，不匹配的模型概率低。将 β 定义为 $\mu(t) - \mu(t-1)$ ，则极化校正函数定义式 (2-6) 所示。

$$f(t) = \frac{1}{1 - \{\mu(t) - \mu(t-1)\}} \quad (2-6)$$

通过式 (2-6) 更新 TPM，可以获得抗噪声性能。当子模型匹配时，因为子模型 i 在非跳跃期随时间的概率最高， β 为正；当子模型不匹配时， β 为负。 $f(t)$ 的值确定如下：

$$\begin{cases} f_i(t) \geq 1, \mu_i(t) \geq \mu_i(t-1) \\ f_j(t) \leq 1, \mu_j(t) < \mu_j(t-1) \end{cases} \quad (2-7)$$

TPM 更新为：

$$\bar{\pi}_{ij}(t) = f(t) * \pi_{ij}(t-1) \quad (2-8)$$

$f(t)$ 增大了匹配模型的 TPM 元素，减小了非匹配模型的 TPM 元素。

2.2.3 激活校正函数

随着目标机动的改变，待估计的系统模型需要改变子模型，TPM 需要重置。在这种情况下，模型概率的历史信息是触发模型变化的障碍。在过渡时期，变化越慢，误差越大。为了最小化响应延迟时间，需要通过应用另一个校正函数进行优化。与极化校正函数不同，它必须对模型概率的变化敏感。

若子模型跳跃的概率为 g ，则比值比（OR 值）如式（2-9）所示。

$$odds(J) = \frac{g}{1-g} \quad (2-9)$$

采用 Logistic 回归方法，利用自变量线性组合的概率模型预测子模型跳跃的概率。两边取对数，做一个对数变换。当采用线性回归时，它可以表示为自变量，如式（2-10）所示。

$$\ln \frac{g}{1-g} = ax + b \quad (2-10)$$

则概率 g 可推导如式（2-11）至式（2-14）。

$$\frac{g}{1-g} = e^{ax+b} \quad (2-11)$$

$$g = (1-g)e^{ax+b} \quad (2-12)$$

$$g(1 + e^{ax+b}) = e^{ax+b} \quad (2-13)$$

$$g = \frac{e^{ax+b}}{1 + e^{ax+b}} = \frac{1}{1 + e^{-(ax+b)}} \quad (2-14)$$

式(2-14)是人工智能中用作激活函数的 *sigmoid* 函数。单调 *sigmoid* 函数在 $x \rightarrow \pm\infty$ 处渐近收敛。如果只定义自变量，则可以得到子模型跳跃概率，并利用该概率更新 TPM。

假设模型 $\mu_i(t-1)$ 的概率在时刻 $t-1$ 最大，模型 $\mu_j(t)$ 的概率在时刻 t 最大。即匹配模型从第 i 个模型转移到第 j 个模型。通过时间 $t-1$ 和 t 时 i 和 j 之间的模型概率交叉差来检查模型之间的切换，如式（2-15）所示。

$$\Delta_j = \mu_j(t) - \sum_{i=1, i \neq j}^N \mu_i(t-1) \quad (2-15)$$

将激活校正函数设计为如式（2-16）所示。

$$g(t) = \frac{1}{1 + e^{-\Delta}} \quad (2-16)$$

假设过去匹配的模型 i 在时间 t 匹配，过去未匹配的模型 j 在时间 t 不匹配；

在子模型中不能跳跃。由于 $\mu_i(t)$ 的值很高, $\mu_j(t-1)$ 的值很低, 所以两个模型概率的交叉差将接近于 1。此时, 激活校正函数的值成为最大值, 在匹配模型中持续反映一个较大的权重。相反, $\mu_j(t)$ 的值低而 $\mu_i(t-1)$ 的值高, 两个模型概率之间的交叉差可以接近于 -1。激活校正函数的值成为最小的值, 一个小的权重不断地反映在不匹配的模型中。然而, 在子模型跳跃中, 两个模型概率或高或小, 两个模型概率之间的交叉差为零值。

通过该函数, 将 TPM 修正如式 (2-17) 所示。

$$\tilde{\pi}_{ij}(t) = g(t) * \pi_{ij}(t-1) \quad (2-17)$$

激活校正函数在子模型跳跃期降低了一个高的模型概率值, 提高了一个低的模型概率值, 可以获得 TPM 整体重新平衡的效果。激活校正函数包括模型之间的历史信息, 并在子模型跳跃时充分计算当前模型信息。

2.2.4 TPM 更新策略

综合激活校正函数与极化校正函数, 更新的 TPM, 如式 (2-18) 所示。

$$\hat{\pi}_{ij}(t) = \bar{\pi}_{ij}(t) - \tilde{\pi}_{ij}(t) = (f(t) - g(t)) * \pi_{ij}(t-1) \quad (2-18)$$

使用两个 TPM 相减的原因是极化校正函数具有鲁棒性, 它们的值大多接近于 1; 激活校正函数的最大值约为 0.7。因此, 集成 TPM 值总是大于零。

$$-1 \leq \beta \leq 1 \rightarrow \frac{1}{2} \leq f \leq \infty$$

从模型概率交叉差来看, Δ 小于等于 1。

$$-N+1 \leq \Delta \leq 1$$

其中 N 是一个大于 1 的整数。

g 的值可以在 0 到 $\frac{1}{1+e^{-1}}$ 之间:

$$0 < g < \frac{1}{1+e^{-1}} \approx 0.731 \dots$$

为了确认 $f - g > 0$, 需要确认 μ 是否最高值。

情形 1: 如 $\mu_i(t)$ 大于其它模型概率

$$0 \leq \beta \rightarrow 1 \leq f$$

因为不管 Δ 的值是多少, g 总是小于 1, 所以 $f - g$ 大于零。

情形 2: 如 $\mu_i(t)$ 小于其它模型概率

$$\begin{cases} \beta < 0 \rightarrow 1/2 \leq f < 1 \\ \Delta < 0 \rightarrow 0 \leq g < 1/2 \end{cases}$$

可得 $f-g$ 大于零。

最后，归一化以保持马尔可夫过程的特征，如式 (2-19) 所示。

$$\pi_{ij}(t) = \frac{\hat{\pi}_{ij}(t)}{\sum_{j=1}^N \hat{\pi}_{ij}(t)} \quad (2-19)$$

2.3 改进交互式多模型负荷建模方法

基于 IMM 算法理论和 IMM 负荷建模相关研究成果，本章提出了 IIMM 负荷建模方法，通过引入极化校正函数和激活校正函数对 TPM 进行动态更新，提高负荷建模的准确性。

假设整个负荷模型集包含 r 个模型，记为 $m_1, m_2 \dots m_r$ ，每个模型被赋以一定的权重。每次迭代时，经过模型遴选，选取 n 个模型作为最优模型集，记为 $M_1, M_2 \dots M_n$ 。在对模型概率、TPM 进行初始化的基础上，根据当前时刻的最优模型集及模型概率 $\mu_1(t-1), \mu_2(t-1), \dots, \mu_n(t-1)$ 对 TPM 进行更新，并通过交互获取下一时刻状态估计 $\hat{M}_1, \hat{M}_2 \dots \hat{M}_n$ 和模型概率 $\mu_1(t), \mu_2(t), \dots, \mu_n(t)$ 。

IIMM 负荷建模方法的过程可以分为四个模块：负荷模型选择、TPM 更新、最优负荷模型输入交互和最优负荷模型输出融合。IIMM 负荷建模方法示意图如图 2-2 所示。

负荷模型选择是指在输入交互之前根据每个模型并行滤波产生的误差计算归一化新息平方和。根据新息向量计算每个模型的归一化新息平方和，以描述模型与实际系统之间的误差。为了节省模型调整时间，提高负荷建模精度，选取综合负荷模型集中归一化新息平方和最小的模型构成最优负荷模型集。详细的负荷模型选择过程参考文献[39]。

TPM 更新是指利用上一时刻最优负荷模型集中各模型的模型概率通过激活校正函数和极化校正函数对 TPM 进行更新，提高模型跟踪效果。

最优负荷模型输入交互是指对最优负荷模型集中的模型通过模型概率、TPM 对状态估计和状态协方差进行交互，生成基于上一次迭代期间所有滤波器估计值的加权和。

最优负荷模型输出融合是指根据更新后的最优负荷模型概率对状态估计的

结果进行融合；其中，每个时刻的状态估计是通过状态估计器根据每个模型的交互信息生成。根据模型概率对状态估计融合生成综合状态估计。




图 2-2 IIMM 负荷建模方法示意图

Fig. 2-2 The IIMM based load modeling method

2.3.1 负荷模型集构成

结合当前电网负荷分析，为了全面反映负荷组成情况，参与交互的负荷模型集应覆盖存在的各种负荷形式。本文选用配电网综合负荷模型对负荷特性进行描述。

(1) 静态负荷模型

$$\begin{cases} P = P_0[P_z(U/U_0)^2 + P_l(U/U_0) + P_p] \\ Q = Q_0[Q_z(U/U_0)^2 + Q_l(U/U_0) + Q_p] \end{cases} \quad (2-20)$$

其中， P_0 、 Q_0 、 P_z 、 P_l 、 P_p 、 Q_z 、 Q_l 、 Q_p 分别代表有功功率和无功功率的初始值及恒阻抗、恒电流和恒功率负荷系数，且

$$\begin{cases} P_z + P_l + P_p = 1 \\ Q_z + Q_l + Q_p = 1 \end{cases} \quad (2-21)$$

(2) 异步电动机模型

$$\begin{cases} T'_{d0} \bullet dE'_d / dt = -E'_d - (X - X')I_q + s\omega_b E'_q T'_{d0} \\ T'_{d0} \bullet dE'_q / dt = -E'_q - (X - X')I_d + s\omega_b E'_d T'_{d0} \\ T_J \bullet ds / dt = T_M - T_E \end{cases} \quad (2-22)$$

其中

$$\begin{cases} T'_{d0} = (X_r + X_m) / \omega_b R_r \\ T_M = K_L [\alpha + (1 - \alpha)(1 - s)^{MP}] \\ T_E = E'_d I_d + E'_q I_q \\ X = X_r + X_m, \quad X' = X_s + X_m // X_r \end{cases} \quad (2-23)$$

其中, E'_d 、 E'_q 、 s 分别表示 d 轴、 q 轴暂态电势以及转差率; I_d 、 I_q 分别为定子电流的 d 轴、 q 轴分量; T_J 、 T'_{d0} 分别为转子惯性时间常数和定子开路暂态时间常数; ω_b 为电角频率基值; T_M 、 T_E 分别为机械力矩和电磁力矩; R_r 为转子电阻; X_r 为转子电抗; X_s 为定子电抗; X_m 为励磁电抗; K_L 为电动机的负荷率; α 为静止阻力矩; MP 为机械负载转矩与转速有相关的指数。

$$\begin{cases} I_d = \frac{1}{R_s^2 + X'^2} [R_s(U_d + E'_d) + X'(U_q - E'_q)] \\ I_q = \frac{1}{R_s^2 + X'^2} [R_s(U_q - E'_q) - X'(U_d + E'_d)] \end{cases} \quad (2-24)$$

输出方程为

$$\begin{cases} P = \frac{R_s}{R_s^2 + X'^2} U(U - E'_d) - \frac{X'}{R_s^2 + X'^2} U E'_q \\ Q = \frac{X'}{R_s^2 + X'^2} U(U - E'_d) - \frac{R_s}{R_s^2 + X'^2} U E'_q \end{cases} \quad (2-25)$$

2.3.2 最优负荷模型输入交互

负荷模型的输入交互是最优负荷模型中信息交换的过程。负荷模型的混合状态变量和协方差都是从最优负荷模型集中生成的。负荷模型的输入交互过程主要是计算负荷模型的混合概率、混合状态估计和协方差。最优负荷模型集的输入交互如图 2-3 所示。

将负荷及其所在节点视为一个跳跃马尔可夫线性系统:

$$\begin{cases} x_{k+1} = F(r_{k+1})x_k + B(r_{k+1})w_k \\ y_k = H(r_k)x_k + v_k \end{cases} \quad (2-26)$$

其中 x_k 是状态变量; r_k 是一个离散变量, 取值于确定目标模型的集合 $\{1, 2, \dots, n\}$ 中

的值, r_k 被建模为具有 TPM 的马尔可夫链 $\pi = p_{ij}$, $1 \leq i, j \leq n$, 其中 n 是模型的数量; y_k 是量测向量; $F(r_k)$ 、 $H(r_k)$ 、 $B(r_k)$ 分别为状态、量测和输入矩阵; w_k 、 v_k 分别为过程噪声和测量噪声, 二者都服从零均值高斯过程。




图 2-3 最优负荷模型集输入交互示意图

Fig. 2-3 Diagram of input interaction of the optimal load model set

定义状态估计 $x_{k|k}^i$ 、模型条件协方差 $COV_i(k|k)$ 和模型概率 $\mu_{k|k}^i$ 。这些变量定义为:

$$x_{k|k}^i = E[x_k | r_k = i, z_{0:k}] \quad (2-27)$$

$$COV_i(k|k) = E[(x_k - \hat{x}_k)(x_k - \hat{x}_k)^T | r_k = i, z_{0:k}] \quad (2-28)$$

$$\mu_{k|k}^i = P[r_k = i, z_{0:k}] \quad (2-29)$$

根据文献[94], 感应电动机的状态变量为 E_d' 、 E_q' 、 s 。量测量是指系统扰动过程中采集到的反映负荷特性的有功功率 P 和无功功率 Q 实测值。为了得到负荷模型的混合状态方程和协方差方程, 需要通过混合概率对状态估计和状态协方差的交互。 $\mu_{ij}(k-1|k-1)$ 表示最优负荷模型从模型 i 切换到模型 j 时马尔可夫链的

混合概率，如式 (2-30) 所示。

$$\mu_{ij}(k-1|k-1) = p_{ij}(k-1)\mu_i(k-1)/\bar{c}_j \quad (2-30)$$

其中 $p_{ij}(k-1)$ 是负荷模型 i 和负荷模型 j 之间的转移概率，可根据式 (2-19)

计算得到； $\bar{c}_j$ 是负荷模型 j 的归一化常数，表示为：

$$\bar{c}_j = \sum_{i=1}^r p_{ij}(k-1)\mu_i(k-1) \quad (2-31)$$

其中 r 是最优负荷模型集中子模型的数量。

模型权重 $\mu_i(k-1)$ 在权重更新过程中取决于似然函数，因此，混合概率由马尔可夫转移系数和似然函数确定。混合是通过使用混合概率来启动每个 IMM 模型的状态向量和协方差矩阵，然后将状态向量和不确定性矩阵的估计转发到各个滤波器。根据混合概率 $\mu_{ij}(k-1|k-1)$ ，可以计算混合状态估计及其对应的协方差，如式 (2-32) 和式 (2-33) 所示。

$$\hat{x}_j^0(k-1|k-1) = \sum_{i=1}^r \hat{x}_i(k-1|k-1)\mu_{ij}(k-1|k-1) \quad (2-32)$$

$$\begin{aligned} COV_j^0(k-1|k-1) = & \sum_{i=1}^r \mu_{ij}(k-1|k-1) \{ COV_i(k-1|k-1) + \\ & [\hat{x}_i(k-1|k-1) - \hat{x}_j^0(k-1|k-1)] \cdot \\ & [\hat{x}_i(k-1|k-1) - \hat{x}_j^0(k-1|k-1)]^T \} \end{aligned} \quad (2-33)$$

其中 $\hat{x}_i(k-1|k-1)$ 和 $COV_i(k-1|k-1)$ 分别表示负荷模型 i 在时间 $k-1$ 的状态估计和状态协方差； $\hat{x}_j^0(k-1|k-1)$ 和 $COV_j^0(k-1|k-1)$ 分别表示负荷模型 j 交互后的混合状态估计和协方差。

2.3.3 状态估计

由于在电力系统扰动数据采集中存在一定的噪声，因此在进行目标跟踪时，系统模型输出结果与实测数据间存在一定误差。为了更接近实际情况，需要通过状态估计器对系统的状态向量进行修正。

当滤波器用来自先前周期的新估计进行初始化时，使用它们基于自己的状态方程和运动模型提供新的估计。所有滤波器都独立于其结构和模型。这样的不同模型并行工作，以根据它们的状态演化模型提供尽可能好的估计，并且预测最接近真实测量的模型被赋予更多的权重。在计算了它们的新估计之后，这些值被用于进行最终状态估计。

扩展卡尔曼滤波由于其固有的优点在状态估计、参数估计和对偶估计领域获得了广泛应用。扩展卡尔曼滤波具有闭环、在线和误差范围可用性的优点，即可以实现在线估计并计算估计误差。鉴于感应电动机状态变量的非线性特征，IIMM 负荷建模方法采用扩展卡尔曼滤波进行负荷模型的状态估计，得到状态变量、状态协方差、新息向量及其协方差。对于最优负荷模型集中模型 M_j 的估计过程如下：

(1) 感应电动机模型离散化如下：

$$\begin{cases} E'_d(k|k-1) = E'_d(k-1) + Ts\{-E'_d(k-1) \bullet (1 + X_2) + \\ E'_q(k-1) \bullet [s(k-1)\omega_B T'_{d0} + X_1] + U_d(k-1)X_2 - U_q(k-1)X_1\} / T'_{d0} \\ E'_q(k|k-1) = E'_q(k-1) + Ts\{-E'_q(k-1) \bullet (1 + X_2) - \\ E'_d(k-1) \bullet [s(k-1)\omega_B T'_{d0} + X_1] + U_d(k-1)X_1 + U_q(k-1)X_2\} / T'_{d0} \\ s(k|k-1) = s(k-1) + Ts \bullet (T_M - T_E) / T_J \end{cases} \quad (2-34)$$

其中， $X_1 = R_s(X - X') / (R_s^2 + X'^2)$ ； $X_2 = X'(X - X') / (R_s^2 + X'^2)$ ；其它参数的含义见文献 [130]。

(2) 量测方程式离散化如下：

$$\begin{cases} P_M(k|k-1) = \\ ST(U_d(k)I_d(k|k-1) + U_q(k)I_q(k|k-1)) \\ Q_M(k|k-1) = \\ ST(U_q(k)I_d(k|k-1) - U_d(k)I_q(k|k-1)) \end{cases} \quad (2-35)$$

其中， $I_d(k|k-1)$ 、 $I_q(k|k-1)$ 分别表示电流 d 轴分量、 q 轴分量的估计值； $U_d(k)$ 、 $U_q(k)$ 分别表示电压 d 轴分量、 q 轴分量； ST 表示电机容量转换系数，其取值为

$$ST = K_{PM} P_0 / [(1 - K_{WG}) (U_{d0} I_{d0} + U_{q0} I_{q0})] \quad (2-36)$$

其中， K_{PM} 是异步电机的比例； K_{WG} 是风力发电机与纯负荷的比率； U_{d0} 、 U_{q0} 分别表示 d 轴分量和 q 轴分量的稳态电压； I_{d0} 、 I_{q0} 分别表示 d 轴分量和 q 轴分量的稳态电流。

(3) 计算新息向量

$$\gamma_j(k) = \begin{bmatrix} P_L(k) \\ Q_L(k) \end{bmatrix} - \begin{bmatrix} P_{Sej}(k|k-1) \\ Q_{Sej}(k|k-1) \end{bmatrix} \quad (2-37)$$

其中, $P_L(k)$ 和 $Q_L(k)$ 是 k 时刻实测负荷有功和无功功率; $P_{Sej}(k)$ 和 $Q_{Sej}(k)$ 是 $k+1$ 时刻负荷模型 M_j 的有功功率、无功功率估计值。估计值为感应电动机的功率、静负荷功率和无功补偿功率的综合结果, 即

$$\begin{cases} P_{Sej}(k) = P_{Mj}(k) + P_{Sj}(k) \\ Q_{Sej}(k) = Q_{Mj}(k) + Q_{Sj}(k) - Q_{Cj}(k) \end{cases} \quad (2-38)$$

式中, $P_{Mj}(k)$ 和 $Q_{Mj}(k)$ 是 k 时刻负荷模型 M_j 的电动机功率; $P_{Sj}(k)$ 和 $Q_{Sj}(k)$ 是 k 时刻负荷模型 M_j 的静负荷有功功率, 如式 (2-39) 所示; $Q_{Cj}(k)$ 是无功补偿功率, 如式 (2-40) 所示。

$$\begin{cases} P_{Sj}(k) = P_{soj} \left[\frac{P_{sj}(U_L(k)/U_{L0})^2 + P_{pj}(U_L(k)/U_{L0}) + P_{pj}}{Q_{sj}(U_L(k)/U_{L0})^2 + Q_{pj}(U_L(k)/U_{L0}) + Q_{pj}} \right] \\ Q_{Sj}(k) = Q_{soj} \left[\frac{Q_{sj}(U_L(k)/U_{L0})^2 + Q_{pj}(U_L(k)/U_{L0}) + Q_{pj}}{Q_{sj}(U_L(k)/U_{L0})^2 + Q_{pj}(U_L(k)/U_{L0}) + Q_{pj}} \right] \end{cases} \quad (2-39)$$

$$Q_{Cj}(k) = U_L(k)^2 / X_{Cj} \quad (2-40)$$

(4) 计算新息协方差

$$S_j(k) = H_j(k) COV_j(k|k-1) H_j(k)^T + R \quad (2-41)$$

式中, R 为状态观测向量的协方差矩阵; $H_j(k)$ 为 k 时刻最优负荷模型 M_j 观测矩阵的雅可比矩阵, 可由式 (2-42) 计算。

$$H(k) = \frac{\partial h(k+1, x(k+1))}{\partial x(k+1)} = \begin{bmatrix} h_{11} & h_{12} & 0 \\ h_{21} & h_{22} & 0 \end{bmatrix} \quad (2-42)$$

其中

$$\begin{cases} h_{11} = ST(U_d(k) \frac{\partial I_d}{\partial E'_d} + U_q(k) \frac{\partial I_q}{\partial E'_d}) \\ h_{12} = ST(U_d(k) \frac{\partial I_d}{\partial E'_q} + U_q(k) \frac{\partial I_q}{\partial E'_q}) \\ h_{21} = ST(U_q(k) \frac{\partial I_d}{\partial E'_d} - U_d(k) \frac{\partial I_q}{\partial E'_d}) \\ h_{22} = ST(U_q(k) \frac{\partial I_d}{\partial E'_q} - U_d(k) \frac{\partial I_q}{\partial E'_q}) \end{cases}$$

$COV_j(k|k-1)$ 为最优负荷模型 M_j 在 k 时刻的新息协方差, 如式 (2-43) 所示。

$$COV_j(k|k-1) = F_j(k-1)COV_j(k-1)F_j(k-1)^T + N \quad (2-43)$$

式中, N 为状态噪声的协方差矩阵; $F_j(k-1)$ 为最优负荷模型在 $k-1$ 时刻的状态矩阵的雅可比矩阵, 可由式 (2-44) 计算。

$$F(k) = \frac{\partial f(k, \hat{x}(k|k))}{\partial x(k)} = \begin{bmatrix} f_{11} & f_{12} & f_{13} \\ f_{21} & f_{22} & f_{23} \\ f_{31} & f_{32} & f_{33} \end{bmatrix} \quad (2-44)$$

其中

$$\begin{cases} f_{11} = 1 - \frac{T_s}{T_{d0}}(1 + (X - X') \frac{\partial I_q}{\partial E'_d}) \\ f_{12} = T_s w_B s(k) - \frac{T_s}{T_{d0}}(X - X') \frac{\partial I_q}{\partial E'_q} \\ f_{13} = T_s w_B E'_q(k) \\ f_{21} = -T_s w_B s(k) + \frac{T_s}{T_{d0}}(X - X') \frac{\partial I_d}{\partial E'_d} \\ f_{22} = 1 - \frac{T_s}{T_{d0}}(1 - (X - X') \frac{\partial I_d}{\partial E'_q}) \\ f_{23} = -T_s w_B E'_d(k) \\ f_{31} = -\frac{T_s}{T_j}(I_d + E'_d \frac{\partial I_d}{\partial E'_d} + E'_q \frac{\partial I_q}{\partial E'_d}) \\ f_{32} = -\frac{T_s}{T_j}(I_q + E'_d \frac{\partial I_d}{\partial E'_q} + E'_q \frac{\partial I_q}{\partial E'_q}) \\ f_{33} = 1 + \frac{1.7 T_s K_L (s(k) - 1)}{T_j} \end{cases}$$

$$\frac{\partial I_d}{\partial E'_d} = \frac{-R_s}{R_s^2 + X'^2}, \quad \frac{\partial I_d}{\partial E'_q} = \frac{-X'}{R_s^2 + X'^2}$$

$$\frac{\partial I_q}{\partial E'_d} = \frac{X'}{R_s^2 + X'^2}, \quad \frac{\partial I_q}{\partial E'_q} = \frac{-R_s}{R_s^2 + X'^2}$$

(5) 计算滤波增益

$$W_j(k) = COV_j(k|k-1)H_j(k)^T S_j(k)^{-1} \quad (2-45)$$

(6) 更新每个负荷模型的状态向量

$$\begin{cases} E'_{dj}(k|k) = E'_{dj}(k|k-1) + W_j(k)\gamma_j(k) \\ E'_{qj}(k|k) = E'_{qj}(k|k-1) + W_j(k)\gamma_j(k) \\ s_j(k|k) = s_j(k|k-1) + W_j(k)\gamma_j(k) \end{cases} \quad (2-46)$$

(7) 更新每个模型的状态协方差

$$COV_j(k|k) = COV_j(k|k-1) - W_j(k)S_j(k)W_j(k)^T \quad (2-47)$$

将式 (2-41) 和式 (2-45) 代入式 (2-47), 可以得到最优负荷模型在 k 时

刻的状态协方差。在估计了新的状态估计值之后，各个滤波器计算基于残差的“模型概率”，即预测测量值和真实测量值之间的差。滤波器的残差越小，该滤波器与当前模型匹配概率越大。

2.3.4 负荷模型概率更新

负荷模型概率是指最优负荷模型集中的子模型权重，模型概率大小反映了子模型与实际负荷特性的匹配程度，所有子模型的模型概率之和为 1^[40]。

负荷模型权重更新为

$$\mu_j(k) = \Lambda_j(k) \bar{c}_j(k) / c, c = \sum_{j=1}^r \Lambda_j(k) \bar{c}_j \quad (2-48)$$

其中 $\bar{c}_j$ 是式 (2-48) 中的归一化常数； $\Lambda_j(k)$ 是模型 j 的似然函数，根据式 (2-49) 计算。

$$\Lambda_j(k) = \exp[-0.5 \gamma_j(k)^T S_j(k)^{-1} \gamma_j(k)] / \sqrt{|2\pi S_j(k)|} \quad (2-49)$$

当实际负荷的组成发生变化时，最优负荷模型集中的模型可以根据估计的模型概率和新息协方差根据式 (2-48) 和式 (2-49) 进行调整。在这个过程中，误差较大的负荷模型描述负荷特性能力较差，权重更新时会降低；误差较小的负荷模型更接近实际负荷特性，权重更新时相应的权重会增加。因此，负荷模型逐渐接近实际电力负荷特性。

2.3.5 最优负荷模型输出融合

信息融合是当前数据处理技术研究和发展的方向，主要包括像素级、特征级和决策级三个层次。在模式识别领域，通过多分类器组合实现分类决策融合已成功应用于人脸识别等分类任务。

在 IIMM 负荷建模方法中，输出融合是一种特征级信息融合，通过对状态估计结果进行融合获取综合输出。负荷模型集中各模型相互作用后将状态估计和协方差输入状态估计器，然后根据更新后的模型概率对来自多状态估计器的数据进行融合。这是一个使用基于当时模型概率的权重再次组合新的个体估计的过程。根据式 (2-50) 和式 (2-51) 获取最新的状态估计和协方差。

$$\hat{x}(k|k) = \sum_{j=1}^r \hat{x}_j(k|k) \mu_j(k) \quad (2-50)$$

$$COV(k|k) = \sum_{j=1}^r \mu_j(k) \{ COV_j(k|k) + [\hat{x}_j(k|k) - \hat{x}(k|k)] [x_j(k|k) - \hat{x}(k|k)]^T \} \quad (2-51)$$

最优负荷模型输出融合将最优负荷模型集中所有负荷模型的输出按照模型

概率进行融合并获取综合负荷模型，包括动态部分融合和静态部分融合两部分。

(1) 动态部分的融合

根据混合估计状态，在每个递归循环后整合状态变量 $\hat{E}_d(k|k)$ ， $\hat{E}_q(k|k)$ ， $\hat{s}(k|k)$ 和协方差 $COV_{Ed}(k|k)$ ， $COV_{Eq}(k|k)$ ， $COV_s(k|k)$ 以及更新的权重 $\mu_j(k)$ 。

$$\begin{cases} \hat{E}_d(k|k) = \sum_{j=1}^r \hat{E}_{dj}(k|k) \mu_j(k) \\ \hat{E}_q(k|k) = \sum_{j=1}^r \hat{E}_{qj}(k|k) \mu_j(k) \\ \hat{s}(k|k) = \sum_{j=1}^r \hat{s}_j(k|k) \mu_j(k) \end{cases} \quad (2-52)$$

$$\begin{cases} COV_{Ed}(k|k) = \sum_{j=1}^r \mu_j(k) \left\{ COV_{Edj}(k|k) + [\hat{E}_{dj}(k|k) - \hat{E}_d(k|k)] \bullet [\hat{E}_{dj}(k|k) - \hat{E}_d(k|k)]^T \right\} \\ COV_{Eq}(k|k) = \sum_{j=1}^r \mu_j(k) \left\{ COV_{Eqj}(k|k) + [\hat{E}_{qj}(k|k) - \hat{E}_q(k|k)] \bullet [\hat{E}_{qj}(k|k) - \hat{E}_q(k|k)]^T \right\} \\ COV_s(k|k) = \sum_{j=1}^r \mu_j(k) \left\{ COV_{sj}(k|k) + [\hat{s}_j(k|k) - \hat{s}(k|k)] \bullet [\hat{s}_j(k|k) - \hat{s}(k|k)]^T \right\} \end{cases} \quad (2-53)$$

其中， $\hat{E}_{dj}(k|k)$ 和 $\hat{E}_{qj}(k|k)$ 分别为最优负荷模型 M_j 的 d 轴和 q 轴的转子暂态电动势； $\hat{s}_j(k|k)$ 是最优负荷模型 M_j 的滑差； $\mu_j(k)$ 是最优负荷模型 M_j 的权重。

$COV_{Edj}(k|k)$ ， $COV_{Eqj}(k|k)$ 和 $COV_{sj}(k|k)$ 分别是最优负荷模型 M_j 的协方差。

通过上述公式，将最优负荷模型中的所有电动机输出融合为一个电动机，作为输出模型的动态部分。

(2) 静态部分的融合

在静态模型输出融合时，主要是通过计算静态负荷模型的权重进行融合。静态负荷模型的权重与动态负荷模型权重 μ_j 以及电动机比重 K_{pmj} 有关。负荷模型 M_j 中静态负荷模型权重计算如式 (2-54) 所示。

$$\mu_{j,ZIP} = \mu_j(1 - K_{pmj}) \quad (2-54)$$

各模型的有功功率恒阻抗参数、恒电流参数、恒功率参数综合如式 (2-55) 所示。

据此可以计算最优模型集中静负荷部分有功功率的综合占比 μ_{ZIP} ，如式

$$\mu_{ZIP,P} = \sum_{i=1}^I \mu_{i,ZIP} P_{Z_i} + \sum_{i=1}^I \mu_{i,ZIP} P_{li} + \sum_{i=1}^I \mu_{i,ZIP} P_{Pi} \quad (2-56)$$

同样方式对无功功率参数进行融合。

2.4 算例分析




图 2-4 仿真系统

Fig. 2-4 The simulation system

如图 2-4 所示,在单机无穷大系统中设置负荷参数和短路故障验证本文所提方法有效性。仿真系统考虑了风机和光伏接入情况,模拟系统发生三相短路故障时,负荷特性变化情况。为简化仿真计算,系统负荷设置为常用的 ZIP 模型和感应电动机模型,通过设置三相断路器通断时间对负荷成分进行调整,模拟负荷时变过程。光伏组件相关参数见文献[131]。

利用仿真工具软件 PSCAD 4.5 搭建仿真系统，设置负荷模型有 ZIP 模型和感应电动机模型组成，参数设置见表 2-1 和表 2-2。

表 2-1 电动机参数设置

Tab. 2-1 Motor parameter settings

	$R_s / p.u.$	$R_r / p.u.$	$X_m / p.u.$	$X_s / p.u.$	$X_r / p.u.$	T_J / s	P_M / MW
M_1	0.006	0.002	3.5	0.16	0.12	2	60
M_2	0.006	0.002	3.5	0.1	0.12	2	10
M_3	0.006	0.002	3.5	0.1	0.12	2	10
M_4	0.006	0.002	3.5	0.2	0.12	2	15
M_5	0.006	0.002	3.5	0.2	0.12	2	15

表 2-2 ZIP 参数设置

Tab. 2-2 ZIP parameter settings

	P_Z	P_I	P_P	Q_Z	Q_I	Q_P	P_0 / MW	$Q_0 / M var$
ZIP ₀	1	0	0	1	0	0	20	15
ZIP ₁	1	0	0	1	0	0	10	2
ZIP ₂	0	0	0	0	0	1	0	42
ZIP ₃	0	0	1	0	0	0	32	0
ZIP ₄	0	0	0	0	0	1	0	22

考虑实际系统中新能源接入情况，在系统母线上设置了风机和光伏电站，风力发电机的参数设置参考文献[132]。

仿真时间为 12s，分别在 3s 时刻和 8s 时刻在 B1 处设置三相短路故障。每次故障持续时间 0.05s，然后切除故障。初始投入负荷为 ZIP₁、ZIP₂、ZIP₄ 及全部的电动机负荷。此外，考虑负荷时变性验证需要，在 6s 时设置一次负荷变动，切除 ZIP₄、M₂、M₃、M₄、M₅，投入 ZIP₃，仿真验证同一扰动发生时不同负荷成分的动态响应情况。在 B2 上测量母线电压、有功功率、无功功率数据进行验证。相关扰动曲线如图 2-5 所示。




图 2-5 扰动曲线

Fig. 2-5 Disturbance curve

如图 2-5 所示, 可知系统初始化后, 约 1.5s 左右进入稳定运行状态。故障发生时, 负荷电压、功率响应发生明显变化。由于 3s 和 8s 时刻的负荷构成不同, 因此扰动时的负荷特性在幅值、恢复时间等方面存在明显差异。使用 MATLAB R2022b 对本文提出的基于 IIMM 负荷建模方法进行验证。负荷模型集 $\{m_1, m_2, \dots, m_9\}$ 的参数如表 2-3 所示^[40,101]。

表 2-3 负荷模型集参数

Tab. 2-3 Parameters of load model set

	m_1	m_2	m_3	m_4	m_5	m_6	m_7	m_8	m_9
P_z	0.25	0.35	0.2	0.25	0.35	0.2	0	0.5	0.5
P_l	0.65	0.45	0.7	0.55	0.4	0.4	1	0.25	0.25
P_p	0.1	0.2	0.1	0.2	0.25	0.25	0	0.25	0.25

续表 2-3 负荷模型集参数


Tab. 2-3 Parameters of load model set(continued)

	m_1	m_2	m_3	m_4	m_5	m_6	m_7	m_8	m_9
Q_z	0.25	0.35	0.2	0.25	0.35	0.2	0	0.5	0.5
Q_l	0.65	0.45	0.7	0.55	0.4	0.4	1	0.25	0.25
Q_p	0.1	0.2	0.1	0.2	0.25	0.4	0	0.25	0.25
α	0.15	0.15	0.15	0.15	0.15	0.15	0.15	0.15	0.15
MP	2	2	2	2	2	2	2	2	2
K_{PM}	0.83	-2.82	-3.18	0.60	3.04	0.70	0.80	3.35	0.60
T'_{d0}	1.339	0.986	1.263	0.011	0.100	0.585	1.350	0.602	0.825
T_j	2.85	2.20	2.50	2.30	2.86	1.5	3.0	2.0	2.0
X_m	3.67	3.29	3.45	3.40	2.11	3.00	3.70	3.49	3.00
R_r	0.009	0.011	0.009	1.010	0.070	0.017	0.009	0.020	0.012
X_r	0.117	0.116	0.120	0.118	0.100	0.124	0.117	0.120	0.120
R_s	0.016	0.030	0.02	0.022	0.082	0.03	0.013	0	0.013
X_s	0.117	0.116	0.120	0.118	0.100	0.124	0.117	0.295	0.11
s_0	0.009	-0.008	-0.007	0.007	-0.044	0.014	0.009	-0.012	0.011


初始协方差矩阵设定为单位矩阵，模型概率初始化为 $\mu=[0.3 \ 0.3 \ 0.4]$ ，马尔可夫转移概率矩阵设定为

$$\pi_{ij} = \begin{bmatrix} 0.96 & 0.02 & 0.02 \\ 0.02 & 0.96 & 0.02 \\ 0.02 & 0.02 & 0.96 \end{bmatrix}$$

截取 2s~10s 数据进行分析。在模型遴选中，最优负荷模型集为 $Mset=\{M1, M2, M3\}$ ，其中每个最优负荷模型均从 m_1-m_9 中选取。分别将最优模型集初始化为 $Mset0=\{m_1, m_2, m_3\}$ ， $Mset0=\{m_3, m_4, m_6\}$ ， $Mset0=\{m_9, m_5, m_8\}$ ，采用本文提出算法进行最优负荷模型集调整，结果见图 2-6、图 2-7 和图 2-8 所示。




(a) 最优模型集调整




(b) 最优负荷模型集权重

图 2-6 最优负荷模型集调整及权重 ($Mset0 = \{m_1, m_2, m_3\}$)

Fig. 2-6 Optimal load model set adjustment and weights ($Mset0 = \{m_1, m_2, m_3\}$)




(a) 最优模型集调整




(b) 最优负荷模型集权重

图 2-7 最优负荷模型集调整及权重 ($Mset0 = \{m_3, m_4, m_6\}$)

Fig. 2-7 Optimal load model set adjustment and weights ($Mset0 = \{m_3, m_4, m_6\}$)



(a) 最优模型集调整




(b) 最优负荷模型集权重


图 2-8 最优负荷模型集调整及权重 ($Mset0 = \{m_0, m_5, m_8\}$)

Fig. 2-8 Optimal load model set adjustment and weights ($Mset0 = \{m_0, m_5, m_8\}$)

最优负荷模型集的权重更新完成后,根据信息融合理论分别对静态部分和动态部分进行综合。下面以 $M_{set0}=\{m_1, m_2, m_3\}$ 为例,对融合结果进行分析。各模型状态变量及其融合结果如图 2-9 所示。



(a) E'_d 融合结果



(b) E'_q 融合结果



 (c) s 融合结果

图 2-9 状态变量融合结果

Fig. 2-9 Fusion results of the of state variables

对比分析图 2-6、图 2-7 和图 2-8，可以得到以下结论：

(1) 最优模型集初始化后，在没有扰动的情况下，最优模型集保持初始化值不变。

(2) 发生故障扰动或负荷调整时，最优模型集会自动调整，在扰动发生时刻及之后的一段时间，模型集调整需要一个过程，但最终稳定到一个最优模型集。

(3) 采用不同初始化的最优模型集，扰动后模型的调整变化情况完全相同，最终的最优模型集均为 $Mset0 = \{m_1, m_4, m_8\}$ ，说明本文提出的方法具有良好鲁棒性。

不同初始化的最优模型集，最终的 TPM 也是相同的，为

$$\pi_{ij} = \begin{bmatrix} 0.9641 & 0.0200 & 0.0200 \\ 0.0200 & 0.9577 & 0.0200 \\ 0.0200 & 0.0200 & 0.9577 \end{bmatrix}$$

最终的模型概率为 $\mu = [0.2895 \quad 0.4134 \quad 0.2971]$ 。

通过分析可知，在系统发生扰动时，最优负荷模型集的组成可能随之发生变化，同时也会影响最优负荷模型集中各模型的权重，负荷特性在扰动过程中可能

随时是变化的。当系统稳定运行时,最优模型集的组成和最优模型集中各模型的权重是不变的。在最优负荷模型集中模型权重的更新过程中,与负荷特性匹配程度高的负荷模型权重增加;反之,权重减小。

将最优负荷模型的动态部分和静态部分分别合并,并将合并后的有功、无功功率拟合结果与实测功率进行对比分析,结果如图 2-10 所示,可以显示实测数据和计算数据的拟合结果。

拟合结果的误差可由式 (2-57) -式 (2-59) 计算。 $\max(|\Delta PQ|)$ 表示有功和无功的最大误差; $|\overline{\Delta PQ}|$ 表示有功和无功功率的平均误差, $\text{std}(|\Delta PQ|)$ 表示标准偏差。

$$\max(|\Delta PQ|) = \max(|\hat{x}_i - x_i|) \quad (2-57)$$

$$|\overline{\Delta PQ}| = \left(\sum_{i=1}^n |\hat{x}_i - x_i| \right) / n \quad (2-58)$$

$$\text{std}(|\Delta PQ|) = \sqrt{\left(\sum_{i=1}^n |\hat{x}_i - x_i|^2 \right) / (n-1)} \quad (2-59)$$

其中 $\hat{x}_i$ 是估计的状态值; x_i 是测量值; n 是测量的数量。


分别采用自适应交互式多模型负荷建模 (Adaptive Interacting Multiple Load Modeling, AILM) 方法和 IIMM 负荷建模方法进行测试,误差对比结果如表 2-4 所示。

表 2-4 拟合误差对比


Tab. 2-4 Comparison of fitting errors

	AILM			IIMM		
	$\max(\Delta PQ)$	$ \overline{\Delta PQ} $	$\text{std}(\Delta PQ)$	$\max(\Delta PQ)$	$ \overline{\Delta PQ} $	$\text{std}(\Delta PQ)$
P	1.9831×10^{-4}	4.3513×10^{-6}	1.0819×10^{-5}	1.9976×10^{-4}	4.2600×10^{-6}	1.0532×10^{-5}
Q	2.5378×10^{-4}	5.6000×10^{-6}	1.4550×10^{-5}	2.5329×10^{-4}	5.3576×10^{-6}	1.4358×10^{-5}

从表 2-4 的功率拟合误差可以看出,采用本文提出方法所建立的负荷模型误差率较小,且相比 AILM 方法误差较小,精度有所提升。因此, IIMM 负荷建模方法的交互和输出融合精度高,可以有效解决负荷特性的时变问题。



(a) 有功功率拟合情况



(b) 无功功率拟合情况

图 2-10 负荷功率的拟合情况

Fig. 2-10 Fitting results of the load power

2.5 本章小结

本章提出了 IIMM 负荷建模方法。在对影响 IMM 算法精度的 TPM 分析的基础上,引入极化校正函数和激活校正函数。在极化校正函数作用下,匹配的模型概率升高,不匹配的模型概率降低,可以获得抗噪声性能。激活校正函数包括模型之间的历史信息,并在子模型跳跃时充分计算当前模型信息。IIMM 负荷建模方法使用一组负荷模型来描述可能的负荷特性,通过负荷模型输入交互和输出融合,建立一个综合负荷模型,每个模型的权重可以根据概率进行调整。仿真结果表明,IIMM 负荷建模方法的输入交互与输出融合具有较高的精度,能够反映负荷成分的变化。

3 基于 GCN 的电力负荷解耦

3.1 引言

随着新型电力系统复杂性与日俱增，尤其分布式发电、电动汽车和需求侧响应等新电网元素的加入，电网的特性发生了巨大的变化。电力负荷是电力系统的重要组成部分，其负荷特性对整个电网的特性有重要的影响。目前电力负荷建模大多数研究都集中于基于测量的负荷建模方法，这种以传统网络拓扑角度分析建立的负荷模型忽略网络节点间电气耦合作用，并不能准确揭示负荷的本质特性。电力负荷本质特性决定其动力学行为，从更符合实际的角度来研究负荷本质特性显得尤为迫切和重要。

基于测量的负荷建模方法通过考虑负荷节点所连接的相应母线上的测量来识别负荷参数，忽略了电源节点和其它负荷节点对该负荷节点的影响。这是因为，负荷节点测量的实时功率受电源节点实时功率变化的影响，还受到除节点以外的负荷节点功率变化的影响。这反映了负荷节点与其它网络节点间的耦合联系。电网所有负荷的耦合（也称“聚合”）效应使得其单个负荷除具有通常特定负荷特性外，还具有电网特性。由于电网的众多负荷交互在一个无法分解为“孤岛”的单个系统中，因此在一个负荷上进行的测量并不反映标称负荷行为，而是反映其在电网环境中的行为。针对电力系统中因负荷耦合无法建立反映真实负荷特性的负荷模型问题，在对电力系统进行图表示的基础上，本章提出基于 GCN 算法的负荷数据解耦方法，获取反映各节点真实的响应特性数据进行负荷建模，进而研究电力系统扰动过程各节点响应和耦合的影响。仿真结果证明了耦合性的存在，验证了所提方法的有效性。

3.2 考虑负荷特性的电力系统图表示

3.2.1 电力系统图表示

深度神经网络已经彻底改变了电力系统中的许多机器学习任务，从先进传感器、智能电表等获取功率曲线、电力变压器的溶解气体和绝缘体的图像等各种欧几里得数据并进行模式识别和信号处理。然而，在电力系统中有越来越多的应用，其数据表示为非欧几里得域的图结构数据，例如潮流计算的输入数据包括每个节点的负荷和邻接矩阵，这是一种图结构数据。图结构数据的复杂性给现有的欧几里得域中定义的深度神经网络带来了新的挑战。

通常，图由一组通过边连接的对象（称为节点）组成，节点和边都可以具有与其关联的数据。电力系统是一个非常复杂的系统，具有许多不确定因素。在基本层面上，电力系统是由发电机、负荷及其相关控制元件组成的互联网络。这些组件中的每一个都可以被认为是图的节点，而物理连接它们的输电线路可以被视为图的边。由于电力系统本身的拓扑结构与图的关系结构一致，通过图表示学习，可以有效地保留数据中隐含的相关性，最大程度地描述电力系统的真实运行状态。

对于由 N 个节点、 M 条输电线路组成的电力系统，可简化为 $G=(V,E)$ 的电力系统图表示，其中 $V=\{v_1, v_2, \dots, v_N\}$ 表示节点， $E=\{e_1, e_2, \dots, e_M\}$ 表示边。当 $N=6, M=7$ 时，该电力系统图表示简化，如图 3-1 所示。




图 3-1 电力系统图表示示例 ($N=6, M=7$)

Fig. 3-1 An example of power system graph representation ($N=6, M=7$)

构造邻接矩阵 $A \in \{0,1\}^{N \times N}$ ，若节点 v_i 和 v_j 相连接，则 $A_{ij}=1$ ；否则 $A_{ij}=0$ 。以

图 3-1 所示为例，可表示为邻接矩阵 A 。

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 1 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 & 0 \end{bmatrix}$$

邻接矩阵可以在没有任何信息损失的情况下表示图。虽然电力系统的线路从

物理上来说都可双向通过能量,当能量的流通方向变化时其物理参数一般都不随之发生变化,但在进行复杂系统的网络建模时,并没有考虑采用双向边的形式,而是认为网络中的边均为无向边。对于具有无向边的图,邻接矩阵将是对称的,因为从节点 n 到节点 m 的边的存在意味着从节点 m 到节点 n 也有边,因此对于所有 n 和 m , $A_{nm} = A_{mn}$ 。

一般用度矩阵 D 来规范邻接矩阵 A 。构造度矩阵 $D = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & 0 & \vdots \\ \vdots & 0 & \ddots & 0 \\ 0 & \cdots & 0 & d_N \end{bmatrix}$ 表示图

中节点与其它节点相邻的次数;其中 $d_i = \sum_{j=1}^N A_{i,j}$ 。

对图 3-1 所示,可表示为度矩阵 D 。

$$D = \begin{bmatrix} 2 & 0 & 0 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 2 & 0 & 0 \\ 0 & 0 & 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 0 & 0 & 2 \end{bmatrix}$$

构造拉普拉斯矩阵

$$L = D - A \quad (3-1)$$

归一化的拉普拉斯矩阵可表示为

$$L = D^{-\frac{1}{2}}(D - A)D^{-\frac{1}{2}} = I - D^{-\frac{1}{2}}AD^{-\frac{1}{2}} \quad (3-2)$$

由于 L 是实对称矩阵,可进一步对角化为

$$L = W \Lambda W^T = \begin{bmatrix} \vdots & \vdots & \cdots & \vdots \\ w_1 & w_2 & \cdots & w_n \\ \vdots & \vdots & \cdots & \vdots \end{bmatrix} \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \cdots & \\ & & & \lambda_n \end{bmatrix} \begin{bmatrix} \cdots & w_1 & \cdots \\ \cdots & w_2 & \cdots \\ \cdots & \vdots & \cdots \\ \cdots & w_n & \cdots \end{bmatrix} \quad (3-3)$$

3.2.2 电力系统图学习

多年来,电网的图论特性如何影响电网模型的稳定性、动态性能、可控性、可观察性、可识别性和其它系统理论特性是电力系统研究的重要方向之一。部分问题已经在相关研究中得到了解决,例如结构保持模型的概念在 20 世纪 80 年代初提出,随后使用李雅普诺夫稳定性理论对瞬态稳定性进行了图论分析。但是,系统地理解图论如何作为深入理解电力系统动力学、稳定性和控制的工具,仍然有待进一步研究。

图学习从图结构数据中学习知识。图深度学习将深度学习应用于图形, 其中 GNN 已经成功地应用于处理图结构数据的各种问题。在 GNN 研究中, 电网仍然是一个很大程度上未开发的应用领域, 尽管它们的图表示和潮流算法已经被广泛研究。直观地说, 这种电网中的物理潮流原理与 GNN 使用的消息传递方法非常契合, 类似于已用于电网的图形模型中的推理。这为电网运行开辟了新的关键用例, 其中模型可以在一组不同的网格拓扑上进行训练, 并应用于新的网络拓扑。例如, 可以使用训练好的 GNN 作为基于物理的潮流求解器的替代品进行电网监测。

现有的 GNN 参数和结构是为计算机视觉数据设计的, 不适合电力系统中的一维时间序列。如何根据电力系统数据的特点, 调整具有较强特征提取能力的 GNN 的结构参数, 还需要进一步研究。到目前为止, GNN 在电力系统中的应用很少具有商业可行性。一方面, 关于 GNN 的理论还不完善, 还处于探索和验证的初级阶段。另一方面, 电力系统对控制方法的稳定性和可靠性有很高的要求, 而目前的 GNN 算法仍然基于统计规律和概率。

3.3 基于 GCN 的电力负荷解耦方法

3.3.1 图卷积神经网络

最早的提出 GNN 的是 Gori 等人^[133]和 Scarselli 等人^[134], 用于节点和图形分类任务。GNN 将特征信息嵌入图结构中并进行传播学习, 在每个节点与其邻居之间迭代地传递消息, 以提取节点周围的局部子结构特征。GNN 直接将图作为输入和输出图/节点表示, 具有性能可靠和可解释性等优点, 已经广泛运用于图结构问题研究。

最近, GNN 取得了重大进展, 有不同的神经网络架构出现, 包括图回归神经网络、图形注意力网络和图自动编码器等。神经网络在计算机视觉中的成功应用, 已经并行开发了大量算法, 将卷积的概念从图像推广到图数据, 通过对节点自身的特征和与该节点相邻节点的特征进行聚合获取节点的特征表示, 即 GCN 模型。

任意图结构数据都可以表示为图特征向量的线性加权。从信号分析理论看, 图特征向量是图信号在频域分解后的不同频率。因此, 图傅里叶变换也可以理解为图信号的频域表示。使用拉普拉斯的特征向量 $W=(\bar{w}_1, \bar{w}_2, \dots, \bar{w}_N)$ 作为基函数, 设 $x(i)$ 对应图节点 v_i 的信号值, 则任意的图上的信号可以表示式 (3-4) 所示。

$$\begin{pmatrix} x(1) \\ x(2) \\ \vdots \\ x(N) \end{pmatrix} = (\bar{w}_1 \quad \bar{w}_2 \quad \cdots \quad \bar{w}_N) \begin{pmatrix} \hat{x}(\lambda_1) \\ \hat{x}(\lambda_2) \\ \vdots \\ \hat{x}(\lambda_N) \end{pmatrix} \quad (3-4)$$

由此可得图傅里叶正变换为

$$\begin{pmatrix} \hat{x}(\lambda_1) \\ \hat{x}(\lambda_2) \\ \vdots \\ \hat{x}(\lambda_N) \end{pmatrix} = (\bar{w}_1 \quad \bar{w}_2 \quad \cdots \quad \bar{w}_N)^T \begin{pmatrix} x(1) \\ x(2) \\ \vdots \\ x(N) \end{pmatrix} \quad (3-5)$$

即，式 (3-6) 所示。

$$F(x) = \hat{x} = W^T x \quad (3-6)$$

设有两组图信号，分别表示为 f 和 h ，其卷积的傅立叶变换是其傅立叶变换的乘积，如式 (3-7) 所示。

$$f \bullet h = W(W^T f) \odot (W^T h) = W \text{diag}[\hat{h}(\lambda_1), \dots, \hat{h}(\lambda_N)] W^T f \quad (3-7)$$

在卷积操作中，一般直接使用参数 θ 代替 $\hat{h}(\lambda_n)$ ，并通过反向传播误差进行调整，如式 (3-8) 所示。

$$f \bullet h = \sigma(W \text{diag}[\hat{h}(\lambda_1), \dots, \hat{h}(\lambda_N)] W^T f) = \sigma(W_{g\theta} W^T f) \quad (3-8)$$

当图数据规模较大时，卷积操作可能需要花费较长时间。基于图傅里叶变换特征值的考虑，对卷积操作改进，如式 (3-9)、式 (3-10) 所示。

$$g_\theta(\Lambda) \approx \sum_{k=0}^K \theta_k \Lambda^k \quad (3-9)$$

$$f \bullet h = \sigma\left(W \sum_{k=0}^K \theta_k \Lambda^k W^T f\right) \quad (3-10)$$

因此，GCN 的卷积层可定义，如式 (3-11) 所示。

$$Y = \sigma\left(W \left(\sum_{k=0}^K \theta_k \Lambda^k\right) W^T X\right) = \sigma(LX) \quad (3-11)$$

GCN 是当前图数据学习和分析的重要算法，能够实现对节点特征信息与图结构信息同时学习，具有广泛适用性。GCN 的主要思想是通过边传递消息，并在节点上聚合这些消息，以计算节点嵌入向量。GCN 对任意拓扑结构的图均能够适用，尤其在处理节点分类或者边预测等任务方面具有明显优势，其原理如图 3-2 所示。

图 3-2 中, $X^{N \times K}$ 为输入特征, 其中 N 为节点个数, K 为特征维度; $Z^{N \times F}$ 输出特征, 其中 N 为节点个数, F 为特征维度。




图 3-2 GCN 原理

Fig. 3-2 The framework of GCN

在 GCN 中的每个隐含层可以写成以下函数形式

$$H^{(l+1)} = f(H^{(l)}, A) \quad (3-12)$$

对于输入层 $H^{(0)} = X$, X 为输入特征矩阵; 对于输出层, $H^{(l)} = Z$, 其中 l 为网络层数, Z 为输出特征矩阵。

GCN 基于输入图结构 (例如, 邻接矩阵 A) 和输入节点特征 X 产生节点表示。GCN 模型基于其在图上的邻居对节点信息进行编码。直观地, GCN 将节点表示为其邻居的函数, 就像 CNN 中的卷积运算一样。GCN 迭代地聚合来自节点的局部邻域的信息, 以为该节点产生更好的特征 (或嵌入)。考虑节点自身特征及邻接矩阵标准化, 式 (3-12) 改写为

$$H^{(l+1)} = f(H^{(l)}, A) = \sigma \left(\hat{D}^{-\frac{1}{2}} \hat{A} \hat{D}^{-\frac{1}{2}} H^{(l)} W^{(l)} \right) \quad (3-13)$$

其中 $\hat{A} = A + I$; $\hat{D}$ 是 $\hat{A}$ 的度矩阵; σ 是非线性激活函数; $W^{(l)}$ 是权重矩阵。

通过定义不同的目标函数, 可实现预测、分类、优化等目的。

3.3.2 基于 GCN 的负荷解耦

为简化电力系统研究, 作以下假定:

- (1) 负荷节点之间的影响是无方向的, 即节点 i 对节点 j 的影响因子 α_{ij} 与节点 j 对节点 i 的影响因子 α_{ji} 相同, $\alpha_{ij} = \alpha_{ji}$;

(2) 如节点 i 与节点 j 不直接相连, 而是通过其它节点间接产生影响, 则忽略该影响;

(3) 电源节点作为特殊负荷节点对待。

基于以上理论和假定, 对节点 i , 其实测功率 $\hat{P}_i$ 为该节点负荷响应 $\bar{P}_i$ 与其它负荷节点功率对该负荷节点响应功率影响的加权值。

$$\begin{bmatrix} \hat{P}_1 \\ \hat{P}_2 \\ \hat{P}_3 \\ \vdots \\ \hat{P}_N \end{bmatrix} = \begin{bmatrix} 1 & \alpha_{12} & \alpha_{13} & \cdots & \alpha_{1N} \\ \alpha_{21} & 1 & \alpha_{23} & \cdots & \alpha_{2N} \\ \alpha_{31} & \alpha_{32} & 1 & \cdots & \alpha_{3N} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \alpha_{N1} & \alpha_{N2} & \alpha_{N3} & \cdots & 1 \end{bmatrix} \begin{bmatrix} \bar{P}_1 \\ \bar{P}_2 \\ \bar{P}_3 \\ \vdots \\ \bar{P}_N \end{bmatrix} \quad (3-14)$$

其中, $\hat{P}_i$ 为节点实测功率; $\bar{P}_i$ 节点负荷响应; $i=1,2,3,\dots,N$; α 为第 N 节点负荷响应功率与其余 $N-1$ 各节点功率之间影响的权值。

根据系统的图表示, 忽略非直接相连负荷节点的影响, 实测功率 $\hat{P}_i$ 的表达式改写为式 (3-15)。

$$\begin{bmatrix} \hat{P}_1 \\ \hat{P}_2 \\ \hat{P}_3 \\ \vdots \\ \hat{P}_N \end{bmatrix} = \begin{bmatrix} 1 & \alpha_{12} & \alpha_{13} & \cdots & \alpha_{1N} \\ \alpha_{21} & 1 & \alpha_{23} & \cdots & \alpha_{2N} \\ \alpha_{31} & \alpha_{32} & 1 & \cdots & \alpha_{3N} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \alpha_{N1} & \alpha_{N2} & \alpha_{N3} & \cdots & 1 \end{bmatrix} (A + I) \begin{bmatrix} \bar{P}_1 \\ \bar{P}_2 \\ \bar{P}_3 \\ \vdots \\ \bar{P}_N \end{bmatrix} \quad (3-15)$$

其中 A 为图的邻接矩阵, 表达了各节点之间的连接情况; 在邻接矩阵作用下, 非直接相连的负荷节点被置为零, 即忽略了其影响。

基于 GCN 的负荷特性数据解耦框架, 如图 3-3 所示。基于 GCN 的负荷特性数据解耦的过程如下:

(1) 对待建模负荷节点所在系统进行简化, 并进行图表示。

(2) 通过实测或模拟扰动, 观测记录各节点实测电压、频率和功率值, 并进行预处理。

(3) 将图特征数据及各节点电压、功率数据作为输入, 对 GCN 进行训练, 获取各节点间权重信息及解耦后的自身电压及功率响应值。

(4) 以解耦后的自身电压及功率响应为输入, 通过 IIMM 建模方法获取负荷模型。




图 3-3 基于 GCN 的负荷解耦框架原理图

Fig. 3-3 The load decoupling framework based on GCN

3.4 算例分析

为了进一步说明耦合性对多机电力系统负荷建模的影响，证明论文所提出解耦方法的有效性，以 IEEE 三机九节点系统为例进行仿真分析。具体验证思路如下：

（1）在相同网络结构、扰动设置情况下，保持待建模负荷节点的模型参数设置不变，改变系统内其它负荷节点的参数，获取待建模负荷节点在不同系统负荷配置下扰动数据。

（2）对不同系统负荷配置下扰动数据，采用第 2 章提出的 IIMM 负荷建模方法，获取模型参数或最优负荷模型组合。由于待建模负荷节点的参数并未改变，如在不同系统负荷配置下的负荷建模结果不一致或存在较大偏差，则说明负荷耦合性的存在；反之，如在不同系统负荷配置下的负荷建模结果一致，则说明负荷建模仅与负荷节点的量测数据有关，系统结构、参数的变化不影响待建模负荷节点，即耦合性不存在。

（3）在耦合性得到有效验证前提下，将扰动数据分为训练集和验证集，采用 GCN 对验证集数据进行解耦，基于 IIMM 负荷建模方法获取待建模负荷节点解耦前后的训练集数据负荷模型。不同系统负荷配置下，如解耦后的负荷建模结

果完全相同或基本一致，则说明所提方法有效剥离了系统结构、参数等对待建模负荷节点的影响，实现了负荷解耦。

(4) 为证明采用解耦后数据建立的模型具有有效性，将待建模负荷节点参数代入单机无穷大系统进行建模测试，对比采用解耦后训练数据建立的负荷模型，如最优负荷模型集模型概率相同则可以证明解耦所建立模型的有效性。

3.4.1 算例系统设置

以 IEEE 三机九节点系统为例进行研究分析，如图 3-4 所示。该系统由 3 台额定电压不同的发电机组组成，升压后在 230kV 电压等级形成简单互连网络。该典型系统的参数见文献[135]。




图 3-4 IEEE 三机九节点系统

Fig. 3-4 IEEE nine bus system

在 Matlab R2022A 中搭建模型进行仿真验证，仿真环境为 Intel Core(TM) i5-10500 CPU @ 3.10GHz, NVIDIA GeForce GTX 1050 Ti, RAM 8GB。具体的扰动设置和负荷配置如下。

(1) 负荷配置

本文以负荷 2 为待建模研究对象，即保持负荷 2 的负荷组成不变。通过对负荷 1 和负荷 3 的仿真参数进行调整，获取验证数据。调整前后的负荷节点参数配置如表 3-1 所示，即调整负荷 3 的 10MVA 电动机(IM)负荷，增加负荷 1 的 10MW 纯阻抗（RLC）负荷。

表 3-1 负荷参数设置

Tab. 3-1 Load parameters

负荷节点	测试 1		测试 2	
	RLC	IM	RLC	IM
负荷 1（MVA）	70+ j80	0	80+ j80	0
负荷 2（MVA）	200-j60	20	200-j60	20
负荷 3（MVA）	0	60	0	50

(2) 扰动设置

仿真开始后，算例系统迅速进入稳定运行状态。设置系统在运行到 6s 时，节点 5 发生三相短路故障，持续时间 0.2s 后故障消除，系统继续运行至 10s。对各节点电流、电压、有功功率、无功功率情况进行数据观测，获取各节点的扰动数据。取基准电压为 500kV、基准功率为 100MVA，将数据转换为标么值。以节点 1 为例，相关曲线如图 3-5 所示。




图 3-5 节点 1 扰动曲线

Fig. 3-5 Load response curves of Node 1

3.4.2 电力负荷耦合性验证

在相同网络结构、扰动设置情况下，分别采用表 3-1 中负荷 1 和负荷 3 不同参数进行测试仿真。节点 6 为负荷 2 所在母线，截取 5.9s 至 6.5s 时间段数据进行研究。在两次测试中的电压、有功功率、无功功率响应曲线对比如图 3-6 所示。




图 3-6 节点 6 两次测试扰动曲线对比

Fig. 3-6 Load response curves of Node 6


采用第 2 章提出的 IIMM 负荷建模方法对节点 6 两次测试的扰动数据进行建模。测试 1、测试 2 中负荷 2 最优模型变化情况、最优模型概率变化情况、有功功率拟合情况分别如图 3-7、图 3-8、图 3-9 所示。

经过计算得到的模型概率如表 3-2 所示，M1、M2 和 M3 分别为最优模型集中的 3 个子模型。


表 3-2 模型概率对比

Tab. 3-2 Model probabilities

	M1	M2	M3
测试 1 概率	0.0362	0.0690	0.8948
测试 2 概率	0.2855	0.4051	0.3094




(a) 测试 1 中负荷 2 最优模型变化情况




(b) 测试 1 中负荷 2 最优模型概率变化情况

图 3-7 测试 1 中负荷 2 最优模型变化情况

Fig. 3-7 Change of optimal models of Load 2 in Test 1




(a) 测试 2 中负荷 2 最优模型变化情况




(b) 测试 2 中负荷 2 最优模型概率变化情况

图 3-8 测试 2 中负荷 2 最优模型变化情况

Fig. 3-8 Change of optimal models of Load 2 in Test 2



(a) 测试 1 中负荷 2 有功功率拟合情况



(b) 测试 2 中负荷 2 有功功率拟合情况

图 3-9 负荷 2 有功功率拟合情况

Fig. 3-9 Active power fitting results of Load 2

从图 3-7 至图 3-9 及表 3-2 的结果可以看出：

(1) 故障发生时（即仿真实际时间的 6s 时刻），模型没有立即开始进行变化调整。这与 IIMM 负荷建模方法的特点有关，即模型切换时间取决于模型转移概率，通过优化模型转移概率可以缩短切换时间，但切换时间永远不可能为零。

(2) 两次测试中，模型概率约在相同时间（故障后 0.02s 左右）开始进行调整，且变化情况大致相同。然而，在故障后 0.05s 左右时，测试 2 中的模型概率再次发生了变化，而测试 1 中的模型概率未再进行调整。

(3) 故障消除后（即 0.3s 后），模型概率均未再发生变化，与故障期间得到的最终模型概率一致。

(4) 在负荷组成及参数未发生变化的情况下，两次测试最终建模结果偏差较大，而这种差异的来源即系统配置或参数变化，同时也说明了耦合性的存在。

(5) 两次测试的拟合情况与实测响应基本一致，曲线几乎完全重叠。一方面，虽然建立模型参数不同，但对特定系统环境下的扰动适应性较好，能够反映当前环境下的负荷特性；另一方面，同一负荷建模得到的参数具有分散性，则该模型的泛化能力较差，如应用于电力系统的数值仿真中将可能导致错误计算结论。

3.4.3 图卷积神经网络解耦

针对 3.4.2 中出现的因耦合性问题导致建模参数不一致或分散性问题，采用本文提出的解耦方法进行处理，并进行建模验证。

(1) 系统图表示

将发电机节点与变压器输出节点合并，如图 3-4 中虚框所示。可得到 IEEE 三机九节点系统的图表示，如图 3-10 所示。IEEE 三机九节点系统的图表示为邻接矩阵 A 和度矩阵 D 。

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 & 0 \end{bmatrix}$$

$$D = \begin{bmatrix} 2 & 0 & 0 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 2 & 0 & 0 \\ 0 & 0 & 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 0 & 0 & 2 \end{bmatrix}$$




图 3-10 简化后 IEEE 三机九节点系统图表示

Fig. 3-10 Graph representation of simplified IEEE nine bus system

(2) 数据解耦

将测试 1 和测试 2 获取的扰动数据进行划分，取 5.9s 至 6.2s 数据进行解耦验证。

对于 GCN，设隐含层为 6，输入特征维数为 1，学习步长为 30，学习率为 0.01，验证频率为 100。设置目标函数为 6 个节点的均方根误差最小值并进行训练。以测试 1 的有功功率解耦为例，训练误差在迭代过程中的变化如图 3-11 所示。






图 3-11 训练误差

Fig. 3-11 Training errors

分别对测试 1、测试 2 中节点 6 电压、有功功率、无功功率的训练数据进行解耦，解耦前后对比如图 3-12 所示。



(a) 测试 1 中 GCN 处理前后节点 6 训练数据



(b) 测试 2 中 GCN 处理后节点 6 训练数据

图 3-12 GCN 处理前后节点 6 训练数据


Fig. 3-12 Training data of Noad 6 before and after processed with GCN

通过对节点 6 观测训练数据解耦前后对比分析可以得出以下结论：


- (1) 同一负荷在不同系统配置或参数下的电压扰动曲线不同，解耦后的电压扰动曲线也不同；有功功率、无功功率扰动曲线也符合该结论。
- (2) 扰动曲线解耦后的变化趋势可能与观测数据一致，如测试 1 的电压、有功功率扰动曲线；也有可能存在与观测数据相反的情况，如测试 2 的电压、无功功率扰动曲线。
- (3) 解耦后的数据可能存在负值的情况。

3.4.4 解耦效果分析


为了验证解耦效果，需要对不同测试条件下节点 6 训练数据进行解耦前后的模型参数对比。如不同测试条件下，解耦后的建模结果一致，则可以说明解耦后的数据与系统配置、参数等无关，能够反映该负荷“孤立”运行时的特性。采用 IIMM 负荷建模方法对测试 1 中节点 6 的训练数据分析，解耦前后的最优负荷模型变化情况、模型概率及功率拟合结果分别如图 3-13、图 3-14 所示。采用同样方法对测试 2 中节点 6 的训练数据分析，结果如图 3-15、图 3-16 所示。



(a) 测试 1 中节点 6 训练数据解耦前最优模型变化情况




(b) 测试 1 中节点 6 训练数据解耦前最优模型概率情况




(c) 测试 1 中节点 6 训练数据解耦前功率拟合情况

图 3-13 测试 1 中 GCN 处理前节点 6 训练数据建模结果


Fig. 3-13 Modeling results of Noad 6 using training data in Test 1 before processed with GCN



(a) 测试 1 中节点 6 训练数据解耦后最优模型变化情况




(b) 测试 1 中节点 6 训练数据解耦后最优模型概率情况




(c) 测试 1 中节点 6 训练数据解耦后功率拟合情况

图 3-14 测试 1 中 GCN 处理后节点 6 训练数据建模结果


Fig. 3-14 Modeling results of Noad 6 using training data in Test 1 after processed with GCN



(a) 测试 2 中节点 6 训练数据解耦前最优模型变化情况




(b) 测试 2 中节点 6 训练数据解耦前最优模型概率情况




(c) 测试 2 中节点 6 训练数据解耦前功率拟合情况

图 3-15 测试 2 中 GCN 处理前节点 6 训练数据建模结果


Fig. 3-15 Modeling results of Noad 6 using training data in Test 2 before processed with GCN



(a) 测试 2 中节点 6 训练数据解耦后最优模型变化情况



(b) 测试 2 中节点 6 训练数据解耦后最优模型概率情况



(c) 测试 2 中节点 6 训练数据解耦前功率拟合情况

图 3-16 测试 2 中 GCN 处理后节点 6 训练数据建模结果

Fig. 3-16 Modeling results of Noad 6 using training data in Test 2 after processed with GCN

从图 3-13、图 3-14、图 3-15 和图 3-16 可以分析得到以下结论：

- (1) 对于解耦前的数据，最优模型在扰动发生后经过调整趋于稳定。
- (2) 对于解耦后的数据，最优模型经过初始化后的调整后同样趋于稳定，分别为子模型 1、子模型 4 和子模型 8；而且在扰动发生后，模型的概率未发生明显变化。

3.4.5 解耦效果验证

为了进一步说明采用解耦后数据建立的模型具有有效性，将节点 6 数据代入单机无穷大系统进行验证，系统结构如图 3-17 所示。负荷 2 即 IEEE 三机九节点系统中的负荷 2。

故障设置与 IEEE 三机九节点系统相同，均为 6s 时刻发生故障，持续 0.2s 后切除。将测试数据采用 IIMM 算法进行电力负荷建模。




图 3-17 单机无穷大系统仿真系统

Fig. 3-17 Single-machine infinite bus system

获得的有功功率、无功功率拟合对比结果如图 3-18 所示，最优模型及最优模型概率变化情况如图 3-19 所示。






图 3-18 单机无穷大系统下负荷功率实测及拟合情况

Fig. 3-18 Measured power and fitting results of load in single-machine infinite bus system



(a) 单机无穷大系统中最优模型变化情况



(b) 单机无穷大系统中最优模型概率变化情况

图 3-19 单机无穷大系统中最优模型变化情况

Fig. 3-19 Change of optimal models in single-machine infinite bus system

对验证结果进行分析可知：

(1) 单机系统下，数据扰动对最优模型集的确定影响较大，主要原因是仿真过程中为了避免短路情况下电压、功率突降为零，增加了系统阻抗；对原负荷模型建立造成了一定影响。

(2) 单机无穷大系统在扰动发生后及扰动消除后经过调整最终确定的最优模型集是子模型 1、子模型 4 和子模型 8，与前述验证结果一致，证明了解耦后的数据建模结果与单机下的结果一致，验证了本文提出的解耦方法的有效性。

3.5 本章小结

现实中的负荷通常不会孤立运行，而是接入由多机系统组成的不同电压等级的电网中。由于负荷耦合效应，电网中负荷除具有单个负荷通常特定的负荷特性外，还具有电网特性。针对在一个负荷上进行的量测建模无法建立反映真实负荷特性的模型问题，本章在对电力系统进行图表示的基础上，采用 GCN 对各节点数据进行处理，研究电力系统扰动过程中各节点响应交互影响耦合的情况。通过数据解耦，获取反映各节点真实负荷特性的数据进行负荷建模，仿真结果验证了所提方法的有效性。

4 电力负荷季节时变特性分析

4.1 引言

电力负荷呈现时变特性,不同季节的峰值负荷呈现出不同的模式,一周中的一天和一天中的一个小时的峰值负荷也会波动。即使对于同一系统,在不同的时间段也可能会出现不同的负荷模型。负荷在一天不同时间和一周的不同日子变化,从而使电力负荷成为时变量。然而,电力负荷的变化存在一定的周期性和规律性。文献[136]通过对不同并网变电站负荷曲线的观察,发现负荷曲线具有“日”、“周”、“月”、“季”特征,这意味着负荷曲线本质上是周期性的。文献[137]采用了三种方法来构建负荷模型,用于捕获每个季节以及工作日、节假日的24小时电力负荷概况,为每个季节和工作日、节假日的组合建立单独的模型。文献[138]提出了一种电力负荷建模与预测的混合方法,通过拟合具有时间和气象因素作为变量的广义相加模型(Generalized Additive Model, GAM)来模拟每周电力负荷数据的整体和季节性趋势,结果表明季节性模式每年都会重复,这可以通过温度、日照持续时间和云量的季节性变化来解释。

造成负荷时变的原因多种多样。电力负荷主要受以下因素的影响:

(1) 经济因素。电价、负荷管理和工业化程度等经济因素对系统平均负荷和系统最大需求有重要影响。电价和人们的购买能力会影响电力的使用,进而影响日负荷曲线。分时电价可以改变高峰负荷的持续时间和发生时间。其它经济因素,如客户类型、人口状况、人均收入、国内生产总值增长和社会活动等,都可能导致负荷模式发生相当大的变化。

(2) 天气因素。天气对家庭和农业消费者的影响最为显著,但它也可以改变工业消费者的负荷状况。天气因素包括温度、湿度、降水、风速、云量、光照强度等。在各种天气特征中,温度是对负荷波动影响最大的因素;人们用电来供暖和制冷,供暖和制冷的电力需求也会随着全年气温的变化而变化,这些变化对冬季采暖和夏季空调的负荷需求影响较大。

(3) 时间因素。时间因素,如季节变化、日照时数变化、平均气温变化等,可能会导致负荷模式发生相当大的变化。此外,昼夜时间负荷消耗不同,工作日和周末不同的消费模式,节假日的负荷模式将与工作日和周末有所不同。

(4) 随机因素。电力系统中存在对负荷模式有较大影响的随机扰动,包括工业突然停工或开工、大范围罢工等。此外,疫情、节能电器的使用、可再生能源和分布式能源应用也是造成负荷随机波动的原因。

传统的负荷建模方法利用某一时间段的测量数据,可能无法捕捉时变的负荷

行为,且缺乏泛化能力。如何表示负荷模型和负荷组成的季节和地理变化是一个研究的热点问题。捕捉负荷行为的时变特性对电压控制、状态估计和能量管理非常有用。

智能电网中大规模负荷数据的采集和存储为电力负荷行为分析、负荷预测和负荷管理创造了条件。通常,负荷数据没有包含足够的负荷变化因子,一般只包含时变的电力需求。在某些情况下,负荷数据包含电价和一些气象特征。随着传感器、智能电表等数据采集技术的发展,每天都会产生大量细粒度的数据,数据源数量的增加以及这些数据源的多样性、准确性和可信度给负荷数据分析和信息提取带来挑战。

日负荷曲线记录了一天內电力负荷随时间的变化情况,其中包含丰富的负荷特征信息。本文借鉴深度学习理论和方法在图像处理中的应用,通过对日负荷曲线的数据挖掘,提取出能够反映季节性电力负荷特性的特征,基于特征提取的分类实现对电力负荷的季节划分,为周、月等周期性或规律性的研究提供参考。

本文采用的 GAF 算法将一维时间序列的日负荷曲线数据转换为图像,而不丢失任何特征,同时添加了时间相关性,有利于负荷时变特性挖掘;采用 PCANet 进行级联特征学习和提取,具有较好的鲁棒性和转移性;CNN 可以捕捉局部特征,Bi-LSTM 可以捕捉时序信息,采用 CNN+Bi-LSTM 进行负荷特性分类具有准确率高、参数少等优点。

4.2 电力负荷特性的基本分类方法

通过负荷特性分析建立不同时段的不同负荷模型是当前负荷建模研究的重点和方向。负荷特性分类已被证明是分析负荷特性最有效的方法之一,特别是各种智能仪表的发展对负荷成分的准确估计和特征提取提供了有力数据支撑。负荷特性分类过程通常包括两个阶段:

(1) 训练阶段:从训练实例构建训练模型,即用带标签的负荷数据或提取到的特征对分类模型进行训练,获取分类模型的各项参数。

(2) 测试阶段:将未参与训练的测试实例输入训练后的负荷特性分类模型,根据分类结果对分类模型的准确性进行评估。

然而,由于当前电力系统中存在数据采集、传输和存储等应用,经常出现数据缺失的问题,使得负荷分类任务无法准确识别负荷类别。同时,由于负荷数据具有周期性、非周期性和噪声因素,时间和空间复杂性高,因此需要通过特征提取和特征选择进行负荷数据压缩和降维,提高分类方法的性能。一般地,负荷特性分类方法包括数据预处理、特征选取、分类算法实现三个步骤,如图 4-1 所示。




图 4-1 电力负荷特性分类方法

Fig. 4-1 Classification method for power load characteristics

(1) 负荷数据预处理。负荷数据预处理主要是进行数据的去噪和坏数据识别。通常使用两种技术来识别负荷数据中的坏数据，一是基于信号分解的技术，将测量信号分解，使分解后的信号具有较好的异常值和较低的不确定性，如小波分解，经验模态分解和傅里叶变换等，已在各类异常检测领域得到了应用；二是非分解技术，检测测量信号中的不规则性如空值、假数据和异常等。

(2) 特征选取。其包括特征的选择和特征的提取两个方面，被广泛用于去除冗余和不必要的特征，以提高学习模型的性能。在特征选择方面，通过从现有特征中选择最合适的特征来降低数据空间的维数。而在特征提取中，通过从现有特征中提取较少数量的新特征来降低数据空间的维数，如因子分析、主成分分析等。特征选择和特征提取是分类过程中的第一个阶段。真实数据可能包含用于预测类标签的不同相关性的特征。不相关的特征除了是计算低效的来源之外，通常还会影响分类模型的准确性。因此，特征选择和特征提取算法的目标是选择关于类标签的信息量最大的特征。通常，负荷时变因素是不同数据集的一部分，需要高效的特征提取方法从海量特征集中提取特征。三种主要特征选择和特征提取方法如下。

①滤波器模型：可以使用清晰的数学标准来评估特征或特征子集的质量，然后使用该标准来过滤掉不相关的特征。在滤波器模型中，使用类敏感判别标准来评估特征或特征子集。一次评估一组特征的优点是可以很好地考虑冗余。考虑两个特征变量彼此完全相关的情况，可以使用另一个来预测每个特征变量。在这种情况下，只使用其中一个特征是有意义的，因为另一个特征相对于第一个特征没有增加增量知识。因此，在实践中，大多数特征选择方法相互独立地评估特征，并选择最具鉴别力的特征。一些特征选择方法，如线性判别分析，将原始特征的

线性组合创建为一组新的特征。这类分析方法既可以被视为独立的分类器，也可以视为分类前使用的降维方法，具体取决于它们的使用方式。

②包装模型：假设分类算法可用于评估算法对特定特征子集的表现，然后将特征搜索算法包裹在该算法周围以确定相关的特征集。不同的分类模型使用不同的特征集更准确。在某些情况下，利用特定分类算法的特性来选择特征。例如，线性分类器能够更有效地处理一组特征，而基于距离的分类器可以很好地处理距离反映类分布的特征。采用包装模型优化特征选择过程，使其与现有的分类算法相匹配，基本策略是通过连续添加特征来迭代细化当前特征集。

③嵌入式模型：分类模型的解决方案通常包含关于最相关特征的有用提示。这样的特征被隔离，并且分类器在修剪后的特征上被重新训练。嵌入式模型的核心思想是，许多分类公式的解决方案提供了关于要使用的最相关特征的重要提示；关于特征的知识被嵌入到分类问题的解决方案中。在递归特征消除中，使用迭代方法。在每次迭代中都会删除少量特征。在修剪后的特征集上对分类器进行再训练，以重新估计权重。重新估计的权重用于再次修剪具有最小绝对权重的特征。重复此过程，直到所有剩余特征被认为足够相关。嵌入式模型通常是以特定的方式设计。

特征指标主要基于典型日指标，如日最大负荷、日最小负荷、日平均负荷、日负荷率等。负荷特性分类所需特征向量应能反映负荷组成成分区别，不同的负荷的特征向量对应的空间中点的距离描述了其相似程度。常用的特征向量主要包括 5 类：

①负荷调查统计数据。此类特征向量主要用于基于元件机理的负荷建模，调查统计的数据主要为特定时间或时间段内用电设备的类型及其占比。采用调查统计数据的缺点主要是需要大量人力进行数据收集和统计综合，涉及地域比较广，所需时间比较长，同时数据准确性受人员因素和工作质量影响比较大。

②负荷实测响应。此类特征向量主要用于基于测量辨识的负荷建模，实测响应数据包括系统扰动下各测量仪器仪表记录的负荷电压、电流的幅值和相角数据，以及扰动发生时的时间、温湿度、季节、光照情况和负荷水平等数据。随着电力系统监测监控水平提高，此类特征向量的获取相对容易。

③负荷模型参数。此类特征向量是在上述实测响应特征向量的基础上进一步提取获得。通过对实测扰动数据进行参数辨识，获取负荷模型参数作为特征向量。

④标准激励模型响应。此类特征向量是在上述实测响应特征向量和模型参数特征向量基础上获取的。利用实测响应数据获取模型参数，以标准电压激励下的负荷有功和无功响应数据作为特征向量。

⑤日负荷曲线。此类特征向量主要在较长时间尺度上反映负荷组成；选择日

负荷曲线数据作为特征向量, 或由其抽取、拼接成的周负荷曲线、月负荷曲线等作为特征向量。此外, 也可以选取可以描述日负荷曲线的变化规律的特定指标作为特征向量。

从采集的负荷数据可以看出, 负荷曲线具有周期性。负荷的周期性不仅表现在日负荷上, 而且表现在周、月、季、年负荷曲线上, 这是负荷曲线的一个非常重要的性质。在某种程度上, 日负荷曲线的使用具有一定的合理性, 因为从社会生产的周期性角度来看, 不同时期的电力消费行为具有显著的相似性。现有研究中, 已广泛使用堆叠自编码、卷积自编码、残差网络、长短期记忆网络等方法进行负荷特征提取。

(3) 分类方法。分类问题是学习已经被划分为组的示例数据集的结构, 这些示例被称为类别或类。这些类别的学习通常通过一个模型来实现。该模型用于估计具有未知标签的一个或多个先前看不见的数据示例的类标签。分类问题的训练数据是带有类标签的示例数据集, 与聚类方法不同之处在于分类方法从示例数据集中获取分组规律和概念。最著名的分类方法包括决策树、基于规则的分类器、概率模型、基于实例的分类器、SVM 和神经网络等。

①决策树使用以树状结构排列的特征变量上的一组分层决策对分类过程进行建模。在树的特定节点处的决策, 被称为分裂准则, 通常是训练数据中一个或多个特征变量的条件。分割标准将训练数据划分为两个或多个部分。决策树中的每个节点在逻辑上表示数据空间的一个子集, 该子集由其上节点的拆分标准组合定义。决策树通常被构造为训练示例的分层划分, 就像自上而下的聚类算法分层划分数据一样。与聚类的主要区别在于, 决策树中的划分标准是用训练实例中的类标签来监督的。

②基于规则的分类器, 使用一组“if-then”规则来匹配前因和后果。与决策树一样, 简洁的规则, 无论是从规则集的基数还是每个规则中的连词数量来看, 通常都更可取。这是因为这样的规则不太可能过度填充数据, 并且会很好地推广到看不见的测试实例。基于规则的算法的训练阶段创建一组规则。测试实例的分类阶段会发现由该测试实例触发的所有规则。当测试实例满足先行词中的逻辑条件时, 规则被称为由测试实例触发。在某些情况下, 具有冲突结果值的规则是由测试实例触发。在这种情况下, 需要一些方法来解决类标签预测中的冲突。规则集可以满足一个或多个属性。

互斥规则: 每个规则覆盖一个不相交的数据分区。一个测试实例最多可以触发一个规则。

详尽规则: 整个数据空间至少由一条规则覆盖。每个测试实例至少触发一个规则。

③概率分类器构建了一个模型，该模型将特征变量和目标（类）变量之间的关系量化为概率。两种最受欢迎的方法可以执行这样的建模。

贝叶斯分类器：贝叶斯规则用于对给定特征变量集的目标变量的每个值的概率进行建模。假设一个类内的数据点是根据特定的概率分布（如伯努利分布或多项式分布）生成的，类条件特征独立性的朴素贝叶斯假设通常用于简化建模。这种类型的分类器被称为生成分类器。

逻辑回归：假设目标变量来自伯努利分布，其均值由特征变量上的参数化 logit 函数定义。因此，类变量的概率分布是特征变量的参数化函数。这与贝叶斯模型形成对比，贝叶斯模型假设每个类的特征分布的特定生成模型。这种类型的分类器被称为判别分类器。

④SVM 是一种二分类模型，可以将分类问题转换成二次规划问题，在解决小样本、非线性和高维模式识别问题方面具有明显优势。SVM 使用分离超平面作为两类之间的决策边界，利用裕度的概念建立了确定这些超平面的优化问题。SVM 的一个重要区别特征是，它们广泛关注两类之间的决策边界区域，因为这是最不确定的区域，容易出现分类错误。SVM 算法采用结构风险最小化原理，具有良好的泛化能力和较强的自适应学习能力，使用核函数将样本映射到高维特征空间可以有效解决非线性样本的分类问题。

⑤神经网络是一种模拟人类神经系统的模型。人类的神经系统是由被称为神经元的细胞组成的。生物神经元在被称为突触的接触点处相互连接。学习是通过改变神经元之间突触连接的强度在生物体中进行的。通常，这些连接的强度会随着外部刺激而变化。神经网络可以被认为是这一生物过程的模拟。与生物网络的情况一样，人工神经网络中的单个节点被称为神经元。这些神经元是从其它一些神经元接收输入、对这些输入进行计算并将其输入其它神经元的计算单元。神经元的计算函数由该神经元的输入连接上的权重定义。这个权重可以被视为类似于突触连接的强度。通过适当地改变这些权重，可以学习计算函数，这类似于生物神经网络中突触强度的学习。人工神经网络中用于学习这些权重的“外部刺激”是由训练数据提供的。其思想是，每当当前权重集做出不正确的预测时，递增地修改权重。

目前负荷特性分类算法研究主要关注无监督机器学习算法，如 K-means、FCM 和 DBSCAN 算法。然而，上述机器学习算法对数据集中数据实例的分布非常敏感，这可能会降低负荷分类性能。监督学习分类算法，如 SVM、贝叶斯网络和近似最近邻搜索也得到了发展并广泛应用于分类问题。随着负荷数据维数和负荷数据量的增加这些算法仍然会遇到效率低下和过拟合的问题。

4.3 电力负荷时变特性特征提取与分类框架

深度学习在计算机视觉和语音识别上发展得很好，但是碰到时间序列时，很难构建预测或分类模型。本文借鉴图像分类的思想，把时间序列转成图片，充分利用目前机器视觉上的优势进行负荷季节特性特征提取和分类研究。GAF 可以将时间序列编码为极坐标系中的图像，而不是典型的笛卡尔坐标，最大程度地保留其时序相关特征^[139,140]。

PCANet 是一种简单的深度学习网络模型，在图像识别领域具有很强的应用潜力^[141]。CNN 是一种由卷积层、池化层和全连接层组成的神经网络，可以在保留训练样本主要特征的同时防止过拟合，从而提高模型的泛化能力。LSTM 是一种改进的循环神经网络，可以深度挖掘历史数据中包含的信息。文献[142]提出了由前向 LSTM 和后向 LSTM 组成的 Bi-LSTM 模型，其中前向 LSTM 从序列开头在时间上移动，后向 LSTM 从序列末尾在时间上移动。将 Bi-LSTM 和 CNN 的优点结合，采用 CNN+Bi-LSTM 相结合的算法；该算法在情感分析、探地雷达扫描图像分析等学习任务中取得了应用^[143]。本文利用 CNN 进行季节性负荷特征的特征学习，将学习到的特征送到 Bi-LSTM 进行时间序列编码，通过 *Softmax* 进行分类。

每个季节使用不同的负荷模型，因为一个季节内的 24 小时负荷具有几乎相同的模式；但不同季节之间有所不同。每个季节的工作日都是单独建模的，因为它们的负荷模型也非常不同。然而，值得注意的是，在较长时间尺度上，一些不可忽略的功耗特征是无法根据典型的日负荷曲线提取出来的。例如，如果以周为单位对日负荷曲线进行分类研究，则有可能在分类结果中保留不同负荷在工作日和周末之间的不同表现的信息，从而获得更准确反映负荷特性的分类结果。因此，在较长时间尺度上对日负荷曲线进行分析，可以更有效的表征用户或负荷节点的日间、月间、季节间的变化特性^[144]。

基于 PCANet 和 CNN+Bi-LSTM 算法的电力负荷季节特性特征提取和分类框架如图 4-2 所示。主要包括 3 部分，具体如下：

(1) 选择季节划分方法，确定不同季节的起止时间，如天文划分法、气象划分法或气候划分法；收集指定电网、变电站或用户的年度日负荷曲线数据，按季节划分标注并存储；对日负荷曲线数据进行预处理；把时序数据规范化到区间[0,1]，把规范化后的值转化为极坐标，利用 GAF 将其转化为二维图像矩阵。

(2) 从每个季节的日负荷曲线数据中随机选取合适数量的样本，分别形成训练数据集和测试数据集；使用 PCANet 算法使用训练数据集提取特征；使用奇异值分解（Singular Value Decomposition, SVD）算法进行特征降维。

(3) 利用 CNN+Bi-LSTM 算法构建和训练分类器；用测试数据集验证分

类器。




图 4-2 基于 PCANet 和 CNN+Bi-LSTM 算法的电力负荷时变特性分类框架

Fig. 4-2 The framework of feature extraction and classification method of time-varying power load characteristics based on PCANet and CNN+Bi-LSTM algorithms

4.4 基于 PCANet 和 CNN+Bi-LSTM 算法的负荷时变特性特征提取与分类方法

4.4.1 日负荷曲线数据处理

日负荷曲线由实测数据描述而成，其变化规律描述测量端负荷特性。日负荷曲线的变化趋势能够在一定程度上反映该负荷节点的综合负荷特性。最明显的特征是，因负荷节点的负荷组成成分不同，负荷曲线早晚高峰出现时间存在明显差异。

图 4-3 所示为国家发展和改革委员会公布的 2020 年典型工作日、节假日电力负荷曲线。从图 4-3 中可以看出，不同地区的工作日负荷曲线存在差异，例如山东电网工作日负荷比较平稳，京津唐电网昼夜负荷差距较大；另外，同一电网工作日与节假日负荷也可能存在较大差异，例如京津唐电网节假日相比工作日呈现双峰特征，节假日中午存在低谷时段。




图 4-3 典型日负荷曲线

Fig. 4-3 Typical daily load curve

选取日负荷曲线或从日负荷曲线提取的特征作为特征向量进行负荷特性分类具有以下特点:

日负荷曲线描述了某一区域或某负荷节点的负荷随时间变化的情况,与该区域或负荷节点下的用户用电行为密切相关。通过对日负荷曲线进行分析或特征提取,可以获取不同负荷节点的负荷特性变化规律,即负荷成分的变化情况。随着电力系统监测监控装置的安装与应用,可以方便的获取不同时间尺度的日负荷曲线实测数据,能够更快更直接的进行负荷特性研究,为在线建模或负荷特性分类提供数据支撑。基于日负荷曲线或提取得到的特征向量进行负荷特性分类,对电力系统负荷预测、需求侧管理等其它负荷管理领域也具有重要借鉴意义。

然而,采用日负荷曲线作为特征向量进行负荷特性分类会存在以下问题。特征量选择:直接采用日负荷曲线的实测值作为特征向量进行分类,数据维度高,将对聚类或分类算法的计算效率产生较大影响。需要选择或提取能够描述日负荷曲线的特征量或反映负荷特性的指标值作为特征向量,实际上也是日负荷曲线降维的过程。选择不同的日负荷曲线特征向量,对分类算法的效率及分类结果的准确性将产生不同影响。目前没有研究证明存在明确唯一的特征向量,需要根据实际情况进行选取。异常数据:自各类监测监控系统中获取的日负荷曲线在采集或传输过程中可能引入噪声或误差。此外,因设备故障或系统异常也可能导致获取的日负荷曲线数据出现缺失、失真或突变等异常,将对分类结果的准确性造成影响。

虽然日负荷曲线因区域分布、季节气候等因素存在一定差异,但同一位置同一时段的曲线峰谷时刻或大致形状存在相似性且一般不会有突增(突降)。负荷建模中的负荷特性分析一般选取变电站日负荷曲线,通过对变电站日负荷曲线的隐含特征或变化规律进行分析或分类,可以获取综合负荷特性或其组成成分变化情况。

4.4.1.1 去噪

从能量管理系统(Energy Management System, EMS)中获取的日负荷曲线数据是离散的,其数据记录间隔通常为1分钟或5分钟,而且在数据采集、传输、转换等环节都可能发生故障或受到干扰,因此在对日负荷曲线进行分析前需要进行数据去噪处理。小波分析是一种重要的信号处理方法,主要运算功能包括伸缩和平移,能够实现多尺度精细化信号分析,可以用于时频分析、信噪分离与提取弱信号、特征提取与故障诊断等,通过小波变换可以容易地分离出噪声或者其它不需要的信息。本文选取sym4小波对日负荷曲线进行4层小波分解并去噪。小波去噪过程在Matlab中调用Wavelet Toolbox实现。以某电网2020年某日的日负荷曲线为例进行小波去噪,去噪前后的日负荷曲线和噪声曲线,如图4-4所示。




图 4-4 日负荷曲线去噪结果

Fig. 4-4 Denoising results of daily load curve

4.4.1.2 异常数据筛选

在数据准备阶段，异常值检测和处理是重要的预处理步骤之一。识别和去除异常值至关重要。异常值的识别已成为统计方法和应用领域的重要课题。在实际电力系统运行过程中，由于数据采集异常、运行方式调整等会造成日负荷曲线数据缺失或突变，不能反映常规运行状态下的特性，这类数据应当在研究中剔除。

Tukey 引入的经典箱线图是表示潜在异常值的主要经典工具，应用之一是识别单变量数据集中的极值和异常值^[145]。当数据的底层分布为正态分布时，在经典箱线图中，一个极端正态观测值被错误地表示为离群值的概率非常小。

箱线图通过数据统计量描述数据离散情况，可以用来快速直观识别数据中的异常值。数据统计量一般选用最小值、最大值，中位数和第一/三四分位数。当数据与相应的四分位 Q1 或 Q3 的距离大于 1.5 个四分位间距(Inter Quartile Range, IQR) 时，用星号或点标记单个数据。本文采用通过缺失数据检测修正箱线图法进行异常数据筛选与剔除。箱线图法原理如下：

设 A1 为数据序列的第一四分位数，A2 为数据序列的中位数，A3 为数据序列的第三四分位数，A4 为 A3 与 A1 的差值。则序列的正常值区间为

$$[A1 - 1.5IQR, A3 + 1.5IQR] \quad (4-1)$$

其中 $IQR = A3 - A1$ 。

以某电网 2020 年 11 月数据为例，箱线图如图 4-5 所示。通过本文方法可以检测出 11 月 7 日数据缺失，11 月 4 日、11 月 10 日数据异常，如图 4-6 所示。




图 4-5 2020 年 11 月数据箱线图

Fig. 4-5 Boxplot of load curve data of November 2020




图 4-6 2020 年 11 月 4/7/10 日负荷曲线

Fig. 4-6 Daily load curve of November 4/7/10, 2020

4.4.2 时间序列数据转换

时间序列数据是按时间顺序索引的一系列数据点,日负荷曲线是典型的时间序列数据。时间序列分类广泛存在于现实生活中的许多领域,如心电信号诊断分析、风力发电预测、故障类型判断等。近年来,学者们提出了大量的时间序列分类方法。文献[146]提出的基于距离的时间序列分类方法为时间序列分类领域提供了新的思路;文献[147]提出了基于特征的算法,该方法将周期性、非线性等13种特征组合来表示时间序列;文献[148]利用一系列时间序列数据集的小波变换和傅里叶变换得到的特征对时间序列进行分类。然而,由于实时序列数据具有波动性和不确定性,传统的专家系统和多模型分类方法在分类中表现不佳,时间序列分类仍然是一个具有挑战性的问题。

多年来,人们提出了不同的时间序列特征提取方法。基于形状的、基于符号的和基于核的时间序列特征提取方法是时间序列特征提取器的几个例子。每个特征都可以为机器学习算法提供一个关于数据集的新视角。然而,在即将到来的大数据时代,人工特征选择过于繁琐,消耗了大量的人力和计算资源,在机器学习问题中找到一个可以概括数据集中信息并产生改进结果的数据的良好表示是一项具有挑战性的任务。

受最近计算机视觉深度学习成功的启发,将时间序列转换为图像的想法在时间序列分析中受到了广泛关注。时间序列表示的一种方法是使用图像提取特征,将时间序列数据编码为图像的问题,以允许机器“视觉”识别和分类时间序列。时间序列的图像可以通过CNN进行训练,并自动从图像中提取特征^[149]。文献[150]改进了递归图(Recurrent Plot, RP)算法,利用压缩距离扩展了时间序列分类的RP范式。文献[151]提出了一种基于RP的加权邻接矩阵方法,在一阶Markov转移场(Markov Transition Fields, MTF)中从时间序列中提取旋转运动特征。

描述三种成像时间序列的方法如下:

(1) 格拉姆角场。该方法基于时间序列的极坐标生成图像。给定一个时间序列 $X = \{x_1, x_2, \dots, x_N\}$, 由归一化 X 的极坐标在 $[-1, 1]$ 范围内得到一个新的级数 $\bar{X}$ 。然后,生成一个 $N \times N$ 维格拉姆角场(Gramian Angular Field, GAF)矩阵,其中 I 是单位线向量。每个点 $GAF_{i,j}$ 是这些点之间的三角函数和。这样, GAF 表示时间序列中不同时间间隔之间的时间相关性。

$$GAF = \bar{X}' \bar{X} - \sqrt{I - \bar{X}^2} \sqrt{I - \bar{X}^2} \quad (4-2)$$

(2) 马尔可夫转移场。该方法基于马尔可夫矩阵对时间序列进行图像处理。给定时间序列 $X = \{x_1, x_2, \dots, x_N\}$, 它的 Q 分位数箱是确定的, 其中 $q_j (j \in [1, Q])$ 是将

排序后的时间序列划分为具有相同维数的子集的点。定义 $Q \times Q$ 维的马尔可夫矩阵 M :

$$M = \begin{bmatrix} P(x_i \in q_1 | x_{i-1} \in q_1) & \cdots & P(x_i \in q_1 | x_{i-1} \in q_Q) \\ P(x_i \in q_2 | x_{i-1} \in q_1) & \cdots & P(x_i \in q_2 | x_{i-1} \in q_Q) \\ \cdots & \cdots & \cdots \\ P(x_i \in q_Q | x_{i-1} \in q_1) & \cdots & P(x_i \in q_Q | x_{i-1} \in q_Q) \end{bmatrix} \quad (4-3)$$

其中 $M_{i,j}$ 描述了 x_{i-1} 在分位数 q_j 时, x_i 在分位数 q_i 中的概率。它去除了矩阵中的时间相关性。一个 $N \times N$ 维的 MTF 矩阵:

$$MTF = \begin{bmatrix} x_1 \in q_i, x_1 \in q_j & \cdots & x_1 \in q_i, x_n \in q_j \\ x_2 \in q_i, x_1 \in q_j & \cdots & x_2 \in q_i, x_n \in q_j \\ \cdots & \cdots & \cdots \\ x_n \in q_i, x_1 \in q_j & \cdots & x_n \in q_i, x_n \in q_j \end{bmatrix} \quad (4-4)$$

其中 $MTF_{i,j}$ 是从一个分位数 q_i 到一个分位数 q_j 的概率。形式上, $MTF_{i,j||i-j|=k}$ 表示时间间隔为 k 的点之间的转移概率。

(3) 递归图。该方法是时间序列的二进制表示, 它提供了关于序列的时间相关性的信息。给定时间序列 $X = \{x_1, x_2, \cdots, x_N\}$, 得到其轨迹 $\vec{x} = \{\vec{x}_i, \vec{x}_{i+\tau}, \cdots, \vec{x}_{i+(m-1)\tau}\}$, $\forall i \in \{1, 2, \cdots, N - (m-1)\tau\}$, 其中 τ 为时间延迟, m 为轨迹维数。如果 $\vec{x}(i)$ 和之间的欧氏距离小于或等于阈值, 则设置点 $RP_{i,j}$ 。形式上, 设 $K = N - (m-1)\tau$, 一个 $K \times K$ 维的 RP 矩阵:

$$R_{i,j} = \begin{cases} 1, & \text{if } \|\vec{x}(i) - \vec{x}(j)\| \leq \varepsilon \\ 0, & \text{else} \end{cases}, \quad \forall i, j \in \{1, 2, \cdots, K\} \quad (4-5)$$

本文借鉴图像分类的思想, 把时间序列转成图片, 充分利用机器视觉进行负荷季节特性特征提取和分类研究, 转换示例如图 4-7 所示。具体转换流程如下:

(1) 数据预处理。为了消除每天负荷水平的差异, 重点研究日负荷曲线的变化规律, 本文对去噪后的日负荷曲线进行了归一化处理, 将数据通过伸缩变换映射到区间 $[0, 1]$ 内。设去噪后的日负荷曲线为 P_d , $P_{d\max}$ 、 $P_{d\min}$ 分别为 P_d 的最大值和最小值, 则归一化处理后的日负荷曲线 P_d^* 的计算公式为

$$P_d^* = \frac{P_d - P_{d\min}}{P_{d\max} - P_{d\min}} \quad (4-6)$$

(2) 坐标转换。将 P_d^* 转换至极坐标系，可表示为

$$\begin{cases} \phi_i = \arccos(P_{di}^*), 0 \leq P_{di}^* \leq 1, P_{di}^* \in P_d^* \\ r_i = \frac{i}{n} \end{cases} \quad (4-7)$$

其中 ϕ_i 为 P_{di}^* 映射到极坐标后的角度； r_i 为半径； n 为 P_{di}^* 中元素个数。

(3) 映射。GAF 可以将时间序列编码为极坐标系中的图像，最大程度地保留其时序相关特征。变换后，角度透视可以通过各点之间的格拉姆和角场 (Gramian Summation Angular Field, GASF) 或格拉姆差角场 (Gramian Difference Angular Field, GADF) 来识别不同时间间隔的时间相关性。

$$GASF = \begin{bmatrix} \cos(\phi_1 + \phi_1) & \cdots & \cos(\phi_1 + \phi_n) \\ \cos(\phi_2 + \phi_1) & \cdots & \cos(\phi_2 + \phi_n) \\ \vdots & \cos(\phi_i + \phi_i) & \vdots \\ \cos(\phi_n + \phi_1) & \cdots & \cos(\phi_n + \phi_n) \end{bmatrix} = P_d^{*T} \cdot P_d^* - \sqrt{I - P_d^{*2}}^T \cdot \sqrt{I - P_d^{*2}} \quad (4-8)$$

$$GADF = \begin{bmatrix} \sin(\phi_1 - \phi_1) & \cdots & \sin(\phi_1 - \phi_n) \\ \sin(\phi_2 - \phi_1) & \cdots & \sin(\phi_2 - \phi_n) \\ \vdots & \sin(\phi_i - \phi_i) & \vdots \\ \sin(\phi_n - \phi_1) & \cdots & \sin(\phi_n - \phi_n) \end{bmatrix} = \sqrt{I - P_d^{*2}}^T \cdot P_d^* - P_d^{*T} \cdot \sqrt{I - P_d^{*2}} \quad (4-9)$$

其中 $I = [1, 1, \dots, 1]$ 是单位行向量。




图 4-7 利用 GAF 的日负荷曲线转换

Fig. 4-7 Daily load curve conversion using GAF

4.4.3 负荷特性特征提取

机器学习是当今最重要、发展最快的技术领域之一。机器学习的应用正在变得无处不在，从数据中学习的解决方案正在越来越多地取代传统的手工算法。机器学习的一个特定分支，即深度学习，已经成为一种从数据中学习的异常强大和通用的框架。深度学习使用大数据集训练的多层神经网络来解决复杂的信息处理任务，并已成为机器学习领域最成功的范例。在过去的十年里，深度学习已经彻底改变了许多领域，包括计算机视觉、语音识别和自然语言处理，它正在医疗保健、制造业、商业、金融、科学发现和许多其它部门越来越多地应用中使用。

特征提取是分类任务开发中的一项重要操作。随着机器学习、计算机视觉、数据挖掘和信号处理社区的大量发展，这一过程已经成熟。图像包含各种特征，如几何特征、线条、奇异点和纹理等。通常，图像特征提取方法可以分为三类：基于线的技术（例如，边缘检测器或具有阈值的 Gabor 滤波器）、基于外观的技术（例如，线性判别分析或独立分量分析）和基于纹理的技术（例如，离散余弦变换）。从原始图像中提取的特征向量基于上述技术之一或不同技术的组合。

在深度学习时代，通过多个堆叠的卷积层处理数据来提取特征。深度架构特征提取的关键是以顺序的方式对多层执行复杂的操作。深度网络获得的特征比传统的浅层网络提供了更好的特征表示。然而，这些网络是通过随机优化技术训练的，这需要相同数据的多次失败才能有效地学习其表示。这导致在从数据中获得特征表示的同时训练时间更长。当前的研究趋势集中在缓解与深度架构开发相关的上述问题。Chan 等人提出了 PCANet 深度学习算法^[140]，其卷积层、非线性处理层和特征池化层分别由主成分分析滤波器组、二进制化和逐块直方图组成。PCANet 是一种很有前途的架构，它是一种在级联层中提取主成分的无监督深度简约网络，在各种数据库中实现了最先进的分类精度。

PCANet 是一个简单的前馈网络，它不需要反向传播来学习。相反，它们采用了从堆叠图像块中学习的 PCA 特征向量作为候选滤波器。在几个卷积层之后，使用二进制散列和逐块直方图对特征进行编码。尽管 PCANet 是用最基本的单元构建的，但它出人意料地在大多数图像分类任务中实现了最先进的性能。文献 [152] 使用五个图像数据库：Yale 数据库、AR 数据库、CMU PIE 人脸数据库、ORL 数据库和 CIFAR-10 数据库，在实验方面从能量的角度提出了一种新的方法来可视化、解释和理解 PCANet 的每一步，所提出的能量解释方法定性证明了 PCANet 的误差率与 BlockEnergy（PCANet 块滑动过程后的能量）对数的倒数相关。

与其它特征提取方法相比较，PCANet 深度学习可以以自适应的方式捕获纹理特征。因此，它可以以有效的灵活性提取相关的图像特征。由于级数和每级滤

波器数量这两个参数是可变的和自适应的，该方法的灵活性得到了保证。

假定训练样本数量为 N ，每个样本尺寸为 $m \times n$ ，每层的滤波器尺寸为 $k_1 \times k_2$ ，则 PCANet 算法进行特征提取，如图 4-8 所示。




图 4-8 基于 PCANet 算法的特征提取原理图

Fig. 4-8 Feature extraction based on PCANet algorithm

(1) 第一层：对于第 i 张图片进行分块处理，即以每个像素为中心，在其周围进行 $k_1 \times k_2$ 块采样，然后将所有的采样块进行级联和拼接， $x_{i,1}, x_{i,2}, \dots, x_{i,\tilde{m}\tilde{n}} \in R^{k_1 k_2}$ ，其中 $\tilde{m} = m - [k_1 / 2]$ ， $\tilde{n} = n - [k_2 / 2]$ 。

对采样得到的块进行零均值化，如式 (4-10) 所示。

$$\bar{X}_i = [\bar{x}_{i,1}, \bar{x}_{i,2}, \dots, \bar{x}_{i,\tilde{m}\tilde{n}}] \quad (4-10)$$

对其它样本进行同样处理得到训练样本集，如式 (4-11) 所示。

$$X = [\bar{X}_1, \bar{X}_2, \dots, \bar{X}_N] \in R^{k_1 k_2 \times N \tilde{m} \tilde{n}} \quad (4-11)$$

构造 PCA 滤波器，

$$W_l^1 = \text{mat}_{k_1 k_2} \left(q_l \left(X X^T \right) \right) \in R^{k_1 \times k_2}, l = 1, 2, 3, \dots, L_1 \quad (4-12)$$

其中 L_1 为第一层滤波器的个数； $\text{mat}_{k_1 k_2}(\bullet)$ 是一个映射函数； $q_l(X X^T)$ 表示 $X X^T$ 的第 l 个特征向量。

第一层的输出，如式 (4-13) 所示。

$$I_l^1 = I_i * W_l^1, i = 1, 2, \dots, N \quad (4-13)$$

(2) 第二层：对第一层的输出按照第一层的操作方法进行处理，得到

$$Y = [Y^1, Y^2, \dots, Y^{L_1}] \in R^{k_1 k_2 \times L_1 N \tilde{m} \tilde{n}} \quad (4-14)$$

其中 $Y^l = [\bar{Y}_1^l, \bar{Y}_2^l, \dots, \bar{Y}_N^l] \in R^{k_1 k_2 \times N \dim}$ 。

构造 PCA 滤波器,

$$W_\ell^2 = \text{mat}_{k_1 k_2} (q_\ell (YY^T)) \in R^{k_1 \times k_2}, \ell = 1, 2, 3, \dots, L_2 \quad (4-15)$$

其中 L_2 为第一层滤波器的个数; $\text{mat}_{k_1 k_2}(\bullet)$ 是一个映射函数; $q_\ell(YY^T)$ 表示 YY^T 的第 ℓ 个特征向量。

第二层的输出, 如式 (4-16) 所示。

$$O_i^l = \{I_i^l * W_z^2\}_{z=1}^{L_2} \quad (4-16)$$

因此, 第二层输出的特征矩阵数量为 $L_1 * L_2$ 个。

(3) 输出层: 首先对第二层的每个输出矩阵进行二值处理, 然后再对其进行二值化哈希编码, 编码位数为 L_2 ,

$$T_i^l = \sum_{\ell} 2^{\ell-1} H(I_i^l * W_\ell^2) \quad (4-17)$$

将第二层 PCA 滤波器的输出矩阵划分为 B 个数据块, 计算每个数据块的直方图特征, 然后将各数据块的直方图特征信息级联为

$$f_i = [Bhist(T_i^1), \dots, Bhist(T_i^{L_1})]^T \in R^{(2^{L_2})_{L_1} B} \quad (4-18)$$

(4) 奇异值分解:

设 $F = [f_1, f_2 \dots f_N]$, 则根据 SVD 分解公式

$$F = U \Sigma V^T \quad (4-19)$$

可得左奇异向量 U 和奇异值 Σ 。特征向量可表达为

$$F^* = U * \text{diag}(1 ./ \text{diag}(\Sigma)) \quad (4-20)$$

通过将日负荷曲线转换为二维图像进行特征提取并降维处理, 可以获取其中蕴含的负荷特性深度特征。获取的特征虽然无明确物理含义, 但能够表征负荷特性的差异, 可以用于负荷特性分析。

4.4.4 负荷特性分类算法

深度神经网络在计算机视觉领域的突出表现, 为电力系统中传统的基于模型的方法无法解决的问题带来了新的机遇。许多具有挑战性的任务, 如负荷和可再生能源(Renewable Energy Sources, RES)的时间序列预测、故障诊断、场景生成和运行控制, 高度依赖于手工特征工程来提取信息丰富的潜在特征, 最近已经被各种深度神经网络彻底改变, 如循环神经网络、CNN、生成对抗网络和自动编码器

等。CNN 是一种由卷积层、池化层和全连接层组成的神经网络，可以在保留训练样本主要特征的同时防止过拟合，从而提高模型的泛化能力。LSTM 是一种改进的循环神经网络，可以深度挖掘历史数据中包含的信息。为了进一步整合上下文有效信息，文献[141]提出了 Bi-LSTM 模型，该算法由前向 LSTM 和后向 LSTM 组合而成。前向 LSTM 从序列开头在时间上移动，后向 LSTM 从序列末尾在时间上移动。Bi-LSTM 算法的输出由前向 LSTM 的输出和后向 LSTM 的数据综合组成。将 Bi-LSTM 和 CNN 的优点结合，采用 CNN+Bi-LSTM 相结合的算法；该算法在情感分析、探地雷达扫描图像分析等学习任务中取得了应用。

4.4.4.1 CNN 算法

CNN 一种专用于处理类似网格结构数据的神经网络。网格结构数据在局部区域具有空间相关性，也表现出空间依赖性。CNN 倾向于从具有相似模式的局部区域创建相似的特征值。在 CNN 中，特征值之间具有基于空间距离的相互依赖性。其它形式的时间序列数据可以视为网格结构数据的特殊情况。

卷积运算是 CNN 的核心算法，也是其重要特征。卷积运算操作是对网格结构数据的权重与输入之间进行的点积运算。在 CNN 中，空间关系是逐层继承的，每个特征值都是基于上一层的网格单元运算得到，每一层中的状态也于空间网格结构排列密切相关。空间关系对卷积运算和到下一层的转换具有重要影响。每层卷积网络都是具有高度、宽度和深度的三维网格结构。

CNN 包含卷积层、池化层和全连接层 3 个单元。卷积层和池化层的作用是特征提取，即从图像中提取边缘、阴影、轮廓等特征。全连接层的作用与 BP 神经网络相同。通常，CNN 有多个完全连接的层，它包含用于卷积计算的多个完全连接层。

(1) 卷积层

卷积层计算公式如下：

$$X_k^{l'} = f \left(\sum_{i \in M_k} X_i^{l-1} * \omega_{ik}^l + b_k^l \right) \quad (4-21)$$

式中，* 代表卷积运算符号； M_k 代表一组输入特征图； ω_{ik}^l 表示网络第 l 层第 i 个卷积核的第 k 个权重； b_k^l 代表偏置； X_i^{l-1} 表示网络第 $l-1$ 层的第 i 个卷积核的输入特征图； $f(\cdot)$ 为激活函数； $X_k^{l'}$ 代表第 l 层的第 k 个输入特征图。

① 卷积运算

在数学上，卷积定义了一个实值函数作用于另一个实值函数以产生新的实值函数的过程。设一个实值连续函数为 $f(t)$ ，另一个实值连续函数为 $g(t)$ ，其中 t 表

示连续时间。这两个函数的卷积记为 $s(t)$ 卷积运算通常表示为 $*$ 。

$$s(t) = f(t) * g(t) = (f * g)(t) = \int_{-\infty}^{\infty} f(\tau) * g(t - \tau) d\tau \quad (4-22)$$

同时，卷积是一个交换运算，即

$$(f * g)(t) = (g * f)(t) = \int_{-\infty}^{\infty} g(\tau) * f(t - \tau) d\tau \quad (4-23)$$

两个方程的离散对应可以写成 $f(k)$ 和 $g(k)$ ，其中 k 表示时间的离散实例。

$$s(k) = f(k) * g(k) = (f * g)(k) = \sum_{\delta=-\infty}^{\infty} f(\delta) * g(k - \delta) \quad (4-24)$$

式 (4-24) 表示一维卷积，通常用于语音应用，其中信号是一维的。卷积的概念也可以应用于二维，这使得它适用于图像的应用。为了定义二维卷积，考虑两个图像 A 和 B 。二维卷积定义为：

$$A * B(i, j) = \sum_m \sum_n A(m, n) B(i - m, j - n) \quad (4-25)$$

卷积层由一系列二维核组成。每个核都使用式(4-25)定义的二维卷积应用于原始图形。

卷积运算与 Sobel 滤波器和 Gaussian 滤波器等图像处理滤波器非常相似。“内核”在图像上滑动，并将权重与每个对齐的像素相乘，在过滤器中按元素排列；然后，将偏置值添加到输出，如图 4-9 所示。




图 4-9 卷积运算原理图

Fig. 4-9 Flow chart of the convolution

有三个超参数决定输出特征图的空间：

步幅 (S)，是每次滑动过滤器时的步骤。当步幅为 1 时，一次移动一个像素的滤波器。当步幅为 2 时，滤波器一次跳跃 2 个像素。这将在空间上产生较小的输出体积。

填充 (P)，根据指定值填充大小的边框。在神经网络框架中，常使用零来填充这些位置，零填充的大小是一个超参数。零填充的大小也可以用于控制输出体积的空间大小。

深度 (D)，输出体积的深度也是一个超参数，它对应于卷积层的滤波器的数量。

②激活函数

在神经网络输入和输出之间建立映射关系，对于复杂和高维的数据建模分析至关重要，神经网络一般使用非线性激活函数。神经网络使用广泛的非线性激活函数之一，是 *sigmoid* 函数和双曲正切函数，分别定义如式 (4-26) 和式 (4-27) 所示。

$$\sigma(x) = \frac{1}{1 + \exp(-x)} \quad (4-26)$$

$$\tanh(x) = \frac{\exp(x) - \exp(-x)}{\exp(x) + \exp(-x)} \quad (4-27)$$

随着神经网络层数的增加，梯度消失的问题变得更加突出，深度学习模型一般不使用 *Sigmoid* 或 *tanh* 函数。使用经校正的线性单元 (Rectified Linear Unit, ReLU)，其总是产生与输入的规模无关的恒定梯度值，解决了梯度消失问题，能提高模型的计算速度。*ReLU* 激活函数在 CNN 设计和应用中得到了广泛认可。 $f(\cdot)$ 一般使用 *ReLU* 函数

$$f(x) = \max(0, \lg(1 + e^x)) \quad (4-28)$$

(2) 池化层

与卷积运算类似，池化运算通过重叠和定义步长等参数来适应不同的应用场景。然而，与卷积运算不同的是，池化运算是对单个矩阵执行的，卷积是对输入矩阵的核矩阵运算。池化为一个特殊的核矩阵，池化层通过用单个值替换较大的块来执行下采样。有两种常见类型池化：最大池化选择局部区域的最大值，准确地获取局部特征并保留纹理信息；平均池化计算局部区域的平均值，较好地保留整体特征，适合突出背景信息。通过池化，一些不重要的信息被丢弃，而对特定任务重要、有利的信息被保留，以降低维度和计算复杂性，如图 4-10 所示。




图 4-10 池化运算原理图

Fig. 4-10 Flow chart of pooling

常用的池化方法是最大池化。在此方法中，仅使用块的最大值来替换整个块。这一层大大降低了流经网络的数据的维数，同时仍然保留了作为卷积操作结果捕获的重要信息。这一层也减少了过拟合。池化后的特征面为

$$X_k^{l''} = f\left(\beta_k^l \text{sub}\left(X_k^{l'-l'}\right) X_k^l + b_k^l\right) \quad (4-29)$$

式中 β_k^l 、 b_k^l 分别代表相加和相乘参数； $\text{sub}()$ 为下采样计算公式。

(3) 全连接层

全连接层以传统的多层感知器的方式将卷积层的输出信息组合在一起生成所需的输出；通常使用 *Softmax* 激活函数规范化输出。为了增加计算能力，按照前馈网络的结构形式使用多个全连接层，含 2 隐含层的全连接层如图 4-11 所示。




图 4-11 含 2 隐含层全连接层原理图

Fig. 4-11 Fully Connected Layer with Two Hidden Layers

全连接层表示为

$$\left(X_k^{l''}, X_k^{2''} \dots X_k^{l''}\right) \quad (4-30)$$

4.4.4.2 Bi-LSTM 算法

LSTM 是一种改进之后的循环神经网络，由 Hochreiter 和 Schmidhuber 于 1997 年首次提出。LSTM 专用于时间序列、建模输出随时间序列输入数据历史变化的控制目标。LSTM 是一种改进之后的循环神经网络，解决了其它循环神经网络架构无法解决的问题，可以深度挖掘历史数据中包含的信息。LSTM 网络为多个重复单元组成的链状结构，而每个重复单元由三种类型的门组成：遗忘门、输入门和输出门，如图 4-12 所示。




图 4-12 LSTM 原理图

Fig. 4-12 Flow chart of the LSTM

(1) 遗忘门：遗忘门的主要作用是控制先前时间戳的存储器 c_{t-1} 当前状态向量 c 的影响，如图 4-13 所示。




图 4-13 遗忘门原理图

Fig. 4-13 Flow chart of the forget gate

遗忘门的控制变量由以下公式确定，通过 *sigmoid* 函数筛选上一单元状态中未被舍弃的部分

$$g_f = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (4-31)$$

其中 W_f 为遗忘门的权重； x_t 为样本输入数据； h_{t-1} 为上一单元的输出； b_f 为遗忘门的偏置。

(2) 输入门：输入们的主要作用是控制 LSTM 输入。首先，新的输入 $\tilde{c}_t$ 是对当前输入 x_t 和先前输出 h_{t-1} 进行变换而来。

$$\tilde{c}_t = \tanh(W_c[h_{t-1}, x_t] + b_c) \quad (4-32)$$

其中, w_c 和 b_c 是通过反向传播算法自动优化的参数; $\tanh$ 是用于将输入归一化的激活函数; $\tilde{c}_t$ 是通过控制输入门的控制变量控制接收的输入量。

$$g_i = \sigma(w_i[h_{t-1}, x_t] + b_i) \quad (4-33)$$

其中 w_i 和 b_i 是通过反向传播算法自动优化的参数; σ 通常使用 *Sigmoid* 函数; g_i 决定 LSTM 如何接受当前时间戳的新输入 $\tilde{c}_t$ 。

通过输入门后, 要写入存储器的矢量为 $g_i \tilde{c}_t$, 如图 4-14 所示。




图 4-14 输入门原理图

Fig. 4-14 Flow chart of the input gate

(3) 输出门: 在遗忘门和输入门的控制下, LSTM 读取先前时间戳的存储器 c_{t-1} 和当前时间戳的新输入 $\tilde{c}_t$ 。状态向量 c_t 更新如式 (4-34) 所示。

$$c_t = g_f c_{t-1} + g_i \tilde{c}_t \quad (4-34)$$

输出门的主要作用是控制 LSTM 的内部状态向量 c_t 选择性的输出, 如图 4-15 所示。该单元的最终输出如式 (4-35) 所示。

$$g_o = \sigma(w_o[h_{t-1}, x_t] + b_o) \quad (4-35)$$

其中 w_o 和 b_o 是经反向传播算法自动优化的参数; σ 一般取 *Sigmoid* 函数。LSTM 的输出如式 (4-36) 所示。

$$h_t = g_o \tanh(c_t) \quad (4-36)$$




图 4-15 输出门原理图

Fig. 4-15 Flow chart of the output gate

记忆向量 c_t 在通过 $\tanh$ 激活函数后与输入门相互作用，以获得 LSTM 的输出。由于 $g_o \in [0,1]$ 和 $\tanh(c_t) \in [-1,1]$ ，所以 LSTM 的输出是 $h_t \in [-1,1]$ 。

Bi-LSTM 融合了 LSTM 单元和双向网络，前向 LSTM 的输出

$$\vec{a}^{(t+1)} = \overrightarrow{Bi-LSTM}(x^{(t)}) \quad (4-37)$$

后向 LSTM 的输出

$$\overleftarrow{a}^{(n-t+2)} = \overleftarrow{Bi-LSTM}(x^{(t)}) \quad (4-38)$$

输出融合得到

$$T_k = \alpha \vec{a}^{(t+1)} + \beta \overleftarrow{a}^{(n-t+2)} \quad (4-39)$$

其中 α 、 β 分别为前向 LSTM 和后向 LSTM 的控制因子，其取值由通过训练集进行训练获取，且满足 $\alpha + \beta = 1$ 。

将融合后特征输入 *Softmax* 层得到分类结果。

$$\sigma_k = \text{Softmax}(T_k) = \frac{e^{T_k}}{\sum_{i=1}^n T_i} \in R^p \quad (4-40)$$

式中，本文 $\text{Softmax}(T_k)$ 季节分类有 4 种，取 $p=4$ 。

4.4.4.3 CNN+Bi-LSTM 算法

CNN 可以捕捉局部特征，Bi-LSTM 可以捕捉时序信息，本文结合两种算法的优势，提出采用 CNN+Bi-LSTM 进行负荷特性分类研究，利用 CNN 进行季节性负荷特征的特征学习，将学习到的特征送到 Bi-LSTM 进行时间序列编码，

通过 *Softmax* 进行分类。CNN+Bi-LSTM 算法分类的原理如图 4-16 所示。




图 4-16 CNN+Bi-LSTM 算法原理图

Fig. 4-16 Flow chart of the CNN+Bi-LSTM algorithm

4.5 算例分析

以典型电网 2020-2021 年的日负荷曲线数据为例，对所提方法进行验证。典型电网是位于中国山东省济南市的区级电网，由 11 座 110kV 变电站和 6 座 35kV 变电站组成。住宅负荷、商业负荷和工业负荷占该电网总功耗的近 80%。受区位和气候的影响，冷负荷和热负荷对负荷特性的影响很大，而且随着城市化和电能替代的发展，影响更加明显。

选用气象划分法，即春季为 3-5 月，夏季为 6-8 月，秋季为 9-11 月，冬季为 12-2 月。将春、夏、秋、冬的类别定义为 1、2、3、4，然后将所有采集到的日负荷曲线数据分配到对应的类别中。

从每个月向日负荷曲线数据中随机抽取 5 个样本组成一个训练集，容量为 60。k 最近邻（K Nearest Neighbor, KNN）算法、随机森林（Random Forest, RF）算法、LSTM 算法等是当前负荷分类或负荷预测研究常用的无监督分类算法。本文分别采用传统分类算法如 KNN 算法、RF 算法、LSTM 算法、GRU 算法、

Bi-LSTM 算法和 CNN+Bi-LSTM 算法等深度学习算法进行分类，对所提算法的有效性进行验证。

本算例通过 Matlab R2020a 编程实现，计算机配置为 windows, Intel(R) Core(TM) i5-10500 CPU @ 3.10GHz, NVIDIA GeForce GTX 1050Ti GPU and 8 GB RAM。

CNN+Bi-LSTM 算法需设置的超参数为 epoch 和 mini-batch。设置 epoch 取值范围为[50,550]，mini-batch 取值范围为[4,120]，采用试错法进行训练和验证，得到训练准确度，如图 4-17 所示。

CNN 可以捕捉局部特征，Bi-LSTM 可以捕捉时序信息，本文结合两种算法的优势，提出采用 CNN+Bi-LSTM 进行负荷特性分类研究，利用 CNN 进行季节性负荷特征的特征学习，将学习到的特征送到 Bi-LSTM 进行时间序列编码，通过 *Softmax* 进行分类。




图 4-17 不同 epoch 和 mini-batch 组合的训练精度

Fig. 4-17 Training accuracy with different combinations of epoch and mini-batch

根据计算结果，从准确性来看，epoch=300，mini-batch>60 时，准确性一直在 100%，因此 epoch 取 300。mini-batch=64、88、108、120 时，各 epoch 对应准确率均为 100%，考虑收敛速度，取 Mini-batch=64。

六种算法的分类精度如表 4-1 所示，分类结果如表 4-2 所示，混淆矩阵图如图 4-18 所示。

表 4-1 测试数据集分类准确率

Tab. 4-1 The accuracy of classification results using test data

算法	KNN	RF	GRU	LSTM	Bi-LSTM	CNN+Bi-LSTM
类别 1	93.3%	86.7%	100%	100%	100%	100%
类别 2	80%	86.7%	93.7%	93.3%	93.7%	93.3%
类别 3	66.7%	86.7%	86.7%	93.3%	86.7%	93.3%
类别 4	100%	86.7%	93.3%	93.3%	93.3%	100%
汇总	85%%	90%	93.3%	95%	93.3%	96.67%

表 4-2 验证数据集验证结果


Tab. 4-2 The verifying results using test data

序号	日期	类别	KNN	RF	GRU	LSTM	Bi-LSTM	CNN+Bi-LSTM
1	2020.6.2	2	1	2	2	2	2	2
2	2020.6.7	2	2	2	2	2	2	2
3	2020.6.12	2	2	3	2	2	2	2
4	2020.6.18	2	2	2	2	2	2	2
5	2020.6.22	2	2	2	2	2	2	2
6	2020.7.4	2	2	2	2	2	2	2
7	2020.7.8	2	2	2	2	2	2	2
8	2020.7.12	2	4	2	2	2	2	2
9	2020.7.16	2	2	2	2	2	2	2
10	2020.7.21	2	2	2	2	2	2	2
11	2020.8.6	2	2	2	2	2	2	2
12	2020.8.12	2	2	2	2	2	2	2
13	2020.8.18	2	2	2	2	2	2	2
14	2020.8.23	2	2	2	2	2	2	1
15	2020.8.30	2	3	3	3	3	3	2
16	2020.9.2	3	3	3	3	3	3	3
17	2020.9.7	3	3	3	3	3	3	3
18	2020.9.12	3	1	1	3	3	3	1
19	2020.9.17	3	3	3	3	3	3	3
20	2020.9.22	3	3	3	3	3	3	3
21	2020.10.4	3	3	3	3	3	3	3
22	2020.10.8	3	3	3	3	3	3	3
23	2020.10.12	3	3	3	3	3	3	3
24	2020.10.17	3	3	3	4	3	4	3
25	2020.10.22	3	4	3	3	3	3	3
26	2020.11.2	3	3	3	3	3	3	3


续表 4-2 验证数据集验证结果

Tab. 4-2 The verifying results using test data(continued)


序号	日期	类别	KNN	RF	GRU	LSTM	Bi-LSTM	CNN+Bi-LSTM
27	2020.11.12	3	3	3	3	3	3	3
28	2020.11.18	3	4	3	3	3	3	3
29	2020.11.24	3	4	3	3	3	3	3
30	2020.11.30	3	4	4	4	4	4	3
31	2020.12.3	4	4	4	4	4	4	4
32	2020.12.8	4	4	4	4	4	4	4
33	2020.12.13	4	4	4	1	1	1	4
34	2020.12.18	4	4	4	4	4	4	4
35	2020.12.23	4	4	4	4	4	4	4
36	2021.1.2	4	4	4	4	4	4	4
37	2021.1.7	4	4	4	4	4	4	4
38	2021.1.12	4	4	4	4	4	4	4
39	2021.1.17	4	4	4	4	4	4	4
40	2021.1.22	4	4	4	4	4	4	4
41	2021.2.3	4	4	4	4	4	4	4
42	2021.2.8	4	4	4	4	4	4	4
43	2021.2.13	4	4	4	4	4	4	4
44	2021.2.18	4	4	4	4	4	4	4
45	2021.2.23	4	4	4	4	4	4	4
46	2021.3.4	1	1	1	1	1	1	1
47	2021.3.9	1	1	1	1	1	1	1
48	2021.3.14	1	1	4	1	1	1	1
49	2021.3.19	1	1	1	1	1	1	1
50	2021.3.24	1	1	1	1	1	1	1
51	2021.4.3	1	4	4	1	1	1	1
52	2021.4.8	1	1	1	1	1	1	1
53	2021.4.13	1	1	1	1	1	1	1
54	2021.4.18	1	1	1	1	1	1	1
55	2021.4.23	1	1	1	1	1	1	1
56	2021.5.6	1	1	1	1	1	1	1
57	2021.5.12	1	1	1	1	1	1	1
58	2021.5.18	1	1	1	1	1	1	1
59	2021.5.24	1	1	1	1	1	1	1
60	2021.5.30	1	1	1	1	1	1	1




(a) KNN 算法




(b) RF 算法




(c) LSTM 算法



(d) Bi-LSTM 算法



(e) GRU 算法



(f) CNN+Bi-LSTM 算法

图 4-18 混淆矩阵图

Fig. 4-18 The confusion matrix diagrams of the algorithms

通过对表 4-1、表 4-2 和图 4-18 所示的分类结果分析可知：

(1) 春秋两季负荷特征有相似之处，这也是分类错误的原因之一。表 4-1 中的样品 18，它被错误分类为春季。

(2) 每个季度中旬的样本分类准确率可以达到 100%，如 4 月、7 月、10 月和 1 月。因此，选取 4、7、10、1 月份的日负荷曲线加权平均结果作为典型的电网季节性负荷特征曲线，如图 4-19 所示。

(3) 从图 4-19 可以看出，算例电网四季特点比较鲜明，两个高峰的幅值偏差随季节变化而不同；中午低谷时段与两个高峰的偏差随季节变化而不同；春秋两季虽然有一定的负荷相似性，但晚高峰幅值最高点出现的时间有所不同。

(4) 从表 4-2 所示知，深度学习算法的准确率高于传统分类算法，而 CNN+Bi-LSTM 算法的分类准确率最高。使用 CNN+Bi-LSTM 算法，每个类的分类准确率在 93.3%以上。




图 4-19 典型季节负荷日曲线

Fig. 4-19 Typical seasonal characteristics

4.6 本章小结

借鉴图像分类的思想,把日负荷曲线转换为二维图像,并分别采用 PCANet 和 CNN+Bi-LSTM 等深度学习算法进行了特征提取及分类,获取了典型季节负荷特性曲线,为负荷周特性、月特性等周期性规律研究提供了方法和思路。进一步地,通过研究月周期、周周期、日周期等特性变化情况,建立时变负荷特性特征库,为时变负荷特性的精确负荷建模奠定基础。另外,研究其它可用于分类的特征量,提高季节交替时期或相似季节情况下分类准确率。

5 结论与展望

电力电子元件及含电力电子设备的负荷大规模接入电力系统,交直流混联日益紧密,送受端耦合日趋明显,其特征与传统电力系统发生迥异变化。在电力电子开关作用下,电网拓扑结构呈现时变特性,同时在不同时间尺度控制下存在相互作用。现有的负荷模型及建模方法无法对时变性和耦合性进行准确描述,难以适应新型电力系统运行与分析的需要。在此背景下,本文以建立能够准确反映负荷特性模型为目标,基于 IIMM 负荷建模,对负荷时变特性、负荷节点间的耦合性问题进行分析和研究,对负荷的周期性变化规律进行分析和验证,对同一系统内不同负荷节点间的耦合机理进行探索,借鉴机动目标跟踪理论建立准确时变负荷模型。取得的主要研究成果如下:

(1) 提出了一种基于 IIMM 负荷建模方法。在对传统目标跟踪算法和 IMM 算法原理进行分析的基础上,针对影响 IMM 负荷建模有效性的模型转移概率更新问题,采用极化校正函数和激活校正函数对模型转移概率进行动态更新,通过权重来提高状态估计性能,以尽可能地抑制低模型概率。从整体负荷模型集中遴选出最优模型参与输入交互,不同模型根据模型转移概率跳转,并将最优模型集的输出依概率进行输出融合。通过不同负荷组成下的扰动仿真对提出方法进行验证,结果表明 IIMM 负荷建模方法能够跟随负荷组成变化动态更新最优负荷模型,且跟踪精度高。

(2) 提出采用 GCN 的负荷特性数据解耦方法。针对负荷建模中负荷耦合性问题,利用图表示学习和 GCN 理论分析电力系统图论特性,以发电机、负荷节点为图节点,以输配电线路为图的边,采用 GCN 对电力系统扰动过程中各节点响应和耦合进行研究。将电力系统按一定原则进行简化,并进行图表示,获取图的邻接矩阵等信息;构造 GCN,并将各节点电压、功率数据作为输入,对 GCN 进行训练,获取各节点间互相影响的权重信息;利用权重信息对负荷特性数据进行解耦,获取反映各节点实际特性的电压及功率响应。以 IEEE 三机九节点系统为例进行仿真测试,对相同网络结构、扰动设置情况下,不同负荷配置对同一节点负荷建模结果的影响进行分析,验证耦合关系的存在。将同一负荷节点参数代入单机无穷大系统进行建模测试,对比采用解耦后训练数据建立的负荷模型,验证了所提方法的有效性。

(3) 提出了一种基于 PCANet 和 CNN+Bi-LSTM 算法的电力负荷时变特性特征提取与分类方法。针对负荷扰动数据无法满足实时负荷建模需要的问题,全面分析了导致负荷时变的影响因素,从特征向量选取、分类方法选用等方面系统

描述了负荷特性分析框架。以负荷季节性变化规律为例,在对日负荷曲线进行特征提取的基础上探索负荷时变特性分类方法。借鉴深度学习理论和方法在图像处理中的应用,利用格拉姆角场将时间序列编码的日负荷曲线转换为极坐标系中的二维图像。对日负荷曲线进行数据挖掘,采用 PCANet 方法获取反映季节性电力负荷特性的深度特征。利用 CNN 算法捕捉局部特征和 Bi-LSTM 算法捕捉时序信息的优势,将两种算法相结合构建 CNN+Bi-LSTM 分类器,对提取的深度特征进行分类,获得各季节的典型负荷特性曲线。通过电网实测数据对提出的负荷特性分析方法进行验证分析,并与 KNN 算法、RF 算法、LSTM 算法、GRU 算法、Bi-LSTM 算法等进行对比,结果表明该方法分类准确性高,满足时变负荷建模需要。

本文主要针对 IMM 负荷建模中的时变性和耦合性问题进行研究,在 IIMM 负荷建模、负荷特性特征提取及分类、负荷特性数据解耦方面取得了一定的研究成果,但论文仍存在一些不足之处。未来需进一步研究的内容包括:

(1) 本文初步尝试将图论知识引入负荷建模,未对图结构负荷实时数据进行深入挖掘和分析。后续可以进一步研究基于图表示学习的电力系统各受端节点同步实时负荷建模的方法,实现全系统实时建模。

(2) 本文在建模过程中构造的模型集仍为比较传统的 ZIP 模型和感应电动机模型,未纳入电力电子元件模型。后续研究中需要进一步丰富模型集组成并研究模型集规模较大时提高模型遴选速度的方法。

参考文献

- [1]Jorge H, Mariano M. Social issues in the energy transition: Effect on the design of the new power system [J]. Applied Energy, 2020, 278: 115654.
- [2]Xie H, Jiang M, Zhang D, et al. IntelliSense technology in the new power systems [J]. Renewable and Sustainable Energy Reviews, 2023, 177: 113229.
- [3]IRENA. Global Renewables Outlook[R]. Abu Dhabi: International Renewable Energy Agency, 2020.
- [4]舒印彪, 薛禹胜, 蔡斌, 等.关于能源转型分析的评述: (一)转型要素及研究范式[J]. 电力系统自动化,2018,42(9):1-15.
- [5]周孝信, 陈树勇, 鲁宗相, 等. 能源转型中我国新一代电力系统的技术特征[J]. 中国电机工程学报, 2018, 38(07): 1893-1904+2205.
- [6]张智刚, 康重庆. 碳中和目标下构建新型电力系统的挑战与展望[J].中国电机工程学报, 2022,42(08):2806-2819.
- [7]Wang Y, Lu C, Zhang X. Applicability comparison of different algorithms for ambient signal based load model parameter identification [J]. International Journal of Electrical Power and Energy Systems, 2019, 111:382–389.
- [8]Zhu Y, Milanovic J V. Automatic identification of power system load models based on field measurements [J]. IEEE Transactions on Power Systems, 2018, 33(3):3162–3171.
- [9]Wang C, Wang Z, Wang J, et al. SVM-based parameter identification for composite ZIP and electronic load modeling [J]. IEEE Transactions on Power Systems, 2019, 34(1):182–193.
- [10]陈定保.瑞典电力系统 1983 年 12 月 27 日重大停电事故[J].电网技术, 1987, 1: 64-67.
- [11]Ohno T, Imai S. The 1987 Tokyo Blackout[C]. 2006 IEEE PES Power Systems Conference and Exposition, Atlanta, GA, USA, 2006: 314-318
- [12]Kosterev D N, Taylor C W and Mittelstadt W A. Model validation for the August 10, 1996 WSCC system outage [J]. IEEE Transactions on Power Systems, 1999, 14(3): 967-979.
- [13]Kosterev D, Meklin A, Undrill J, et al. Load modeling in power system studies: WECC progress update[C].2008 IEEE Power and Energy Society General Meeting - Conversion and Delivery of Electrical Energy in the 21st Century, Pittsburgh, PA,

- USA, 2008:1-8.
- [14]Milanovic J V, Gaikwad A, Borghetti A, et al. Modelling and aggregation of loads in flexible power networks[R]. CIGRE WG C4.605, 2014.
- [15]Gebreselassie A, Chow J H. Investigation of the effects of load models and generator voltage regulators on voltage stability [J]. International Journal of Electrical Power and Energy Systems, 1994, 16(3):83–89.
- [16]Xu Y, Ma J, Dong Z, et al. Robust transient stability-constrained optimal power flow with uncertain dynamic loads [J]. IEEE Transactions on Smart Grid, 2017, 8(4):1911–1921.
- [17]Milanovic J V, Yamashita K, Villanueva S M, et al. International industry practice on power system load modeling[J]. IEEE Transactions on Power Systems, 2013, 28(3):3038–3046.
- [18]Pasiopoulou I D, Kontis E O, Papadopoulos T A, et al. Effect of load modeling on power system stability studies [J]. Electric Power Systems Research, 2022, 207: 107846.
- [19]Arif A, Wang Z, Wang J, et al. Load modeling-a review [J]. IEEE Transactions on Smart Grid, 2018, 9(6):5986–5999.
- [20]Huang Q, Huang R, Palme B J, et al. A generic modeling and development approach for WECC composite load model [J]. Electric Power Systems Research, 2019, 172:1–10.
- [21]董坤, 赵剑锋, 孙睿晨, 等.含新型负荷元件的电力负荷建模方法研究现状与展望[J]. 电力系统自动化, 2023,47(23):70-83.
- [22]Yu S, Zhang S, Zhang X. Two-step method for the online parameter identification of a new simplified composite load model [J]. IET Generation Transmission & Distribution, 2016, 10(16): 1-9.
- [23]王振树. 电力系统负荷建模理论与方法[M]. 北京: 中国电力出版社, 2019.
- [24]Alireza R, Ali A. Real-Time Dynamic Parameter Estimation for an Exponential Dynamic Load Model [J]. IEEE Transactions on Smart Grid, 2016, 7(3):1530-1536.
- [25]倪以信. 动态电力系统的理论与分析[M]. 北京: 清华大学出版社, 2002.
- [26]Ge Y, Alexander J F, Kim D K, et al. An Event-Oriented Method for Online Load Modeling Based on Synchrophasor Data [J]. IEEE Transactions on Smart Grid, 2015, 6(4):2060-2068.
- [27]Regulski P, Vilchis-Rodriguez D S, Djurović S, et al. Estimation of Composite

- Load Model Parameters Using an Improved Particle Swarm Optimization Method [J]. IEEE Transactions on Power Delivery, 2015, 30(2):553-560.
- [28]Liang X. A New Composite Load Model Structure for Industrial Facilities [J]. IEEE Transactions on Industry Applications, 2016, 52(6): 4601-4609.
- [29]Qu X, Li X, Song J, et al. An Extended Composite Load Model Taking Account of Distribution Network [J]. IEEE Transactions on Power Systems, 2018, 33(6):7317-7320.
- [30]Jovica V. Milanovic , Koji Yamashita , Sergio Martinez Villanueva, et al. International Industry Practice on Power System Load Modeling [J]. IEEE Transactions on Power Systems, 2013, 28(3):3038-3046.
- [31]Zheng C, Wang S, Liu Y, et al. A novel RNN based load modelling method with measurement data in active distribution system [J]. Electric Power Systems Research, 2019, 166: 112-124.
- [32]Wang X, Wang Y, Shi D, et al. Two-Stage WECC Composite Load Modeling: A Double Deep Q-Learning Networks Approach [J]. IEEE Transactions on Smart Grid, 2020, 11(5):4331-4344.
- [33]IEEE Standard 2781-2022, IEEE Guide for Load Modeling and Simulations for Power Systems[S].
- [34]Kim J K, An K, Ma J, et al. Fast and Reliable Estimation of Composite Load Model Parameters Using Analytical Similarity of Parameter Sensitivity [J]. IEEE Transactions on Power Systems, 2016, 31(1):663-671.
- [35]Chávarro-Barrera L, Pérez-Londoño S, Mora-Flórez J. An Adaptive Approach for Dynamic Load Modeling in Microgrids [J]. IEEE Transactions on Smart Grid, 2021, 12(4): 2834-2843.
- [36]Ma Z, Wang Z, Wang Y, et al. Mathematical Representation of WECC Composite Load Model [J]. Journal of Modern Power Systems and Clean Energy, 2020, 8(5):1015-1023.
- [37]Ma Y, Wang Z, Jiang X, et al. Research on adaptive synthesis dynamic load model based on multiple model ideology [C]. Asia-Pacific Power and Energy Engineering Conference, APPEEC, 2016, Brisbane, QLD, Australia.
- [38]马阳阳. 交互式多模型电力负荷建模理论与方法研究[D].山东大学, 2016.
- [39]Wang Z, Ji N, Ma Y, et al. Model selection mechanism of Interactive Multiple Load Modeling [J]. International Journal of Electrical Power and Energy Systems, 2018, 103:58-66.

- [40]纪娜. 基于自适应交互式多模型算法的电力系统负荷建模研究 [D].山东大学, 2018.
- [41]Glavine P J. Interactive multiple model filtering for robotic navigation and tracking applications [D]. Memorial University of Newfoundland, 2019.
- [42]Munir A, Atherton D P. Adaptive interacting multiple model algorithm for tracking a maneuvering target [J]. IEE Proceedings-Radar, Sonar and Navigation, 1995, 142(1):11-17.
- [43]Wu P, Li X, Zhang L, et al. Tracking algorithm with radar and infrared sensors using a novel adaptive grid interacting multiple model[J]. IET Science, Measurement & Technology, 2014, 8(5):270-6
- [44]Bar-Shalom Y, Chang K, Blom H. Tracking a maneuvering target using input estimation versus the interacting multiple model algorithm [J]. IEEE Transactions on Aerospace and Electronic Systems, 1989, 25(2):296-300.
- [45]臧荣春, 崔平远. 马尔可夫参数自适应 IFIMM 算法研究[J]. 电子学报, 2006, (03): 521-524.
- [46]戴定成,姚敏立,蔡宗平等.改进的马尔可夫参数自适应 IMM 算法[J].电子学报,2017,45(05):1198-1205.
- [47]Han B, Huang H, Lei L, et al. An Improved IMM Algorithm Based on STSRCKF for Maneuvering Target Tracking [J]. IEEE Access, 2019, 7: 57795-57804.
- [48]杨标,朱圣棋,余昆等.贪婪的量测划分机制下的多传感器多机动目标跟踪算法 [J].电子与信息学报,2021,43(07):1962-1969.
- [49]Xie G, Sun L, Wen T, et al. Adaptive Transition Probability Matrix-Based Parallel IMM Algorithm [J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2021, 51(5):2980-2989.
- [50]叶瑾, 许枫, 杨娟, 等.一种改进的时变转移概率 AIMM 跟踪算法[J]. 2020, 39(2): 253-258
- [51]Lee I H, Park C G. An Improved Interacting Multiple Model Algorithm With Adaptive Transition Probability Matrix Based on the Situation [J]. International Journal of Control, Automation and Systems, 2023, 21:3299-3312.
- [52]曹一家, 刘美君, 丁理杰, 等. 大电网安全性评估的系统复杂性理论研究[J]. 电力系统及其自动化学报, 2007(01):1-8.
- [53]曹一家, 王光增.电力系统复杂性及其相关问题研究[J].电力自动化设备, 2010,30(02):5-10.
- [54]梁颖,方瑞明,卢小芬,等. 基于复杂网络理论的电力系统脆弱线路辨识研究现

- 状 [J]. 电力系统保护与控制, 2012, 40 (20): 151-155.
- [55]姚建国, 杨胜春, 王珂, 等. 智能电网“源-网-荷”互动运行控制概念及研究框架[J].电力系统自动化,2012,36(21):1-6.
- [56]侯玉强,方勇杰,杨卫东,等.综合电压频率动态交互影响的自动减负荷控制新方法[J].电力系统自动化,2010,34(5):24-28.
- [57]Chen B, Wang Y. Short-Term Electric Load Forecasting of Integrated Energy System Considering Nonlinear Synergy between Different Loads [J]. IEEE Access, 2021, 9: 43562-43573.
- [58]韦善阳, 黎静华, 黄乾, 等.考虑多重因素耦合的广义负荷特征曲线的模式分析[J].电力系统自动化,2021,45(01):114-122.
- [59]Li J, Zhu M, Liang J. Pattern simulation and analysis of generalized load profile coupling with active load and renewable energy power [J]. International Journal of Electrical Power & Energy Systems, 2020, 117:105611.
- [60]谢李为,李勇,罗隆福,等. 基于复杂网络与运行因素的电网薄弱点辨识方法 [J]. 电力系统保护与控制, 2022, 50 (04): 83-91.
- [61]胡臻,李欣然,刘光晔,等. 基于动态阻抗的源 - 网 - 荷耦合特性分析方法 [J]. 中国电机工程学报, 2017, 37 (04): 1106-1114.
- [62]谭玉东,李欣然,蔡晔,等. 基于电气距离的复杂电网关键节点识别 [J]. 中国电机工程学报, 2014, 34 (01): 146-152.
- [63]程鹏. 基于节点耦合关系的电力系统电压稳定分析与应用[D]. 湖南大学, 2017.
- [64]Berg G J. Power-system load representation [J]. Proceedings of the Institution of Electrical Engineers, 1973, 120(3):344-348.
- [65]Berg G J. System and load behaviour following loss of generation. Experimental results and evaluation [J]. Proceedings of the Institution of Electrical Engineers, 1972, 119(10):1483-1486.
- [66]Hill D J. Nonlinear dynamic load models with recovery for voltage stability studies [J]. IEEE Transactions on Power Systems, 1993, 8(1):166-176.
- [67]Popović D, Hiskens I A, Hill D J. Investigations of load-tap changer interaction [J]. International Journal of Electrical Power & Energy Systems, 1996, 18(2):81-97.
- [68]Shalalfeh L, Jonckheere E. Load aggregation effect in power grid[C]. 2016 IEEE 55th Conference on Decision and Control (CDC), Las Vegas, NV, USA, 2016:5793-5798.
- [69]Fairley P. Sniffing out grid attacks [J]. IEEE Spectrum, 2016, 53(9):13-15.

- [70]Kirchhoff G, Gustav R. Ueber die Auflösung der Gleichungen, auf welche man bei der Untersuchung der linearen Vertheilung galvanischer Ströme geführt wird[J]. Annalen der Physik, 1847, 148: 497-508.
- [71]Oepomo T S. Applied Graph Theory and Topology for 3 Phase Power System Under Faulted Studies[C]. Proceedings of the Seventh International Conference on Management Science and Engineering Management, 2014.
- [72]Kohler, Iris. Graph Theoretical Modelling of Electrical Distribution Grids [D]. California Polytechnic State University, 2021.
- [73]Coto M., Arboleya P, González-Morán C. On the Use of Graph Theory for Railway Power Supply Systems Characterization [J]. Intelligent Industrial Systems, 2015, 1:127-139.
- [74]Liao W, Yang D, Wang Y, et al. Fault diagnosis of power transformers using graph convolutional network[J]. CSEE Journal of Power and Energy Systems, 2021, 7(2):241-249.
- [75]廖文龙,于贇,王煜森,等.基于图卷积网络的配电网无功优化[J].电网技术, 2021, 45(06): 2150-2160.
- [76]Wang Z, Yang F, Xu Q, et al. Capacity estimation of lithium-ion batteries based on data aggregation and feature fusion via graph neural network[J]. Applied Energy, 2023, 336:120808.
- [77]Zhou X, Zhang Y, Wei Q. Few-shot fine-grained image classification via GNN [J]. Sensors, 2022, 22:7640.
- [78]张翼,朱永利.图信号与图卷积网络相结合的局部放电模式识别方法[J].中国电机工程学报, 2021, 41(18):6472-6481.
- [79]Wan Y, Yuan C, Zhan M, et al. Robust graph learning with graph convolutional network [J]. Information Processing & Management, 2022, 59(3):102916.
- [80]Lv J, Mirosław P, Annakkage U D, et al. Statistical testing for load models using measured data [J]. Electric Power Systems Research, 2018, 163: 66-72.
- [81]Wang C, Wang Z, Wang J, et al. SVM-based parameter identification for composite ZIP and electronic load modeling [J]. IEEE Transactions on Smart Grid, 2019, 34(1):182-193.
- [82]Mitra A, Dutta R, Gupta A, et al. A Robust Data-Driven Approach for Adaptive Dynamic Load Modeling [J]. IEEE Transactions on Power Systems, 2022, 37(5):3779-3791.
- [83]Zhu Y, Jovica V M. Efficient identification of critical load model parameters

- affecting transient stability [J]. Electric Power Systems Research, 2019, 175: 105929.
- [84]Melanie B, Liu Y. The impact of large-scale dynamic load modeling on frequency response in the U.S. Eastern Interconnection [J]. International Journal of Electrical Power & Energy Systems, 2020, 120: 105983.
- [85]Cui J, Yu R, Zhao, D, et al. Intelligent load pattern modeling and denoising using improved variational mode decomposition for various calendar periods[J]. Applied Energy, 2019, 247: 480–91.
- [86]汤奕, 崔晗, 党杰. 基于继承思想的时变性电力系统暂态稳定预测[J].中国电机工程学报, 2021,41(15):5107-5119.
- [87]董新洲, 汤涌, 卜广全, 等.大型交直流混联电网安全运行面临的问题与挑战 [J].中国电机工程学报, 2019, 39(11):3107-3119.
- [88]朱蜀, 刘开培, 秦亮, 等.电力电子化电力系统暂态稳定性分析综述[J].中国电机工程学报, 2017, 37(14):3948-3962+4273.
- [89]李亚楼, 张星, 胡善华, 等.含高比例电力电子装备电力系统安全稳定分析建模仿真技术[J].电力系统自动化, 2022, 46(10):33-42.
- [90]石景海,贺仁睦.动态负荷建模中的负荷时变性研究[J].中国电机工程学报, 2004(04):89-94.
- [91]段献忠, 汪馥英, 何仰赞,等.负荷建模研究现状综述[J].电力系统自动化,1994(08):60-68.
- [92]Wang Z, Wang J. Review on Implementation and Assessment of Conservation Voltage Reduction [J]. IEEE Transactions on Power Systems, 2014, 29(3): 1306-1315.
- [93]Wang Z, Wang J. Time-Varying Stochastic Assessment of Conservation Voltage Reduction Based on Load Modeling [J]. IEEE Transactions on Power Systems, 2014, 29(5):2321-2328.
- [94]Zhao J, Wang Z, Wang J. Robust Time-Varying Load Modeling for Conservation Voltage Reduction Assessment [J]. IEEE Transactions on Smart Grid, 2018, 9(4):3304-3312.
- [95]Khodayar M, Wang J. Probabilistic Time-Varying Parameter Identification for Load Modeling: A Deep Generative Approach [J]. IEEE Transactions on Industrial Informatics, 2021, 17(3):1625-1636.
- [96]Wang C, Wang Z, Wang J, et al. Robust Time-Varying Parameter Identification for Composite Load Modeling [J]. IEEE Transactions on Smart Grid, 2019, 10(1):

967-979.

- [97]张红斌. 电力系统负荷模型结构与参数辨识的研究[D].华北电力大学(北京), 2004.
- [98]Si C, Xu S, Wan C, et al. Electric load clustering in smart grid: Methodologies, applications, and future trends [J]. *Journal of Modern Power Systems and Clean Energy*, 2021, 9(2): 237-252.
- [99]Amir F, Mark G. Analysing the effects of seasonal variation on occupancy in an electricity demand model [J]. *International Journal of Low-Carbon Technologies*, 2013, 8(4): 282-288.
- [100]Vincent F, Thi H, Jatinder N. Sustainable microgrid design with multiple demand areas and peer-to-peer energy trading involving seasonal factors and uncertainties[J]. *Renewable and Sustainable Energy Reviews*, 2022, 161:112342.
- [101]李中强. 基于模糊逻辑强跟踪的交互式多模型电力负荷建模研究[D]. 山东大学, 2021.
- [102]Hossan M S, Chowdhury B. Comparison of Time-Varying Load Models for Estimating CVR Factor and VSF Using Dual-Stage Adaptive Filter [J]. *IEEE Transactions on Power Delivery*, 2019, 34(3):1001-1010.
- [103]Ma Z, Xiang Y, Wang Z. Robust Conservation Voltage Reduction Evaluation Using Soft Constrained Gradient Analysis [J]. *IEEE Transactions on Power Systems*, 2022, 37(6):4485-4496.
- [104]张红斌, 贺仁睦, 刘应梅. 基于 KOHONEN 神经网络的电力系统负荷动特性聚类与综合[J].*中国电机工程学报*,2003(05):2-6+44.
- [105]曾博, 张建华, 丁蓝, 等. 改进自适应模糊 C 均值算法在负荷特性分类的应用 [J].*电力系统自动化*,2011,35(12):42-46.
- [106]李培强, 李欣然, 陈辉华,等.基于模糊聚类的电力负荷特性的分类与综合[J].*中国电机工程学报*, 2005, 25(24): 73-78.
- [107]Wang Z, Bian S, Liu Y, et al. The load characteristics classification and synthesis of substations in large area power grid [J]. *International Journal of Electrical Power & Energy Systems*, 2013, 48:71-82.
- [108]Zhang S, Yu S, Sun Y, et al. Fast classification, aggregation, and modeling of load clusters for transient voltage stability [J]. *International Journal of Electrical Power & Energy Systems*, 2021, 124:106368.
- [109]李欣然, 林舜江, 刘杨华, 等. 基于实测响应空间的负荷动特性分类原理与方法[J].*中国电机工程学报*, 2006, (08): 39-44.

- [110]Wang Z, Bian S, Lei M, et al. Feature extraction and classification of load dynamic characteristics based on lifting wavelet packet transform in power system load modeling [J]. International Journal of Electrical Power & Energy Systems, 2014, 62:353-363.
- [111]Zhou K, Yang S, Shen C. A review of electric load classification in Smart Grid Environment [J]. Renewable and Sustainable Energy Reviews, 2013, 24:103-110.
- [112]Matthew L, David A, Miaomiao H. Seasonal variation in household electricity demand: A comparison of monitored and synthetic daily load profiles [J]. Energy and Buildings, 2018, 179: 292-300.
- [113]牛牧童, 廖凯, 杨健维, 等.考虑季节特性的多时间尺度电动汽车负荷预测模型[J].电力系统保护与控制,2022,50(5):74-85.
- [114]Mayur B, Nalin B, Dev C. Season specific approach for short-term load forecasting based on hybrid FA-SVM and similarity concept [J]. Energy, 2019, 174:886-896.
- [115]Fintan M, Aidan D, Michael C. A clustering approach to domestic electricity load profile characterization using smart metering data [J]. Applied Energy, 2015, 141:190-199.
- [116]Ignacio B, Alfredo Q, José-Luis D, et al. Dynamic clustering segmentation applied to load profiles of energy consumption from Spanish customers[J]. International Journal of Electrical Power & Energy Systems, 2014, 55:437-448.
- [117]Pietro F, Emanuele C, Mauro T, et al. Comparison and clustering analysis of the daily electrical load in eight European countries[J]. Electric Power Systems Research, 2016, 141:114-123.
- [118]马瑞, 周谢, 彭舟, 等.考虑气温因素的负荷特性统计指标关联特征数据挖掘[J].中国电机工程学报,2015, 35(1):43-51.
- [119]白雅玲, 周亚同, 刘君. 基于深度卷积嵌入聚类的日负荷曲线聚类分析[J].电网技术, 2022,46(06):2104-2113.
- [120]Anunay G, Anjum, Shreyansh G, et al. InstaCovNet-19: A deep learning classification model for the detection of COVID-19 patients using Chest X-ray [J]. Applied Soft Computing, 2021, 99:106859.
- [121]Johan F, Murat S, Burak K, et al. TableDet: An end-to-end deep learning approach for table detection and table image classification in data sheet images [J]. Neurocomputing, 2022, 468:317-34.
- [122]Kapil G, Varun B, Irshad A A. OSACN-Net: Automated classification of sleep

- apnea using deep learning model and smoothed gabor spectrograms of ECG signal [J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71:1-9.
- [123]Zheng W, Huang W, David J H. A deep learning-based general robust method for network reconfiguration in three-phase unbalanced active distribution networks [J]. International Journal of Electrical Power & Energy Systems, 2020, 120:105982.
- [124]Zhang Y, Shi X, Zhang H, et al. Review on deep learning applications in frequency analysis and control of modern power system[J]. International Journal of Electrical Power & Energy Systems, 2022, 136: 107744.
- [125]Li Y, Zhang M, Chen C. A Deep-Learning intelligent system incorporating data augmentation for Short-Term voltage stability assessment of power systems [J]. Applied Energy, 2022, 308:118347.
- [126]Sun M, He L, Zhang J. Deep learning-based probabilistic anomaly detection for solar forecasting under cyberattacks [J]. International Journal of Electrical Power & Energy Systems, 2022, 137:107752.
- [127]Li Y, Wei X, Li Y, et al. Detection of false data injection attacks in smart grid: a secure federated deep learning approach[J]. IEEE Transactions on Smart Grid, 2022, 13(6): 4862-4872.
- [128]Vanting N, Ma Z, Jørgensen, B. A scoping review of deep neural networks for electric load forecasting [J]. Energy Informatics, 2021, 4 (Suppl 2):49.
- [129]Huang G, Wu F, Guo C. Smart grid dispatch powered by deep learning: a survey [J]. Frontiers of Information Technology & Electronic Engineering, 2022, 23:763–776.
- [130]Kim Y R, Sul S K, Park M H. Speed sensorless vector control of induction motor using extended Kalman filter[J]. IEEE Transactions on Industry Applications, 1994, 30(5):1225-1233.
- [131]姚致清,张茜,刘喜梅.基于 PSCAD/EMTDC 的三相光伏并网发电系统仿真研究 [J].电力系统保护与控制,2010,38(17):76-78.
- [132]Cidras J, Feijoo A E. A linear dynamic model for asynchronous wind turbines with mechanical fluctuations [J]. IEEE Transactions on Power Systems, 2002, 17(3): 681-687.
- [133]Marco G, Gabriele M, Franco S. A new model for learning in graph domains[C]. Proceedings 2005 IEEE International Joint Conference on Neural Networks, 2005:729–734.
- [134]Franco S, Marco G, Ah C T, et al. The graph neural network model [J]. IEEE

- Transactions on Neural Networks, 2009, 20(1):61–80.
- [135]Paul M, Fouad A. Power System Control and Stability[M]. New Jersey: Wiley-IEEE Press, 2002.
- [136]Girraj S, Chauhan D, Aseem C, et al. Factor Affecting Elements and Short term Load forecasting Based on Multiple Linear Regression Method[J]. International Journal of Engineering Research & Technology, 2014, 3(12):736-740.
- [137]Jornaz A. Modeling daily electricity load curve using cubic splines and functional principal components [D]. Missouri University of Science and Technology, 2016.
- [138]Haeran Cho, Yannig Goude, Xavier Brossat, et al. Modeling and Forecasting Daily Electricity Load Curves: A Hybrid Approach [J]. Journal of the American Statistical Association, 2013, 108(501):7-21.
- [139]Liu S, Wang S, Hu C, et al. Determination of alcohols-diesel oil by near infrared spectroscopy based on gramian angular field image coding and deep learning[J]. Fuel, 2022, 309: 122121.
- [140]Chan T, Jia K, Gao S, et al. PCANet: a simple deep learning baseline for image classification? [J]. IEEE Trans. Image Process, 2015, 24 (12): 5017–5032.
- [141]Graves A, Schmidhuber J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures [J]. Neural Networks, 2005, 18 (5): 602–610.
- [142]Senthil K, Malarvizhi N. Bi-directional LSTM–CNN combined method for sentiment analysis in part of speech tagging (PoS) [J]. International Journal of Speech Technology, 2020, 23:373–380.
- [143]Özkaya U, Öztürk Ş, Melgani F, et al. Residual CNN + Bi-LSTM model to analyze GPR B scan images[J]. Automation in Construction, 2021, 123: 103525.
- [144]Lu S, Lin G, Liu H, et al. A Weekly Load Data Mining Approach Based on Hidden Markov Model [J]. IEEE Access, 2019, 7:34609-34619.
- [145]Tukey J W. Exploratory data analysis [M]. Addison-Wesley, Reading, 1977.
- [146]Zoltan G, Vladimir K, Mirjana I, et al. Weighted kNN and constrained elastic distances for time-series classification [J]. Expert Systems with Applications, 2020, 162:113829.
- [147]Wang X, Smith K, Hyndman R. Characteristic-based clustering for time series data [J]. Data Mining and Knowledge Discovery, 2006, 13(3):335–364.
- [148]Morchen F, Ultsch A, Thies M, et al. Modeling timbre distance with temporal statistics from polyphonic music [J]. IEEE Transactions on Audio, Speech, and

- Language Processing, 2006, 14(1):81-90.
- [149]LeCun Y, Boser B, Denker J, et al. Backpropagation Applied to Handwritten Zip Code Recognition [J]. Neural Computation, 1989, 1(4):541-551.
- [150]Pereira S, Pinto A, Alves V, et al. Brain Tumor Segmentation Using Convolutional Neural Networks in MRI Images [J]. IEEE Transactions on Medical Imaging, 2016, 35(5):1240-1251.
- [151]Campanharo A, Sirer M, Malmgren R, Ramos F, et al. Duality between Time Series and Networks [J]. PLoS ONE, 2011, 6(8): e23378.
- [152]Wu J, Qiu S, Kong Y, et al. PCANet: An energy perspective [J]. Neurocomputing, 2018, 313:271-287.